

Um instrumento para avaliar a autoeficácia em Cursos introdutórios de algoritmos

Holger Danielsiek,
Departamento de Ciência da Computação,
Westfälische Wilhelms-Universität Münster,
Einsteinstr. 62, 48149 Münster,
Alemanha, holger.danielsiek@uni-
muenster.de

Laura Toma
Departamento de Ciência da Computação
Bowdoin College
8650 College Station
Brunswick, ME 04011, EUA
ltoma@bowdoin.edu

Jan Vahrenhold,
Departamento de Ciência da Computação,
Westfälische Wilhelms-Universität Münster,
Einsteinstr. 62, 48149 Münster,
Alemanha, jan.vahrenhold@uni-
muenster.de

RESUMO

Apresentamos o desenvolvimento e a validação de um instrumento para avaliar a autoeficácia em um curso introdutório de algoritmos. O instrumento foi desenvolvido com base em trabalhos anteriores de Ramalingam e Wiedenbeck e avaliado em um contexto multi-institucional. Realizamos análises estatísticas das pontuações obtidas com o instrumento e comparamos nossos resultados com medidas psicométricas validadas. Essas análises demonstram que nossos resultados são consistentes com a teoria da autoeficácia e, portanto, sugerem validade de construto.

CONCEITOS CCS

• **Tópicos sociais e profissionais** y **Educação em ciência da computação**; Avaliação de alunos;

PALAVRAS-CHAVE

Educação em Ciência da Computação; Autoeficácia; Algoritmos

1 INTRODUÇÃO

A autoeficácia, introduzida por Bandura [2], é um conceito de crença em si mesmo ao qual, entre outros efeitos, foram atribuídas influências consideráveis no desempenho acadêmico — veja, por exemplo, Pajares e Schunk [31] e as referências ali citadas. De acordo com Bandura, a autoeficácia, ou seja, a expectativa de eficácia pessoal, determina “se o comportamento de enfrentamento será iniciado, quanto esforço será despendido e por quanto tempo será sustentado diante de obstáculos e experiências aversivas” [2, p. 191]. À luz de relatos recentes sobre problemas de saúde mental e diminuição da resiliência entre estudantes universitários [19, 40], uma correlação positiva entre autoeficácia e comportamento de enfrentamento torna a investigação da autoeficácia em cursos de graduação em computação relevante não apenas de um ponto de vista puramente voltado para o desempenho.

Tem sido argumentado que a autoeficácia pode ser influenciada por métodos de ensino correspondentes — veja, por exemplo, [1, 35, 42] e as referências neles contidas. Para o desenvolvimento e avaliação de tais métodos, são necessários instrumentos validados para medir a autoeficácia. Embora Bandura descreva o conceito de autoeficácia de forma não específica a um domínio, é evidente que estratégias e técnicas de enfrentamento para desafios específicos de um domínio devem ser avaliadas com instrumentos específicos para esse domínio. Poderia-se argumentar que o desenvolvimento de um instrumento de autoeficácia específico para cada disciplina do currículo talvez não seja necessário. Contudo, considerando que cursos avançados ou aulas de ciência da computação no ensino médio geralmente se concentram em programação e conceitos relacionados, um curso de algoritmos provavelmente apresentará desafios mesmo para aqueles com experiência prévia em ciência da computação. Portanto, mesmo alunos que ingressaram na universidade bem preparados podem precisar superar obstáculos e vivenciar situações adversas. Para entender como lidar com isso, um instrumento específico para a disciplina em

Embora a autoeficácia influencie o desempenho acadêmico, as expectativas de eficácia por si só não são suficientes [2, 25]. Além das expectativas de eficácia, são necessárias expectativas de resultados correspondentes. A expectativa de resultado diz respeito à crença de que um determinado comportamento resultará em um determinado resultado, enquanto a expectativa de eficácia diz respeito à crença de que se pode executar um determinado comportamento (que potencialmente leva a um determinado resultado) [2]. Dito de outra forma, as expectativas de resultado são necessárias para alinhar os comportamentos de uma pessoa a um determinado objetivo, mas é diferente estar convencido de que se pode realmente fazer o que é necessário para atingir esses objetivos. Em nosso estudo, focamos nas expectativas de eficácia.

A autoeficácia não se manifesta necessariamente em “notas mais altas”, mas pode ser vista como “uma medida importante do que os alunos ‘obtem’” [42, p. 374] de uma aula. Consequentemente, medir a autoeficácia é diferente de medir o desempenho acadêmico.

Nossa questão de pesquisa foi como desenvolver e validar conceitualmente um instrumento para avaliar a autoeficácia no contexto de um curso de algoritmos. Discutimos o desenho de tal instrumento, uma análise fatorial exploratória juntamente com uma investigação da consistência interna e — por meio da comparação de nossos resultados com a teoria da autoeficácia e outras medidas — sua validade de construto. Como a validação de um instrumento desse tipo geralmente requer múltiplas iterações, as questões de pesquisa sobre a identificação de fatores que influenciam o construto medido e o desenvolvimento de intervenções correspondentes não puderam ser abordadas durante os estágios iniciais do desenvolvimento relatados aqui e, portanto, são objeto de trabalhos futuros.

É concedida permissão para fazer cópias digitais ou impressas, totais ou parciais, desta obra para uso pessoal ou em sala de aula, sem custo, desde que as cópias não sejam feitas ou distribuídas para fins lucrativos ou comerciais e que as cópias contenham este aviso e a citação completa na primeira página. Os direitos autorais dos componentes desta obra que pertencem a terceiros que não o (s) autor(es) devem ser respeitados. É permitido fazer resumos com a devida atribuição. Para copiar, republicar, postar em servidores ou redistribuir para listas, é necessária permissão prévia específica e/ou o pagamento de uma taxa. Solicite permissões pelo e-mail permissions@acm.org. ICER '17, 18 a 20 de agosto de 2017, Tacoma, WA, EUA

© 2017 Direitos autorais reservados ao(s) proprietário(s)/autor(es). Direitos de publicação licenciados à Association for Computing Machinery.

ACM ISBN 978-1-4503-4968-0/17/08...\$15,00

<https://doi.org/10.1145/3105726.3106171>

2 TRABALHOS RELACIONADOS

O conceito de autoeficácia tem recebido considerável atenção na psicologia educacional (ver, por exemplo, [31] e as referências ali citadas): de acordo com o Google Scholar, o artigo seminal de Bandura foi citado mais de 43.000 vezes. Em contraste, o estudo sistemático da autoeficácia tem recebido comparativamente pouca atenção no ensino de ciência da computação, com foco exclusivo na autoeficácia em programação introdutória. Ramalingam e Wiedenbeck [36] desenvolveram um instrumento de 32 itens para medir a autoeficácia em programação de computadores. Este instrumento possui subescalas para quatro fatores derivados empiricamente, interpretados como “Independência e Persistência”, “Tarefas Simples de Programação”, “Autorregulação” e “Tarefas Complexas de Programação” [36]. Usando este instrumento, Zingaro [42] mostrou que a instrução por pares contribui positivamente para a autoeficácia em um curso de CS1. Ramalingam et al. [35] basearam-se em seu trabalho anterior para relacionar experiências prévias, autoeficácia e modelos mentais como fatores que influenciam o desempenho em um curso introdutório de programação. Outra escala de autoeficácia foi desenvolvida por Quade [34], porém, esta escala não é específica para o conteúdo do curso e, em vez disso, inclui expectativas acadêmicas e de carreira mais gerais. Em um estudo qualitativo de pequena escala, Kinnunen e Simon [24] investigaram a autoeficácia de calouros de ciência da computação usando uma abordagem de teoria fundamentada, eles se concentraram no papel das tarefas de programação.

A teoria da mentalidade de crescimento [14] tem sido tema de diversos artigos recentes na comunidade de pesquisa em educação computacional, por exemplo, [28, 38]. Essa teoria se preocupa com a crença do aluno de que sua inteligência e habilidades podem ser desenvolvidas. Embora relacionada à autoeficácia, existem diferenças importantes: por exemplo, um aluno pode ter uma mentalidade fixa, ou seja, acreditar que suas habilidades e inteligência são inatas e imutáveis, mas ainda assim relatar alta autoeficácia para determinadas tarefas. Por outro lado, uma mentalidade de crescimento apoia o desenvolvimento da autoeficácia e vice-versa — veja a revisão da literatura de Farrington et al. [15].

3 PARTICIPANTES E ADMINISTRAÇÃO

Ao compor o grupo de estudo para o desenvolvimento de um instrumento de avaliação da autoeficácia em algoritmos, tivemos que equilibrar diferentes aspectos: por um lado, era necessário considerar uma população suficientemente grande para trabalhar em condições semelhantes às de Ramalingam e Wiedenbeck, que utilizaram $n = 421$ respostas para o desenvolvimento de suas escalas. Por outro lado, observando que Ramalingam e Wiedenbeck agregaram “oito turmas [...] ministradas por sete instrutores diferentes” [36, p. 369], também buscamos utilizar cursos ministrados por diferentes instrutores para reduzir possíveis vieses. Levando em conta tanto as medidas de matrícula quanto os objetivos da missão (dois dos quatro critérios sugeridos por Rawson et al. [37] relevantes para o nosso contexto), chegamos a quatro instituições participantes diferentes. Três delas (Bowdoin College, Washington & Lee University e Williams College) estão localizadas nos Estados Unidos, e a outra (Westfälische Wilhelms-Universität Münster) está localizada na Europa. As três escolas americanas têm sido consistentemente classificadas entre as melhores instituições de ensino superior para graduação. O departamento de ciência da computação da Universidade de Münster (Westfälische Wilhelms-Universität Münster) possui tamanho comparável, além de índices de matrícula e proporção aluno-professor semelhantes aos das outras instituições. Todos os instrutores eram professores pesquisadores titulares; o segundo autor ministrou o curso no Bowdoin College.

O fato de este conjunto de participantes não ser representativo da população estudantil em geral foi uma escolha deliberada do projeto. Devido à relativa homogeneidade da população estudantil, mais fatores externos puderam ser descartados na análise da validade de construto do instrumento. Além disso, a teoria da autoeficácia prevê que os ganhos serão maiores para aqueles com baixa autoeficácia inicial [2]. Portanto, um instrumento desenvolvido com base em dados de participantes que supostamente apresentam uma autoeficácia inicial relativamente alta [1] e que se mostra sensível até mesmo a pequenas mudanças, possui valor adicional. Ao interpretar os resultados de futuras aplicações do instrumento, no entanto, as características do respectivo grupo de estudo devem ser levadas em consideração.

O tamanho da população estudantil da qual foram obtidas respostas completas durante o estudo pré-curso que levou à construção das subescalas do nosso instrumento foi de $n_{\text{pré-curso}} = 362$. Destes, 53 participantes eram de instituições dos EUA, enquanto 309 eram da Universidade de Münster (Westfälische Wilhelms-Universität Münster). O grande número de estudantes da Universidade de Münster se explica pelo fato de o curso de algoritmos ser uma disciplina do segundo semestre, frequentada por alunos de diversas áreas, incluindo Matemática, Física ou Administração de Empresas; todos os alunos haviam cursado a mesma disciplina de “Introdução à Programação” no semestre anterior e, portanto, eram indistinguíveis em termos de exposição prévia a conceitos de ciência da computação na universidade. Os estudantes dos EUA haviam cursado “Introdução à Ciência da Computação” e “Estruturas de Dados” antes das disciplinas de “Algoritmos” consideradas. Para garantir a validade do estudo, observamos que, com exceção da programação dinâmica (ver Seção 6), todos os alunos foram expostos aos mesmos conceitos, algoritmos e requisitos de competência.

O instrumento foi aplicado em sala de aula e em formato impresso, visto que a experiência de um pequeno estudo piloto, bem como de outras pesquisas, indicava uma alta taxa de resposta. Em cada folha de papel, os alunos foram solicitados a fornecer um código hash unidirecional baseado em informações confidenciais; esse código foi usado para identificar as respostas anônimas dos questionários pré e pós-curso. Os questionários pré-curso foram aplicados durante a primeira semana de aulas, e os questionários pós-curso, durante a última semana de aulas.

Como a participação foi voluntária e, mais importante, a frequência às aulas não era obrigatória, obtivemos $n_{\text{pós-curso}} = 130$ respostas aos questionários pós-curso. O número de respostas correspondentes de todos os questionários pré e pós-curso foi $n_{\text{correspondentes}} = 107$ (28 dos EUA/79 da Europa). Antecipando as análises detalhadas na Seção 6, onde apresentaremos as pontuações pré e pós-curso de forma agregada, ou seja, para todos os participantes, e detalhadas por continente, observamos que o desequilíbrio nominal da população do estudo não afetou a significância dos resultados relatados.

4. PROJETO DO INSTRUMENTO

Na concepção do nosso instrumento, partimos da escala fornecida por Ramalingam e Wiedenbeck [36]. Examinamos cada item e verificamos se os construtos subjacentes poderiam ser transferidos para um curso de algoritmos. Isso levou à exclusão de quase metade dos itens que se referiam, por exemplo, ao uso de palavras reservadas em um

A Tabela 4 mostra, de fato, pontuações iniciais bastante elevadas.

linguagem de programação, o paradigma orientado a objetos ou o uso de funções ou bibliotecas de terceiros. Também decidimos não reformular a subescala de “autorregulação” no contexto de algoritmos, pois, após o artigo de Ramalingam e Wiedenbeck, a teoria da autodeterminação levou a um instrumento psicométrico validado para medir a autorregulação [4]; além disso, o conceito de “prazo para um projeto de programação” [36] não tem equivalente direto em um curso de algoritmos.

Dependendo da escola e das preferências dos instrutores, o foco principal de um curso de algoritmos pode variar entre os detalhes da implementação em uma linguagem de programação específica e as provas formais de correção. Além disso, não é incomum na Europa ensinar tanto estruturas de dados quanto algoritmos (não avançados) em um mesmo curso, adiando tópicos mais avançados, como programação dinâmica ou randomização, para cursos de nível superior. Cada instrutor pode ter preferências pessoais sobre quais algoritmos explicar com mais detalhes. Por fim, a atribuição de algoritmos a um curso introdutório específico não é totalmente consensual, mesmo dentro do escopo do currículo de computação da ACM [21].

Para tornar nosso instrumento o mais amplamente aplicável possível, decidimos não nos concentrar em algoritmos específicos, como o Quicksort ou o algoritmo de Floyd-Warshall. Ao fazer isso, também tentamos evitar a armadilha de solicitar uma autoavaliação de habilidades muito específicas, como a execução de um algoritmo em particular, em vez da autoeficácia pretendida, relacionada a uma compreensão mais geral de tópicos em algoritmos. Com base em aspectos curriculares e trabalhos anteriores sobre tópicos em algoritmos propensos a concepções errôneas [17, 39], construímos itens referentes à análise de tempo de execução, divisão e conquista e programação dinâmica; veja a Tabela 1.

Optamos deliberadamente por incluir apenas itens que pudessem ser operacionalizados facilmente. Em particular, embora parte da motivação para um bom desempenho em um curso de algoritmos seja o fato de grandes empresas incluírem itens de “resolução de problemas” em suas avaliações, abstinemo-nos de incluir itens mais genéricos de “resolução de problemas” ou “abstração” em nosso instrumento.² Uma razão muito prática para isso é que o instrumento, assim como o de Ramalingam e Wiedenbeck, foi projetado para ser administrado em um nível universitário muito básico ou talvez até mesmo em um nível de colocação avançada e, portanto, deve ser refinado para aspectos muito básicos. Mais importante ainda, pesquisas recentes sobre abstração em aulas de ciência da computação mostram “uma forte tendência, por parte de muitos alunos veteranos, de permanecer em baixos níveis de abstração, mesmo depois de vivenciar a abstração em uma variedade de cursos de ciência da computação” [18, p. 242] e identificam uma falta de prática de abstração em cursos de algoritmos. Além disso, o desenvolvimento de estratégias de abstração parece levar mais tempo do que o curso de um semestre [32].

A existência de uma escala de “resolução de problemas” em Matemática parece contradizer o raciocínio acima. De fato, Pajares e Miller [30] relatam ter usado a Escala de Confiança em Matemática de Dowling [12]; outro conjunto de itens foi proposto por Dunham [13]. Uma análise mais detalhada desses itens, no entanto, revela que o termo “resolução de problemas” é usado de forma diferente: os itens da escala de Dunham apresentam um problema matemático da forma “Resolva $\frac{y-2}{x+3} = 0$ ” [13, p. 123] e perguntam ao sujeito sobre a confiança em selecionar corretamente uma das cinco respostas dadas. Os itens da escala de Dowling [3] são da forma “Um conjunto de sala de estar composto por um sofá e uma cadeira tem o preço de

a \$200. Se o preço do sofá for 50% maior que o preço da cadeira, encontre o preço do sofá” [20, Tabela 3]. Em contraste, a tarefa de “resolver um problema” em um curso de algoritmos geralmente inclui modelar o problema, elaborar um algoritmo (ou outra construção matemática), provar sua correção e, em seguida, aplicá-lo ao cenário dado, veja, por exemplo, [18]. Portanto, nosso raciocínio acima permanece válido.

Conforme discutido anteriormente, Ramalingam e Wiedenbeck identificaram “Independência e Persistência” como o fator com o maior autovetor. Os itens correspondentes referiam-se à “conclusão de um projeto de programação” com diferentes níveis de suporte. Abordamos essa questão construindo itens tanto para o projeto do algoritmo quanto para a análise de tempo de execução, que pressupunham níveis equivalentes de suporte disponível. Um estudo piloto de pequena escala no Bowdoin College (outono de 2015) demonstrou que a aplicação do instrumento não apresentou obstáculos organizacionais. Além disso, nenhum aluno relatou dificuldades em compreender os itens.

5 ANÁLISE FATORIAL EXPLORATÓRIA

Para avaliar a validade de construto do nosso instrumento e para melhor interpretar os resultados, seguimos Ramalingam e Wiedenbeck e realizamos uma análise fatorial exploratória dos dados pré-curso.⁴ Em consonância com a abordagem anterior, os dados foram extraídos utilizando a fatoração de eixos principais e, como não se podia esperar que os fatores fossem independentes, uma rotação fatorial oblimin direta.

Com 21 itens e npré-curso = 362 respostas ao questionário pré-curso, a medida geral de Kaiser-Meyer-Olkin (KMO) foi de 0,908, com medidas KMO individuais todas superiores a 0,846, classificando os resultados de “meritório” a “maravilhoso” [22]. O Teste de Esfericidade de Bartlett foi estatisticamente significativo ($p < 0,001$, $\chi^2 = 6027,217$), indicando que os dados provavelmente eram fatoráveis. A análise revelou quatro fatores com autovalores maiores que 1, que explicaram 44,3%, 9,3%, 7,9% e 4,7% da variância total, respectivamente. Juntos, esses fatores explicaram 66,3% da variância total. Esses fatores atenderam ao critério de interpretabilidade e, portanto, foram mantidos.

A interpretação dos dados foi consistente com o que o instrumento foi projetado para medir, indicando validade de construto.

Os dados mostraram uma forte correlação dos itens referentes ao projeto de um algoritmo com diferentes graus de suporte no Fator 1. Este fator, “Projeto de Algoritmo”, representou 44,3% da variância e incluiu um item referente à busca de contraexemplos para um algoritmo sabidamente incorreto; este item, contudo, possui um baixo fator de correlação de 0,390. Cinco itens referentes à compreensão e aplicação dos paradigmas de dividir para conquistar e programação dinâmica apresentaram forte correlação no Fator 2. Este fator representou 9,3% da variância e é denominado “Paradigmas Avançados”. Quatro itens referentes à análise do tempo de execução de um algoritmo, com diferentes graus de suporte, apresentaram forte correlação no Fator 3. Este fator representou 7,9% da variância e é denominado “Análise de Tempo de Execução”. Os seis itens restantes, referentes à produção e rastreamento de pseudocódigo, apresentaram forte correlação no Fator 4. Este fator representou 4,7% da variância e é denominado “Escrita e Rastreamento de Pseudocódigo”.

Os detalhes, apresentados na Tabela 1, também mostram que existem dois itens com baixas cargas fatoriais primárias: a carga fatorial primária do Item 10 “Rastrear mentalmente a execução de um algoritmo iterativo que me foi dado” (Fator “Escrita e Rastreamento de Pseudocódigo”) é apenas marginal.

²Isto contrasta com um instrumento deliberadamente genérico para avaliar a autoeficácia no projeto de engenharia [7].

³Relatamos a adaptação de Hackett e Betz [20].

⁴Todas as análises estatísticas relatadas foram realizadas utilizando o IBM SPSS™ 24. Intervalos de confiança de 95%.

Não.	Descrição do item	II	III	4	² M SD
Fator 1: Projeto do Algoritmo ($\bar{y} = 0,898$)					
6.	Elabore um algoritmo para o caso de eu poder ligar para alguém e pedir ajuda se eu ficar preso em algum problema.	.916	-.044 .051	0,004 0,757 5,27 1,310	
7.	Elaborei um algoritmo depois que alguém me ajudou a começar.	.856	-.043 -.043 -.007 .734 5.17 1.311		
8.	Se eu tivesse bastante tempo, criaria um algoritmo.	0,830	-.057 -.094 -.035 0,704 5,35 1,335		
4.	Organize e projete um algoritmo de forma modular.	.624	.210 .068	0,031 0,533 4,15 1,505	
9.	Encontrar maneiras de superar o problema caso eu fique preso ao elaborar uma solução. um algoritmo.	.444	.087 -.222	.182 .591 4.42 1.311	
15.	Elabore um contraexemplo para um algoritmo sabidamente incorreto.	.390	.158 -.144 .169 .483 4.20 1.427		
Fator 2: Paradigmas Avançados ($\bar{y} = 0,881$)					
18.	Compreenda o paradigma da programação dinâmica.	-0,077 0,943	-0,032 -0,025 0,834 3,43 1,725		
19.	Compreender um algoritmo de programação dinâmica.	-0,023 0,942	0,040 -0,041 0,818 3,43 1,673		
20.	Escreva uma definição recursiva da solução ótima para um problema dinâmico. programa.	0,042 0,799	-0,009 -0,070 0,645 3,02 1,536		
17.	Compreenda o paradigma de dividir para conquistar.	.091 .506	-.096	.196 .505 4.99 1.541	
5.	Compreender um algoritmo complexo de divisão e conquista.	.303 .362	-.064 .191 .532 3.90 1.720		
Fator 3: Análise de Tempo de Execução ($\bar{y} = 0,929$)					
12.	Análise o tempo de execução de um algoritmo depois que alguém me ajudou. Comece agora.	.040 -.045 -.937	-.058 .843 4.59 1.481		
13.	Analisaria o tempo de execução de um algoritmo se tivesse bastante tempo para isso.	0,005 -0,005 -0,914	-0,028 0,843 4,59 1,481		
11.	Análise o tempo de execução de um algoritmo se eu pudesse ligar para alguém para pedir ajuda se Fiquei preso.	-0,063 -0,009 -0,912	-0,014 0,755 4,56 1,557		
14.	Encontrar maneiras de superar o problema caso eu fique preso em algum ponto durante a análise. o tempo de execução do algoritmo.	.016 .084 -.746	.059 .677 4.11 1.448		
Fator 4: Escrita e Rastreamento de Pseudocódigo ($\bar{y} = 0,871$)					
1.	Escreva um pseudocódigo para calcular a média de três números: -0,117 e -0,055. 2. Escreva um pseudocódigo para resolver um problema simples que você já conhece. para mim.	0,041 0,984	0,801 5,77 1,432		
3.	Escreva uma descrição em pseudocódigo para resolver um problema razoavelmente complexo. Isso me é apenas vagamente familiar.	.198 .023 .014 .665	.637 4.38 1.410		
16.	Escreva uma descrição em pseudocódigo para a ordenação de n números.	.143 .100 -.045 .549	.505 4.99 1.541		
21.	Escreva uma descrição em pseudocódigo para a busca binária em um vetor ordenado de n elementos. números.	.077 .236 -.156 .364	.415 4.06 1.788		
10.	Mentalmente, descreva a execução de um algoritmo iterativo que me foi dado. 0,261 0,026 -0,276 0,307	0,501 5,14 1,418			

Tabela 1: Coeficientes de padrão fatorial, estimativas de comunalidade, médias e desvios padrão para a autoeficácia dos algoritmos
itens (npré-curso = 362). Para cada item, o coeficiente do padrão fatorial mais alto acima de 0,300 é mostrado em negrito. Para cada um dos
Os fatores resultantes e as estimativas de confiabilidade alfa são apresentados entre parênteses. As médias sublinhadas exibem o valor mais alto em cada categoria.
O fator que representa o item de maior confiança dentro deste fator. A média mais baixa é exibida em itálico.

	Média DP	Fator 1	Fator 2	Fator 3	Fator 4	
Projeto de Algoritmos	4,758 1,114		1.000			
Paradigmas Avançados	3,585 1,420 0,559**			1.000		
Análise de Tempo de Execução	4,470 1,366 0,593**	Escrita e Rastreamento	0,468***	1.000		
de Pseudocódigo	5,004 1,160 0,688**		0,475***	0,529***	1.000	

Tabela 2: Coeficientes de correlação de classificação de Spearman para a análise fatorial exploratória dos dados pré-curso (npré-curso = 362;
**: correlação significativa em $p < 0,01$).

superior a 0,3. No entanto, como a próxima carga fatorial mais alta estava bem abaixo de 0,3, decidimos não omitir este item e sua atribuição ao fator. Para o Item 5 "Compreender uma estratégia complexa de dividir para conquistar" algoritmo", ambos o carregamento primário (0,362; Fator "Avançado

Paradigmas") e a carga secundária (0,302; Fator "Algoritmo Os valores de "Design" foram superiores a 0,3. No entanto, o carregamento secundário foi apenas marginalmente superior a esse valor limite, o principal A carga foi aproximadamente 20% maior que a carga secundária. Como, em

Grupo n		Todos os itens					Excluindo itens de programação dinâmica				
		antes	μpost	dm	t	p	μpre	μpost	dμ	t	p
TODOS 107	4,56 5,37	(1,00) (0,95)		0,81 9,714	< 0,0005		4,81	5,55	0,74 8,977	< 0,0005	
		(0,86)					(1,02) (0,92) (0,85)				
NÓS	28	4,70	5,97	1,27	7,642	< 0,0005	5,08	5,95	0,87 4,936	< 0,0005	
		(0,98) (0,76) (0,87)					(1,05) (0,78) (0,93)				
Europa 79		4,50	5,15	0,65 7,180	< 0,0005		4,71	5,41	0,69 7,486	< 0,0005	
		(1,01) (0,91) (0,81)					(1,00) (0,93) (0,82)				

Tabela 3: Resultados da realização de um teste t pareado nas diferenças (n = nmatched = 107) entre as pontuações pré e pós-curso (média). (em todos os itens). São apresentadas a média e o desvio padrão (entre parênteses). Os resultados são apresentados para as pontuações derivadas de Todos os itens e as pontuações derivadas sem os itens referentes à Programação Dinâmica.

Além disso, a inspeção dos itens em cada grupo confirmou que

O Item 5 correspondeu ao Item 17, que apresentou uma carga fatorial claramente maior no fator "Paradigmas Avançados" do que no fator "Algoritmo".

Considerando o fator "Design", decidimos também manter o Item 5 no instrumento. e atribuí-lo ao fator "Paradigmas Avançados".

A confiabilidade das pontuações, medida pelo Alfa de Cronbach, foi de 0,938, com a confiabilidade dos quatro fatores variando entre 0,871 e 0,929. Isso é ligeiramente inferior à confiabilidade das pontuações de Rama-lingam e Wiedenbeck, mas ainda suficientemente alto para atender aos critérios. padrões clínicos [5]. A escala apresentou alta validade de reteste em o npós-curso = 130 respostas pós-curso: a confiabilidade de todos A pontuação foi de 0,950, com a confiabilidade dos quatro fatores variando. entre 0,868 e 0,931.

Para possivelmente explicar as diferenças entre as instituições, nós tentou-se extrair fatores separadamente com base nos dados dos EUA e da Europa. No entanto, a qualidade dos dados para npost-course,US = 32 A taxa de resposta dos EUA foi muito baixa (medida KMO: 0,684) para gerar resultados confiáveis. Portanto, utilizamos os fatores acima, derivados de todas as respostas pré-curso. A Tabela 2 apresenta as estatísticas descritivas dos fatores derivados empiricamente e suas correlações.

Naturalmente, os fatores acima também poderiam ser usados com diferentes abordagens. pesos que refletem sua importância relativa para um determinado resultado.

6 ANÁLISES

Discutimos os resultados da aplicação da escala e os fatores obtidos. por meio de nossa análise fatorial exploratória. Para avaliar a validade de construto de Com nosso instrumento, relacionamos nossas descobertas à teoria da autoeficácia.

Pré/Pós-Curso. De acordo com a teoria geral da autoeficácia e Estudos anteriores sobre autoeficácia indicam que um aumento na autoeficácia deve ser observado. esperado ao longo de um semestre. Para verificar isso, analisamos a mudança no geral, ou seja, a média de todos os 21 itens, antes do curso e as notas após o curso.

Segundo Fay e Proschan, deve-se usar um teste t "sempre que a diferença entre as médias for desejada para a interpretação dos resultados". dados" [16, p. 19]. A análise dos dados revelou dois outliers que eram a mais de 1,5 comprimentos de caixa da borda da caixa em um boxplot. O primeiro desses valores correspondeu a um aumento de 1,5 (pré- curso) para 5,85 (pós- curso). Uma análise mais detalhada revelou que isso O aluno indicou baixa confiança ("1") em todos os itens contendo

Termos técnicos específicos para o projeto e análise de algoritmos. Parece que esse aluno respondeu à deixa "Se um específico

O termo ou tarefa é totalmente desconhecido para você, por exemplo, porque nunca foi... discutido em aula, mas, por favor, marque 1" (essa dica também foi usada) por Ramalingam e Wiedenbeck [36, p. 372]), portanto, o valor era mantido na análise. O segundo desses valores correspondeu a um diminuição de 5,0 (pré-curso) para 1,16 (pós-curso). Mesmo que Esse valor era extremo; não podíamos descartar esse ponto de dados como algo irrelevante. das entradas eram maiores que 1, indicando que o aluno não havia

simplesmente recebeu uma resposta padrão, sem reflexão. Para avaliar a influência do segundo desses valores discrepantes, realizamos o seguinte: um teste t com e sem esse ponto de dados incluído. Em ambos os casos, A normalidade foi confirmada por meio de inspeção visual de um QQ normal. plot.5 Incluindo o segundo valor discrepante, as pontuações aumentaram em 0,812 (IC 95%, 0,646 a 0,978) do período pré-curso para o período pós-curso, o aumento foi estatisticamente significativo, t(106) = 9,714, p < 0,0005. Excluindo No segundo caso atípico, as pontuações aumentaram em 0,846 (IC 95%, 0,692 a 0,999) do pré-curso para o pós-curso, o aumento foi estatisticamente significativo significativo, t(105) = 10,952, p < 0,0005. Concluímos que manter O valor discrepante extremo não afetou o tipo ou a significância do alterou e manteve isso também.

Em seguida, investigamos separadamente as estatísticas descritivas e a mudança nas pontuações para as três instituições americanas6 e a europeia instituição. Para as três instituições americanas, não houve valores discrepantes em os dados, conforme avaliado pela inspeção de um diagrama de caixa para valores maiores do que 1,5 vezes o comprimento da caixa a partir da borda da caixa. As diferenças em As pontuações apresentaram distribuição normal, conforme avaliado por inspeção visual. de um gráfico QQ normal e o teste de Shapiro-Wilk (n = 28, p = 0,926). As pontuações aumentaram em 1,26 (IC 95%, 0,927 a 1,607) do pré-curso para o pós-curso, sendo esse aumento estatisticamente significativo.

t(27) = 7,642, p < 0,0005. Para a instituição europeia, o teste de Shapiro-Wilk não confirmou a hipótese diagnóstica. normalidade devido à presença do valor discrepante extremo discutido acima (n = 79, p = 0,004). Seguindo a linha de raciocínio acima, no entanto, Confirmamos a normalidade por meio de inspeção visual de um QQ normal. plotou e manteve o ponto de dados.7 As pontuações aumentaram em 0,651 (95%)

5O segundo valor discrepante, no entanto, fez com que o teste de Shapiro-Wilk falhasse (n = 107, p < 0,001); A exclusão desse ponto de dados teria resultado na confirmação pelo teste de Shapiro-Wilk. normalidade também (n = 106, p = 0,165). 6Devido ao pequeno tamanho das amostras em cada instituição e à seleção prévia dos cursos. Para garantir a comparabilidade (ver Seção 3), não realizamos análises separadas para cada um. instituição. 7A exclusão do ponto de dados extremo teria resultado na aprovação do teste de Shapiro-Wilk. também (n = 78, p = 0,244).

Grupo n		Autoeficácia pré-curso				Autoeficácia pós-curso			
		Pseudocódigo de	tempo de execução	avançado do algoritmo	Pseudocódigo de	tempo de execução	avançado do algoritmo		
		Projeto	Análise de paradigmas	Escrever/Rastrear	Análise de paradigmas	de design	Escrever/Rastrear		
Mulher americana	8	4,85	2,73	5,53	5,60	5,77	6,15	6,03	6,27
		(1,61)	(1,56)	(1,07)	(0,77)	(1,00)	(0,99)	(0,94)	(0,62)
Homem americano	20	4,85	3,14	4,90	5,75	5,82	5,89	5,55	6,36
		(1,22)	(1,21)	(1,81)	(0,72)	(0,84)	(0,70)	(1,19)	(0,73)
NÓS	28	4,85	3,02	5,08	5,71	5,80	5,96	5,68	6,33
		(1,31)	(1,31)	(1,64)	(0,72)	(0,87)	(1,13)	(0,69)	(0,76)
Europa 79		4,84	3,63	4,32	5,01	5,30	4,81	5,13	5,75
		(1,04)	(1,45)	(1,33)	(1,11)	(1,05)	(1,20)	(1,27)	(0,94)
TODOS OS 107		4,85 5,19	(1,12) (1,06)	4,53		5,43	4,72	5,28	5,91
			(1,44)	(1,45)		(1,03)	(1,32)	(1,25)	(0,91)

Tabela 4: Estatísticas descritivas para vários grupos demográficos. Para cada fator, são apresentadas a média e o desvio padrão (entre parênteses). O curso europeu não abordou Programação Dinâmica; portanto, as pontuações pós-curso para o nível “Avançado” O fator de autoeficácia dos paradigmas é consideravelmente menor.

IC, 0,470 a 0,831) do pré-curso para o pós-curso, o aumento foi estatisticamente significativo, $t(78) = 7,180$, $p < 0,0005$. Os valores t apresentados indicam que o aumento nas pontuações foi maior. para as instituições americanas do que para as instituições europeias. No entanto, É importante observar que o currículo do curso europeu não continha programação dinâmica, pois esse tópico foi tratado em um curso avançado de algoritmos. Em vez disso, o curso abordou vários tópicos de estruturas de dados não incluídos nos currículos dos EUA cursos. Filtrando os três itens relacionados à programação dinâmica , a análise mostrou que as mudanças foram muito mais consistentes. Em todas as instituições: as pontuações dos cursos dos EUA aumentaram em 0,871. (IC 95%, 0,509 a 1,23; $t(27) = 4,936$, $p < 0,0005$) e as pontuações para a instituição europeia aumentou em 0,694 (IC 95%, 0,510 a 0,879; $t(78) = 7,486$, $p < 0,0005$). Assim, a influência dos dois subgrupos (EUA vs. Europa) não afetou o resultado geral nem sua significância : a Tabela 3 mostra que um aumento estatisticamente significativo poderia ser constatado tanto para a população em geral quanto para grupos individuais.

Ganho de autoeficácia para grupos de quartis. Dado que apenas alguns, ou nenhum, Os alunos foram expostos aos tópicos abordados em algoritmos. curso anterior, pode-se presumir que uma baixa autoeficácia inicial não é atribuído a experiências adversas anteriores. De acordo com Ramalingam. Assim, com base em Wiedenbeck, conjecturamos que o maior ganho em autoeficácia seria observado naqueles com baixa autoeficácia inicial. Para investigar essa hipótese, realizamos uma ANOVA de uma via. ($\bar{y} = 0,05$) para determinar se a diferença entre o pré-curso e As pontuações pós-curso foram diferentes para os grupos determinados pelo Quartis das pontuações pré-curso. O grupo correspondente ao mais baixo O quartil continha 27 participantes, os outros grupos, em ordem crescente. A ordem dos quartis continha 31, 23 e 26 participantes, respectivamente. Conforme discutido acima, o conjunto de dados continha dois outliers, um dos quais Isso pode ser atribuído a uma aparente negligência por excesso de cautela. e marcando “nada confiante” para cada item do questionário pré-curso, resultando, portanto, em um aumento extremamente grande. em autoeficácia. O outro participante apresentou uma queda extrema em autoeficácia, que até agora não conseguimos explicar. Assim, a Os dados de ambos os participantes foram mantidos. Homogeneidade da variância,

conforme avaliado pelo teste de Levene para igualdade de variâncias ($p = 0,076$), Foi observado. Os dados são apresentados como média $\pm$ desvio padrão. O aumento na autoeficácia foi estatisticamente significativo entre os quatro grupos ($F(3, 103) = 9,974$, $p < 0,001$, p parcial). $2^{\circ} = 0,363$). As diferenças aumentaram em relação à primeira ($1,46 \pm 0,85$), para o segundo ($0,76 \pm 0,98$), para o terceiro ($0,67 \pm 0,52$), para o quarto ($0,32 \pm 0,58$) grupos, nessa ordem. A análise post hoc de Tukey revelou que o aumento do primeiro para o segundo ($\bar{y}0,69$, IC 95% ($\bar{y}1,22$ a $\bar{y}0,16$), $p = 0,005$), do primeiro ao terceiro ($\bar{y}0,77$, IC 95% ($\bar{y}1,35$ a $\bar{y}0,21$), $p = 0,002$) e do primeiro ao quarto grupo ($\bar{y}1,13$, IC 95% ($\bar{y}1,69$ a $\bar{y}0,57$), $p < 0,001$) foi estatisticamente significativo.

Gênero. Em resposta à literatura sobre diferenças de gênero em relação à autoavaliação em computação [3, 8, 11], demos continuidade a esta pesquisa. uma ANOVA de uma via ($\bar{y} = 0,05$) para ambas as pontuações gerais (média para todos os itens), bem como para cada um dos fatores. Como só tínhamos O acesso às informações de gênero de $n_{gender} = 28$ participantes dos EUA , a população estudada, foi relativamente pequena. Normalidade para o A mudança nas pontuações foi avaliada usando o teste de Shapiro-Wilk. cada grupo ($p > 0,05$). Houve homogeneidade de variâncias, como avaliado pelo teste de Levene para igualdade de variâncias ($p = 0,340$). No entanto , não foram encontradas diferenças estatisticamente significativas entre os grupos de $n_{female,US} = 8$ participantes do sexo feminino e os grupos de $n_{male,US} = 20$ Foi possível detectar participantes do sexo masculino ($F(1, 26) = 0,130$, $p = 0,721$); O mesmo se aplica ao nível dos fatores. Isso é consistente com as conclusões de Ramalingam e Wiedenbeck, que não conseguiram encontrar um diferença estatisticamente significativa entre (grupos muito maiores de) Estudantes do sexo feminino e masculino em relação à autoeficácia em programação de computadores. A hipótese deles é que “as mulheres que ingressam na área de ciência da computação são membros de um grupo autoselecionado que tende a ter alto desempenho em matemática”. [...] experiência” [36, p. 379] é apoiada por Beyer [3] que relatou Pontuações (ligeiramente) mais altas no ACT de Matemática, tanto para alunos da área quanto para alunos de outras áreas. alunas em cursos introdutórios de programação.

Pré/Pós-prova. Em cada um dos cursos americanos considerados neste estudo. Para estudar, os alunos tiveram que fazer uma prova de meio de semestre. Como a prova de meio de semestre O exame foi o primeiro feedback formal importante, colocando a autoeficácia em prática.

	Média DP	Autoeficácia	Competência Percebida	Interesse/Prazer	Pressão/Tensão	
Autoeficácia	5,761	0,853	1.000			
Competência Percebida	4,147	1,479	Interesse/0,629***	1.000		
Prazer Pressão/Tensão	4,326	1,132	0,527***	0,662***	1.000	
	4,116	1,601	-0,335y	-0,604***	-0,280	1.000

Tabela 5: Coeficiente de correlação de classificação de Spearman para autoeficácia pós-intervalo e fatores do Inventário de Motivação Intrínseca (nintervalo = 46; y : correlação significativa em p < 0,05; y y : correlação significativa em p < 0,01).

No contexto do desempenho real, aplicamos nosso instrumento.

imediatamente antes e depois da prova de meio de semestre.

As alterações relatadas pelo nosso instrumento não puderam ser demonstradas para ser estatisticamente significativo: 12 dos nmidterm,matched = 23 alunos Para aqueles para os quais tínhamos dados completos, observou-se um aumento na autoeficácia. enquanto 11 participantes apresentaram uma diminuição. À luz da autoeficácia Em teoria, isso não é surpreendente, visto que, ao tomar esses primeiros algoritmos... O exame pode reforçar a autoeficácia existente ou demonstrar o desempenho. realizações, ou dar feedback negativo e desmotivador. De acordo com a teoria da autoeficácia, o ganho em autoeficácia a partir deste primeiro

O ponto de calibração até o final do curso foi estatisticamente significativo novamente, conforme avaliado pelo teste de Wilcoxon com postos sinalizados8 (n = 23, nincr = 16, ndecr = 5, ntie = 2, z = 2,714, p = 0,007, r = 0,40). Isto pode estar relacionado tanto com as conquistas de desempenho posteriores quanto com o curso e experiências vicárias como "ver outros realizando atividades ameaçadoras sem condições adversas [...] pode convencer observadores que eles podem] alcançar pelo menos alguma melhoria" [2, p. 197]. Conjecturamos que o pequeno número de alunos por turma nas escolas participantes As instituições americanas privilegiavam a observação atenta das experiências vicárias.

Relacionamos essas observações às descobertas de Lishinski et al. [26]. Em sua pesquisa sobre autoeficácia geral em um curso introdutório Durante o curso de programação, eles observaram a influência do desempenho. feedback sobre o desenvolvimento da autoeficácia. Como eles usaram um geral

Escala de autoeficácia extraída do programa Motivated Strategies for Learning (Estratégias Motivadas para Aprendizagem).

Questionário, essa similaridade nas observações apoia a convergência validade de construto. Lishinski et al. também descobriram que as estudantes do sexo feminino exibem padrões de desenvolvimento diferentes dos estudantes do sexo masculino: as estudantes do sexo feminino ajustaram sua autoeficácia antes da prova intermediária. exames, enquanto os alunos do sexo masculino começaram a ajustar sua autoeficácia após este ponto. Em nossas análises usando ANOVA de uma via, no entanto, nós Não foi possível detectar diferenças estatisticamente significativas entre os sexos. e alunas pelas mudanças nas pontuações do pré-curso para

pré-prova intermediária (F (1, 21) = 0,21, p = 0,887) e pós-prova intermediária para pós-curso (F (1, 21) = 0,75, p = 0,786). Nossa hipótese é que essas divergências observações a serem relacionadas à natureza diferente da introdução curso de programação estudado por Lishinski et al. e os cursos introdutórios de algoritmos estudados por nós: alunas foram relataram ter menos confiança em sua capacidade computacional do que estudantes do sexo masculino [3], também é conhecido que cursos com foco em programação e suas tarefas induzem uma carga emocional [23]. Combinando esses dois fatores com o fato de que a prova intermediária foi a primeira O feedback que pode influenciar positivamente a autoeficácia pode explicar as observações de Lishinski et al. Ao mesmo tempo, esses fatores e a autoseleção também relatada por Beyer et al. [3] é adequada para

8Devido ao pequeno número de indivíduos para os quais havia dados disponíveis, decidimos não... Utilize um teste t.

Explique por que nenhuma diferença baseada no gênero pôde ser observada em nosso estudo de cursos de algoritmos muito mais voltados para a matemática.

Para avaliar os aspectos motivacionais que podem influenciar a autoeficácia após o período de avaliação intermediária, aplicamos um questionário de 12 itens. juntamente com o questionário pós-intervalo. As subescalas neste Os dados do instrumento foram retirados do Inventário de Motivação Intrínseca — veja, Por exemplo, [10]—e referiu-se a "Interesse/Prazer", "Competência Percebida " e "Pressão/Tensão". Essas pontuações foram verificadas para correlações com os escores de autoeficácia pós-intervalo, conforme medido pelo nosso instrumento. Nem todas as variáveis apresentaram distribuição normal. (Teste de Shapiro-Wilk, p < 0,05), portanto, correlações de Spearman. foram calculadas. Análises preliminares mostraram que todas as relações eram monotônico, conforme avaliado pelo diagrama de dispersão.

A Tabela 5 mostra que tanto a pontuação de "Interesse/Prazer" quanto a de "Competência Percebida" correlacionam-se positivamente com a autoeficácia pós-intervalo (nmidterm = 46). Por outro lado, a pontuação de "Pressão/Tensão" correlaciona-se negativamente com a autoeficácia pós-intervalo. Isso está de acordo com a teoria de Bandura sobre as correlações entre desempenho, realização e autoeficácia, por um lado, e excitação emocional e autoeficácia por outro lado [2, p. 195ff.].

Além disso, comparamos esses escores motivacionais com as notas de meio de semestre autodeclaradas, obtidas como parte da avaliação pós-curso . O envio dessas notas era opcional; portanto, nem todos os alunos o fizeram.

optou-se por fazê-lo (nreported-grades = 28). Como já observado por Wilson e Shrock [41] não encontraram correlação estatisticamente significativa entre as notas e a autoeficácia (conforme relatado imediatamente após a realização da atividade). concluíram o exame) puderam ser observadas (classificação de Spearman, rs (28) = y0,203, p = 0,300). Executando uma correlação de Spearman. A correlação entre "Pressão/Tensão" e as notas auto-relatadas, no entanto, mostrou uma correlação bastante forte (rs (28) = 0,545, p = 0,003).

Como as notas foram codificadas de forma invertida, ou seja, A = 1, B = 2 e C = 3, Isso demonstra que alta pressão/tensão está correlacionada com baixa qualidade. Isso é de particular interesse, visto que todas as provas de meio de semestre foram para serem feitas em casa. exames, ou seja, pode-se presumir que a pressão do tempo desempenhou um papel muito importante. papel mais fraco do que para exames em sala de aula.

7. VALIDADE DE CONSTRUTO

A validação de um instrumento geralmente requer múltiplas iterações. durante o qual o instrumento pode ser aprimorado. No contexto disso Neste artigo, relatamos apenas as etapas preliminares para avaliar o construto. validade. Na seção anterior, discutimos como as mudanças em pontuações pré e pós-intervenção relacionadas à teoria geral da autoeficácia. Para investigar mais a fundo a validade do construto, seguimos Peter [33] que distingue quatro aspectos da validade de construto: confiabilidade, validade convergente, validade divergente e validade nomológica.

A confiabilidade, ou seja, o grau de correlação do instrumento com a própria avaliação foi feita por meio da confiabilidade alfa dentro dos fatores. (entre 0,871 e 0,929, ver Tabela 1) e as correlações estatisticamente significativas entre os fatores (ver Tabela 2). Ambas as medidas demonstraram que as condições de confiabilidade necessárias precisavam ser atendidas.

Como o instrumento proposto é, segundo o melhor conhecimento dos autores, o primeiro instrumento direcionado à avaliação da autoeficácia. no domínio dos algoritmos introdutórios, um método multicaracterístico-multimétodo matriz [6], o método padrão para avaliar convergentes e divergentes A validade não pôde ser calculada. Em vez disso, tentamos estabelecer a validade nomológica e discriminante relacionando as pontuações obtidas. e outras pontuações psicométricas obtidas juntamente com o questionário pré-curso dos algoritmos. Como em nenhum caso todas as variáveis foram todas as correlações apresentaram distribuição normal (teste de Shapiro-Wilk, $p < 0,05$). foram calculadas como correlações de classificação de Spearman.

Autoeficácia em Programação de Computadores. Essa pontuação foi determinada pela aplicação do instrumento desenvolvido por Ramalingam. e Wiedenbeck [36]. Este instrumento foi administrado em todos cursos em conjunto com nosso instrumento durante os testes pré-curso. Quando necessário, reformulamos os itens em termos de programação. linguagem usada no curso de programação anterior. Encontramos um forte correlação positiva entre autoeficácia em programação e algoritmos autoeficácia, ($rs(99) = 0,772$, $p < 0,001$). Inicialmente, isso pode parecer indicar que os dois instrumentos medem a mesma coisa construir mais do que as expectativas nomológicas indicariam e, Portanto, nosso instrumento não é específico o suficiente para o curso. No entanto, pesquisas anteriores mostraram uma correlação entre o desempenho em cursos introdutórios de programação e de algoritmos [9] indicando que a autoeficácia nessas áreas também pode estar correlacionada.

Além disso, foi encontrada divergência durante a análise fatorial. No artigo original, Ramalingam e Wiedenbeck haviam trabalhado com itens que pedem confiança para "concluir um projeto de programação" Considerando vários graus de apoio. Esses itens foram considerados constituem um fator denominado "Independência e Persistência". No projeto do nosso instrumento, reformulamos esses itens, tanto o "como" quanto o "como" "criar um algoritmo" no contexto (Itens 6–8) e "analisar o funcionamento" contexto de tempo (Itens 11–13). Nossa análise fatorial exploratória (usando a mesma metodologia de Ramalingam e Wiedenbeck) claramente separou essas duas instâncias do fator "Independência e Persistência" de Ramalingam e Wiedenbeck. Em vez disso, a análise agruparam-nos com outros itens diferentes, indicando que pelo menos Nos níveis de subescala, os instrumentos não mediam de forma idêntica. construções. Deixamos para trabalhos futuros se as especificidades do domínio ofuscar a interpretação de Ramalingam e Wiedenbeck ou se a interpretação que fizeram desse fator deve ser revista.

Autorregulação. Como mencionado na introdução, nós não tínhamos incluímos itens de autorregulação em nosso instrumento. Em vez disso, esta pontuação foi determinado usando dez itens validados de Black e Deci. escala [4]. Seis desses itens referiam-se à "Regulação Autônoma", Os quatro itens restantes referiam-se (externamente) à "Regulação Controlada". Comparamos essas pontuações com as pontuações do fator "Autorregulação", conforme determinado por Ramalingam e Wiedenbeck. instrumento (ver acima). Embora correlações positivas pudessem ser encontradas Entre esse fator e a regulação autônoma e controlada, bem como a soma de ambos, nenhuma dessas diferenças foi estatisticamente significativa. significativo. Novamente, isso sugere uma discriminação do nosso instrumento.

contra o instrumento proposto por Ramalingam e Wiedenbeck.

Além disso, a falta de convergência entre os instrumentos de Black e Deci.

e o fator "autorregulação" de Ramalingam e Wiedenbeck

Isso levanta questões interessantes de revalidação para trabalhos futuros.

Traços de personalidade. De acordo com O'Connor e Paunonen [29], Os traços de personalidade "Conscienciosidade" e "Abertura à Experiência" estão positivamente associados ao sucesso acadêmico. Como a autoeficácia também tem sido associada ao sucesso acadêmico [30, 31], assim investigamos se a validade nomológica, ou seja, uma "relação entre medidas que supostamente avaliam construtos diferentes (mas conceitualmente relacionados)" [33, p. 137f.], poderia ser estabelecida. As pontuações dos traços de personalidade foram determinadas usando dezesseis itens de "Conscienciosidade" e oito itens de "Abertura à Experiência" de o inventário de personalidade NEO [27]. Encontramos correlações positivas entre "Conscienciosidade" e autoeficácia em programação ($rs(99) = 0,383$, $p < 0,001$) e autoeficácia dos algoritmos pós-curso ($rs(99) = 0,322$, $p = 0,001$); correlação com algoritmos pré-curso A autoeficácia foi mais fraca ($rs(99) = 0,200$, $p < 0,05$). "Abertura para A "experiência" apresentou correlação positiva com o pré-curso ($rs(99) = 0,272$, algoritmos pós-curso ($rs(99) = 0,300$, $p = 0,003$) autoeficácia; a correlação com a autoeficácia em programação foi mais fraca. ($rs(99) = 0,272$, $p = 0,012$). Esses resultados são consistentes com a interpretação de "Conscienciosidade" em termos de motivação e o papel mais fraco da "Abertura à Experiência", conforme discutido por O'Connor e Paunonen [29]; sugerindo assim validade nomológica.

Resumo. Resumindo as análises apresentadas nesta seção, Concluímos que a confiabilidade pôde ser confirmada estatisticamente e evidências que apoiam a validade nomológica (através de outra pontuação psicométrica) e a validade divergente (através da comparação com A autoeficácia em programação e a autorregulação geral podem ser relatadas. Devido à falta de instrumentos alternativos, a validade convergente não pôde ser examinada além da comparação com o nosso instrumento. com um instrumento para avaliar a autoeficácia em programação.

8 CONCLUSÕES

Desenvolvemos um instrumento direcionado à avaliação da autoeficácia em um curso introdutório de algoritmos. Um fator exploratório.

A análise revelou quatro fatores principais que interpretamos como "Projeto de Algoritmo", "Paradigmas Avançados", "Análise de Tempo de Execução" e "Escrita e Traçado de Pseudocódigo". Os resultados das análises estatísticas da primeira aplicação deste instrumento sugerem a construção validade em relação à teoria geral da autoeficácia. Suporte adicional para a validade do construto vem de correlações com teorias relacionadas. fatores psicológicos, como motivação e traços de personalidade.

Para fortalecer o argumento da validade e aumentar a confiança na tomada de decisões utilizando este instrumento em um contexto mais amplo. para populações estudantis, planejamos ampliar o contexto de aplicabilidade. e aplicar este instrumento em instituições com uma gama mais ampla de seletividade. Além disso, buscamos identificar tópicos e correspondentes. itens para os quais mudanças extremas ou nenhuma mudança podem ser observadas ao avaliar a autoeficácia; isso nos permitirá examinar A influência das metodologias de ensino na autoeficácia dos algoritmos.

Agradecimentos. Agradecemos aos instrutores participantes por Agradecemos a colaboração de B. Köpcke e J. Seep pela entrada de dados. Este trabalho foi parcialmente financiado pelo Ministério Federal Alemão. do Ministério da Educação e Pesquisa (bolsa 01PB14007A).

REFERÊNCIAS

- [1] AR Artino Jr. Autoeficácia acadêmica: da teoria educacional à prática instrucional. *Perspectivas em Educação Médica*, 1:76–85, 2012.
- [2] A. Bandura. Autoeficácia: em direção a uma teoria unificadora da mudança comportamental. *Psychological Review*, 84(2):191–215, 1977.
- [3] S. Beyer, K. Rynes, J. Perrault, K. Hay e S. Haller. Diferenças de gênero em estudantes de ciência da computação. Em S. Grissom, D. Knox, D. Joyce e W. Dann, editores, *Anais do 34º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação*, páginas 49–53. ACM Press, 2003.
- [4] AE Black e EL Deci. Os efeitos do apoio à autonomia dos instrutores e da motivação autônoma dos alunos na aprendizagem de química orgânica: uma perspectiva da teoria da autodeterminação. *Science Education*, 84(6):740–756, nov. 2000.
- [5] JM Bland e DG Altman. Notas estatísticas: alfa de Cronbach. *British Medical Journal*, 314:572, fev. 1997.
- [6] DT Campbell e DW Fiske. Validação convergente e discriminante pela matriz multitraço-multimétodo. *Psychological Bulletin*, 56(2):81–105, março de 1959.
- [7] AR Carberry, H.-S. Lee e MW Ohland. Medindo a autoeficácia do projeto de engenharia. *Journal of Engineering Education*, 99(1):71–79, jan. 2010.
- [8] JM Cohoon. Experiências de gênero em programas de pós-graduação em computação. Em I. Russell, SM Haller, JD Dougherty e SH Rodger, editores, *Anais do 38º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação*, páginas 546–550. ACM Press, 2007.
- [9] H. Danielsiek e J. Vahrenhold. Mantenha-se nessas estradas: fatores potenciais que indicam o desempenho dos alunos em um curso CS2. Em C. Alphonse, J. Tims, ME Caspersen e S. Edwards, editores, *Anais do 47º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação (SIGCSE 2016)*, páginas 12–17. ACM Press, 2016.
- [10] EL Deci, H. Eghari, BC Patrick e DR Leone. Facilitando a internalização: a perspectiva da teoria da autodeterminação. *Journal of Personality*, 62(1):119–142, Dezembro de 1994.
- [11] P. Denny, A. Luxton-Reilly, J. Hamer, DB Dahlstrom e HC Purchase. Desempenho auto-previsto e real em um curso introdutório de programação. Em R. Ayfer, J. Impagliazzo e C. Laxer, editores, *Anais da 15ª Conferência Anual SIGCSE sobre Inovação e Tecnologia no Ensino de Ciência da Computação, ITICSE 2010*, páginas 118–122, Nova York, 2010. ACM.
- [12] DM Dowling. O desenvolvimento de uma escala de confiança em matemática e sua aplicação no estudo da confiança em estudantes universitárias. Tese de doutorado, Universidade Estadual de Ohio, 1978.
- [13] PH Dunham. Confiança matemática e desempenho no pré-cálculo aprimorado por tecnologia : diferenças relacionadas ao gênero. Tese de doutorado, Universidade Estadual de Ohio, 1990.
- [14] CS Dweck. Autoteorias: seu papel na motivação, personalidade e desenvolvimento. Psychology Press, Filadélfia, PA, 1999.
- [15] Farrington CA, Roderick M, Allensworth E, Nagaoka J, Keyes TS, DW Johnson e NO Beechum. Ensinando adolescentes a se tornarem aprendizes. O papel de fatores não cognitivos na formação do desempenho escolar: uma revisão crítica da literatura. Consórcio da Universidade de Chicago para Pesquisa da Escola de Chicago, Chicago, 2012.
- [16] MP Fay e MA Proschan. Wilcoxon-Mann-Whitney ou teste t? sobre pressupostos para teste de hipóteses e múltiplas interpretações de regras de decisão. *Statistics Surveys*, 4:1–39, 2010.
- [17] J. Gal-Ezer e E. Zur. A eficiência dos algoritmos – concepções errôneas. *Computers & Education*, 42:215–226, 2004.
- [18] D. Ginat e Y. Blau. Múltiplos níveis de abstração na resolução algorítmica de problemas. Em ME Caspersen, S. Edwards, T. Barnes e DD Garcia, editores, *Anais do 48º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação (SIGCSE 2017)*, páginas 237–242. ACM Press, 2017.
- [19] P. Gray. Diminuição da resiliência estudantil: um problema sério para as universidades. *Psychology Today*, 2015. Postagem no blog (22 de setembro): <https://www.psychologytoday.com/blog/freedom-learn/201509/declining-student-resilience-serious-problem-colleges>.
- [20] G. Hackett e NE Betz. Expectativas de autoeficácia em matemática, desempenho em matemática e a consideração de cursos relacionados à matemática. Trabalho apresentado na Reunião Anual da Associação Americana de Pesquisa Educacional, março de 1982. 42 páginas.
- [21] M. Hertz. O que significam CS1 e CS2?: Investigando diferenças nos cursos iniciais. Em T. Cortina e E. Walker, editores, *Anais do 41º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação (SIGCSE 2010)*, páginas 199–203. ACM Press, 2010.
- [22] HF Kaiser e J. Rice. Little Jiffy, Mark IV. *Educacional e Psicológico Medição*, 34(1):111–117, setembro de 1974.
- [23] P. Kinnunen e B. Simon. Vivenciando tarefas de programação em CS1: o custo emocional. Em ME Caspersen, MJ Clancy e K. Sanders, editores, *Anais do 6º Workshop Internacional sobre Pesquisa em Educação Computacional (ICER 2010)*, páginas 77–86. ACM Press, 2010.
- [24] P. Kinnunen e B. Simon. Percepções de autoeficácia de alunos de Ciência da Computação em CS1: Resultados à luz da teoria sociocognitiva. Em ME Caspersen, A. Clear e K. Sanders, editores, *Anais do 7º Workshop Internacional sobre Pesquisa em Educação em Computação (ICER 2011)*, páginas 19–26. ACM Press, 2011.
- [25] RW Lent e SD Brown. Em direção a uma teoria sociocognitiva unificadora de interesse, escolha e desempenho acadêmico e de carreira. *Journal of Vocational Behavior*, 45(1):79–122, 1994.
- [26] A. Lishinski, A. Yadav, J. Good e R. Enbody. Aprendendo a programar: diferenças de gênero e efeitos interativos da motivação, objetivos e autoeficácia dos alunos no desempenho. Em J. Sheard, J. Tenenber, D. Chinn e B. Dorn, editores, *Anais da Conferência ACM de 2016 sobre Pesquisa Internacional em Educação em Computação (ICER 2016)*, páginas 221–220. ACM Press, 2016.
- [27] JL Maples, L. Guan, NT Carter e JD Miller. Um teste da representação do conjunto de itens de personalidade internacional do inventário de personalidade NEO revisado e desenvolvimento de uma medida de 120 itens baseada no IPIP do modelo de cinco fatores. *Avaliação Psicológica*, 26(4):1070–1084, Dez. 2014.
- [28] L. Murphy e L. Thomas. Perigos de uma mentalidade fixa: implicações da pesquisa sobre teorias do eu para o ensino de ciência da computação. Em J. Amillo, C. Laxer, EM Ruiz e A. Young, editores, *Anais da 13ª Conferência Anual SIGCSE sobre Inovação e Tecnologia no Ensino de Ciência da Computação, ITICSE 2008*, páginas 271–275, Nova York, 2008. ACM.
- [29] MC O'Connor e SV Paunonen. Cinco grandes preditores de personalidade do desempenho acadêmico pós-secundário. *Personalidade e Diferenças Individuais*, 43(5):971–990, 2007.
- [30] F. Pajares e MD Miller. Papel da autoeficácia e das crenças do autoconceito na resolução de problemas matemáticos: uma análise de caminho. *Journal of Educational Psychology*, 86(2):193–203, 1994.
- [31] F. Pajares e DH Schunk. Crenças sobre si mesmo e sucesso escolar: Autoeficácia, autoconceito e desempenho escolar. Em R. Riding e S. Rayner, editores, *Percepção*, páginas 239–266. Ablex Publishing, Londres, 2001.
- [32] J. Perrenet e E. Kaasenbrood. Níveis de abstração na compreensão do conceito de algoritmo pelos alunos : a perspectiva qualitativa. Em R. Davoli, M. Goldweber e P. Salomoni, editores, *Anais da 11ª Conferência Anual SIGCSE sobre Inovação e Tecnologia no Ensino de Ciência da Computação, ITICSE 2006*, páginas 270–274, Nova York, 2006. ACM.
- [33] JP Peter. Validade de construto: uma revisão de questões básicas e práticas de marketing. *Revista de Pesquisa de Marketing*, 18(2):133–145, maio de 1981.
- [34] A. Quade. Desenvolvimento e validação de uma escala de autoeficácia em ciência da computação para cursos CS0 e a análise de grupo da autoeficácia do aluno CS0. Em *Anais da Conferência Internacional sobre Tecnologia da Informação: Computadores e Comunicações (ITCCI03)*, páginas 60–64. IEEE Computer Society, 2003.
- [35] V. Ramalingam, D. LaBelle e S. Wiedenbeck. Autoeficácia e modelos mentais na aprendizagem de programação. Em RD Boyle, M. Clark e A. Kumar, editores, *Anais da 9ª Conferência Anual SIGCSE sobre Inovação e Tecnologia na Educação em Ciência da Computação, ITICSE 2004*, páginas 171–175, Nova York, 2004. ACM.
- [36] V. Ramalingam e S. Wiedenbeck. Desenvolvimento e validação de pontuações em uma escala de autoeficácia em programação de computadores e análises de grupos de autoeficácia de programadores novatos. *Journal of Educational Computing Research*, 19(4):367–381, dez. 1998.
- [37] TM Rawson, DP Hoyt e DJ Teeter. Identificando instituições “comparáveis”. *Pesquisa em Ensino Superior*, 18(3):299–310, 1983.
- [38] B. Simon, B. Hanks, L. Murphy, S. Fitzgerald, R. McCauley, L. Thomas e C. Zander. Dizer não é necessariamente acreditar: influenciando autoteorias na computação. Em ME Caspersen, R. Lister e M. Clancy, editores, *Anais do Quarto Workshop Internacional de Pesquisa em Educação Computacional, ICER 2008*, páginas 173–184, Nova York, 2008. ACM.
- [39] J. Vahrenhold e W. Paul. Desenvolvimento e validação de itens de teste para cursos de ciência da computação do primeiro ano. *Educação em Ciência da Computação*, 24(4):304–333, dez. 2014.
- [40] R. Wilcon. Uma epidemia de angústia: sobrecarregadas pela demanda por cuidados de saúde mental, as faculdades enfrentam conflitos na escolha de como responder. *Higher Education Chronicle*, 21 de agosto de 2015, <http://chronicle.com/article/An-Epidemic-of-Anguish/232721>.
- [41] BC Wilson e S. Shrock. Contribuindo para o sucesso em um curso introdutório de ciência da computação: um estudo de doze fatores. Em HM Walker, RA McCauley, JL Gersting e I. Russell, editores, *Anais do 32º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação*, páginas 184–188. ACM Press, 2001.
- [42] D. Zingaro. A instrução por pares contribui para a autoeficácia em CS1. Em JD Dougherty, K. Nagel, A. Decker e K. Eiselt, editores, *Anais do 45º Simpósio Técnico SIGCSE sobre Educação em Ciência da Computação (SIGCSE 2014)*, páginas 373–378. ACM Press, 2014.