

Identificando equívocos comuns sobre SQL entre iniciantes: Resultados de um estudo de caso.

Estudo de pensamento em voz alta

Daphne Miedema
demiedema@tue.nl
Laboratório de Inteligência
Artificial e Engenharia de
Dados (AIDE) Eindhoven,
Holanda Universidade de Tecnologia
de Eindhoven Eindhoven, Holanda

Efthimia Aivaloglou
e.aivaloglou@liacs.leidenuniv.nl Instituto de
Ciência da Computação Avançada de
Leiden Leiden, Holanda
Open University Heerlen, Holanda

George Fletcher
ghlfletcher@tue.nl
Laboratório de Inteligência Artificial e
Engenharia de Dados (AIDE)
Eindhoven, Holanda Universidade
de Tecnologia de Eindhoven Eindhoven, Holanda

RESUMO

SQL é a linguagem de consulta de banco de dados mais comumente ensinada. Embora pesquisas anteriores tenham investigado os erros cometidos por iniciantes durante a formulação de consultas SQL, as causas subjacentes desses erros permaneceram inexploradas. Compreender as concepções errôneas básicas dos iniciantes que levam a esses erros ajudaria a melhorar a forma como ensinamos linguagens de consulta aos nossos alunos. Neste artigo, buscamos identificar as concepções errôneas que podem ser as causas dos erros de SQL documentados cometidos por iniciantes. Para tanto, conduzimos um estudo qualitativo de verbalização do pensamento para coletar informações sobre o processo de raciocínio de estudantes universitários ao resolver problemas de formulação de consultas. Com as consultas em mãos, analisamos as causas subjacentes dos erros cometidos pelos participantes. Neste artigo, apresentamos as concepções errôneas de SQL identificadas, organizadas em quatro categorias principais: concepções errôneas baseadas em conhecimento prévio do curso, concepções errôneas baseadas em generalização, concepções errôneas baseadas na linguagem e concepções errôneas devido a um modelo mental incompleto ou incorreto. Uma exploração aprofundada das concepções errôneas pode revelar lacunas no ensino. Ao chamar a atenção para esses aspectos, pretendemos aprimorar o ensino de SQL.

CONCEITOS CCS

• **Sistemas de informação** y **Linguagem de Consulta Estruturada (SQL)**; • **Tópicos sociais e profissionais** y **Educação em informática**.

PALAVRAS-CHAVE

SQL, iniciante, erro, equívoco

Formato de referência da ACM:

Daphne Miedema, Efthimia Aivaloglou e George Fletcher. 2021. Identificando concepções errôneas de SQL em iniciantes: resultados de um estudo de verbalização do pensamento. Em Anais da 17ª Conferência Internacional da ACM sobre Pesquisa em Educação Computacional (ICER 2021), 16 a 19 de agosto de 2021, Evento Virtual, EUA. ACM, Nova York, NY, EUA, 13 páginas. <https://doi.org/10.1145/3446871.3469759>



Esta obra está licenciada sob uma Licença Internacional Creative Commons Atribuição 4.0.

ICER 2021, 16 a 19 de agosto de 2021, Evento Virtual, EUA ©
2021 Direitos autorais reservados ao(s) proprietário(s)/autor(es).
ACM ISBN 978-1-4503-8326-4/21/08. <https://doi.org/10.1145/3446871.3469759>

1 INTRODUÇÃO

Bancos de dados e a Linguagem de Consulta Estruturada (SQL) são tópicos centrais nos currículos de Engenharia de Software e Ciência da Computação no ensino superior [33]. Embora a sintaxe do SQL seja relativamente simples em comparação com a maioria das linguagens de programação, o SQL não é uma linguagem trivial de aprender. Diversos trabalhos relataram erros comuns em consultas SQL escritas por estudantes e iniciantes, identificando várias categorias, como erros de sintaxe, erros lógicos, erros semânticos e complicações [3, 8, 21, 31, 32, 34]. Na área de pesquisa em torno do ensino de SQL, o foco principal tem sido nos erros cometidos, sem aprofundar as causas subjacentes ou as concepções errôneas que os iniciantes podem ter. A identificação de concepções errôneas é um primeiro passo importante para desenvolver abordagens instrucionais que abordem as dificuldades dos alunos. Na área de ensino de programação, por outro lado, as concepções errôneas têm sido bem estudadas. Mesmo que o SQL seja uma linguagem de consulta, e não uma linguagem de programação, paralelos entre as duas

Os primeiros trabalhos sobre concepções errôneas em programação as identificaram como falhas conceituais na forma como os iniciantes programam e compreendem os programas [20], dificuldades de aprendizagem de programação e erros baseados na aplicação incorreta de analogias [7]. Desde então, um grande número de trabalhos tem se concentrado em concepções errôneas sobre programação introdutória, especialmente sobre linguagens de programação imperativas e orientadas a objetos, identificando uma ampla gama de erros em sua compreensão conceitual [9, 24]. Uma das causas de dificuldades e concepções errôneas que tem sido amplamente relatada é a aplicação incorreta do conhecimento prévio dos alunos [12, 24]. Ao considerar o ensino de SQL, o conhecimento prévio relevante pode vir de diversos domínios. Matemática, teoria dos conjuntos e álgebra relacional são alguns pré-requisitos possíveis para a aprendizagem de SQL e, portanto, podem influenciar a aprendizagem do material. Além disso, o SQL utiliza palavras-chave da linguagem natural e, portanto, pode ser suscetível à transferência linguística [7, 9]. A exposição prévia a outras linguagens de programação também demonstrou causar concepções errôneas [25], por exemplo, devido às diferenças nas notações e em seu uso, e os aprendizes de SQL geralmente recebem instrução em programação como parte dos currículos que seguem. Esses diferentes tipos de conhecimento prévio podem ser causas potenciais de concepções errôneas que levam a erros de SQL, os quais foram documentados em trabalhos anteriores. As primeiras pesquisas sobre as causas de erros de SQL levantaram a hipótese de cinco causas subjacentes: sobrecarga da memória de trabalho, ausência de pistas de recuperação, fixação procedimental, conhecimento procedimental incorreto e percepção errônea [27]. Recentemente, erros nas consultas SQL enviadas por alunos foram mapeados para essas cinco causas por Taipalus [31], sem, no entanto, utilizá-las.

Neste artigo, nosso objetivo é compreender as dificuldades que os iniciantes enfrentam ao formular consultas SQL e as causas subjacentes de seus erros. A questão de pesquisa que buscamos responder é: Quais são as concepções errôneas dos iniciantes em SQL que causam dificuldades ou erros durante a formulação de consultas? Para tanto, realizamos um estudo de verbalização do pensamento, no qual pedimos a 21 alunos que resolvessem problemas de formulação de consultas. De forma semelhante a outros trabalhos que identificam concepções errôneas de alunos (por exemplo, [13, 28]), um estudo de verbalização do pensamento nos permite coletar informações qualitativas sobre o processo de raciocínio dos alunos. Utilizando as transcrições juntamente com as anotações dos alunos, identificamos as causas subjacentes de seus erros, que categorizamos em quatro categorias principais : concepções errôneas baseadas em conhecimento prévio do curso, concepções errôneas baseadas em generalização, concepções errôneas baseadas na linguagem e concepções errôneas devido a um modelo mental incompleto ou incorreto. Até onde sabemos, este é o primeiro estudo sobre as causas de erros em SQL baseado em informações qualitativas sobre o processo de raciocínio dos alunos .

2 TRABALHOS RELACIONADOS

A pesquisa sobre o ensino de SQL tem se concentrado principalmente nos erros cometidos por iniciantes, sem aprofundar as causas subjacentes. Alguns trabalhos anteriores exploraram as causas analisando a cognição humana e a análise de tarefas. Um deles é o de Smelcer, que desenvolveu um modelo para explicar erros conhecidos [27]. Infelizmente, a lista de erros apresentada por eles é muito curta e se concentra em erros básicos, como omissões e erros de ortografia. Eles listam cinco causas subjacentes: sobrecarga da memória de trabalho, ausência de pistas de recuperação, fixação procedimental, conhecimento procedimental incorreto e percepção errônea. De acordo com Smelcer, as percepções errôneas estão relacionadas à tarefa, como perceber 'lc' como 'k', e, portanto, levam a erros de ortografia. Isso não tem relação, em grande parte, com as percepções errôneas que discutimos neste artigo.

Trabalhos mais recentes expandiram os tipos básicos de erros além de omissões e erros ortográficos. Uma divisão típica é que os estudos se concentrem em erros de sintaxe [1], erros semânticos [3, 8] ou ambos [2, 21]. Em sua discussão sobre erros semânticos, Brass e Goldberg distinguem dois tipos de respostas [8]. Aquelas consultas para as quais precisamos conhecer a pergunta para verificar se estão corretas e aquelas em que a consulta está incorreta independentemente da pergunta (por exemplo, devido a uma cláusula WHERE conflitante que resulta em uma resposta vazia).

Taipalus e Siponen também usam essas duas classes: eles chamam a primeira categoria de erros lógicos e a segunda de erros semânticos [34]. Além disso, eles adicionam complicações à sua categorização. Complicações são aquelas adições desnecessárias que confundem a compreensão de uma consulta, mas produzem a tabela de resultados correta.

Para obter uma melhor compreensão de quais erros são mais significativos do que outros, Taipalus e Perälä consideram os erros persistentes nos trabalhos dos alunos. Eles definem erros persistentes como aqueles que estão presentes na resposta final do aluno [32]. Eles descobriram que os erros lógicos e as complicações tiveram a maior incidência, e que os erros de sintaxe e semântica ocorreram com menor frequência nas tentativas finais. Recapitulando, os erros lógicos são aqueles que só podemos avaliar como incorretos depois de conhecermos a pergunta que a consulta tenta responder. Isso significa que os alunos escreveram uma consulta que, em princípio, poderia estar correta, mas não corresponde à pergunta que lhes foi feita. Seria interessante levar em consideração a perspectiva dos alunos, para ver onde ocorre a discrepância.

A questão que se desenvolve é a que reside entre a formulação da pergunta e a formulação da consulta. É aqui que surgem os equívocos.

A pesquisa sobre concepções errôneas é uma das áreas essenciais para compreender quando se busca aprimorar a educação. Se quisermos ajudar nossos alunos a aprender a usar SQL com mais eficácia, precisamos conhecer a natureza dos equívocos que resultam em dificuldades ou na escrita de código errôneo. Infelizmente, até o momento, não há muitos trabalhos sobre concepções errôneas em SQL. Em um artigo que conhecemos, Taipalus [31] discute as causas que podem estar por trás dos erros persistentes explorados em [32]. Eles mapeiam os erros para quatro explicações cognitivas , conforme introduzidas por Smelcer [27]. Infelizmente, esse mapeamento é especulativo [31], pois eles usam apenas a consulta em texto simples, tal como submetida, sem discussão qualitativa com os alunos.

Por outro lado, existe um vasto trabalho qualitativo sobre concepções errôneas em programação. Embora SQL seja uma linguagem de consulta, e não uma linguagem de programação, podem ser traçados paralelos. Em nosso trabalho sobre concepções errôneas em consultas, nos baseamos na pesquisa sobre concepções errôneas em programação.

As concepções errôneas sobre programação introdutória foram categorizadas em dificuldades no conhecimento sintático, no conhecimento conceitual e no conhecimento estratégico, referindo-se ao conhecimento sobre planejamento, escrita e depuração de programas [24]. Para identificar concepções errôneas, os erros de programadores iniciantes foram previamente categorizados em erros de sintaxe, erros semânticos e erros de lógica [17]. Reconheceu -se precocemente que uma importante fonte de concepções errôneas são as propriedades que os alunos assumem da máquina que executa seu código [7] ou o superbug que Pea reconheceu como a suposição de que "existe uma mente oculta em algum lugar na linguagem de programação que possui poderes inteligentes e interpretativos" [20]. A pesquisa sobre concepções errôneas em programação tem se concentrado na compreensão de conceitos em linguagens imperativas e orientadas a objetos [15, 28] – uma extensa lista de concepções errôneas é apresentada em [29]. Além das linguagens comumente ensinadas em CS1, trabalhos recentes sobre concepções errôneas têm se concentrado em linguagens de programação visual usadas por alunos mais jovens [30], linguagens de programação funcional [11], bem como dificuldades com a compreensão de estruturas de dados [38].

Conceitos errôneos têm sido considerados como "extensões falhas de conhecimento prévio produtivo" que devem ser identificadas e refinadas, em vez de substituídas [12]. Em programação, o conhecimento prévio dos alunos , especialmente em linguagem natural e matemática, tem se mostrado transferido e causador de conceitos errôneos [9, 24]. A transferência linguística é especialmente relevante para o nosso trabalho sobre erros de SQL, uma vez que palavras-chave de programação emprestadas da língua inglesa podem ter significados ambíguos ou diferentes [7, 22], como a palavra "and", que é uma conjunção na linguagem natural, mas um operador booleano em programação . Foi constatado, por exemplo, que programadores iniciantes acreditavam que uma instrução "if" estava continuamente aguardando ativamente que a condição booleana fosse verdadeira, como é usado na linguagem natural [20]. Diversos trabalhos atribuíram conceitos errôneos à má aplicação do conhecimento prévio em matemática, especialmente em notação algébrica . Observou-se, por exemplo, que isso causa confusão em instruções de atribuição de variáveis [4] e afeta a compreensão de sequências de execução [28]. Também foi constatado que a exposição prévia a diferentes linguagens de programação causa concepções errôneas [25], por exemplo, devido às diferenças nas notações e seu uso para as definições de variáveis e operadores aritméticos.

Pergunta	Resumo das respostas
Em que linguagens de programação você sabe programar?	Java, C#, Python, JavaScript, C++, R 13/21
Você já teve contato com programação funcional ?	
Você já estudou Álgebra Relacional? 17/21 Você já estudou Teoria dos Conjuntos? 14/21 Você tem experiência profissional na indústria ? 5/21	
(toda experiência em programação) Experimente linguagens de programação ou de consulta?	
Como você avaliaria seu nível de proficiência em SQL? (1 - Extremamente iniciante, 10 - Completamente experiente)	Média: 5,35, desvio padrão: 1,7
Que interface você usa para escrever consultas SQL?	DataGrip, Jupyter, terminal, Microsoft Access, interface web, editor de texto com realce de sintaxe.

Tabela 1: Questões sobre o conhecimento prévio e a experiência dos participantes.

Com esse conhecimento sobre erros de SQL e exercícios de programação, pretendemos contribuir para o ensino de SQL, identificando as dificuldades e concepções errôneas dos alunos. Em contraste com o trabalho de Taipalus [31], realizamos um estudo qualitativo de verbalização do pensamento, no qual pedimos aos alunos que resolvessem problemas de formulação de consultas. Com base nos processos dos alunos, formulamos hipóteses sobre as causas subjacentes aos seus erros. Nas seções seguintes, detalhamos nosso estudo e resultados, e apresentamos uma primeira categorização de concepções errôneas sobre SQL.

3 MÉTODO

Para coletar informações sobre os erros cometidos por iniciantes em SQL e suas causas subjacentes, realizamos um estudo com usuários por meio de entrevistas semiestruturadas de verbalização do pensamento. Nessas entrevistas, apresentamos aos participantes problemas de formulação e avaliação de consultas com níveis crescentes de dificuldade.

O estudo foi realizado na Holanda, em duas universidades e uma escola secundária. As entrevistas foram conduzidas via Skype devido às medidas de confinamento. Os participantes escreveram suas anotações e respostas em papel, que mostraram em frente à webcam.

Após a entrevista, os participantes enviaram fotos de suas anotações e respostas ao pesquisador. As entrevistas foram programadas para durar aproximadamente 30 minutos. Não houve qualquer tipo de remuneração.

3.1 Materiais

Questionário Antes do início da entrevista, solicitamos aos participantes que preenchessem um questionário de forma assíncrona para nos fornecer informações sobre seus conhecimentos de SQL e assuntos relacionados. As perguntas podem ser encontradas na Tabela 1.

Perguntas da entrevista O conjunto de perguntas para a entrevista de verbalização do pensamento está disponível na Tabela 3, com o esquema do banco de dados representado na Tabela 2. Voltaremos a essas perguntas ao discutir nossos resultados. As perguntas foram elaboradas para abranger todos os conceitos básicos de SQL com os quais os iniciantes devem estar familiarizados, respeitando o tempo estipulado para o estudo. Na Tabela 3, também mencionamos os conceitos abordados. Estes são baseados nos sete tipos de consultas SQL definidos por Ahadi et al. [2].

A pergunta inicial foi escolhida com base na pontuação SQL autodeclarada. Para os participantes com pontuação igual ou inferior a 5, começamos pela pergunta 1. Todos os outros começaram pela pergunta 3. Constatamos que muitos participantes se autoavaliaram com pontuação muito baixa ou muito alta, o que significava que, por vezes, nos desviávamos desse procedimento, voltando ou pulando perguntas, para aproveitar ao máximo a entrevista.

Mesa	Atributos
nome	
cliente	cID, cName, rua, cidade
loja	sID, sName, rua, cidade
produto	pID, pName, sufixo
lista de compras	cID, pID, quantidade, data da compra
	tID, cID, sID, pID, data, quantidade, preço
inventário	sID, pID, data, quantidade, preço unitário

Tabela 2: O esquema de banco de dados usado para o As perguntas na Tabela 3. Os atributos sublinhados juntos formam a chave primária de cada tabela.

3.2 Participantes

Para o nosso grupo de participantes, procurávamos alunos que tivessem aprendido SQL recentemente. Para o recrutamento, contatamos instrutores de cursos de banco de dados que os autores conheciam. Instrutores interessados em:

Enviamos o convite para a entrevista aos nossos alunos, que puderam então se inscrever para um horário específico.

Contamos com 21 participantes, sendo 3 mulheres e 18 homens. Nenhum participante relatou ter alguma deficiência. Apenas dois participantes do nosso estudo eram falantes nativos de inglês; os demais tinham outras línguas maternas. Para tornar o estudo acessível a todos os participantes, as perguntas foram formuladas em inglês. Como a língua materna do entrevistador e da maioria dos participantes era a mesma, 15 das entrevistas foram realizadas nesse idioma.

Em relação ao nível de escolaridade, nossos participantes foram divididos em duas categorias. Um grupo (n=4) era composto por alunos do ensino médio que cursavam Informática como parte de seu currículo, haviam recebido aulas de SQL e acabado de ser avaliados por seu professor. O segundo grupo era formado por estudantes universitários de duas universidades diferentes (U1: n=4, U2: n=13) que haviam cursado uma disciplina de Bancos de Dados antes da entrevista, incluindo duas aulas sobre SQL. A maioria dos nossos participantes pode ser considerada iniciante em SQL.

A Tabela 1 resume o conhecimento prévio e a experiência relatados pelos participantes. Em relação à proficiência em SQL, eles se autoavaliaram com uma média de 5,35 (em uma escala de 1 a 10), com um desvio padrão de 1,7.

Todos os participantes sabiam programar em pelo menos uma linguagem de programação, sendo que a maioria conhecia duas ou mais linguagens.

3.3 Procedimento

Todas as entrevistas foram realizadas online via Skype pelo primeiro autor, que não fazia parte da equipe docente dos cursos de bancos de dados. Os participantes receberam o questionário e o termo de consentimento livre e esclarecido antes do início da entrevista e puderam nos enviar fotos ou digitalizações desses documentos. As entrevistas começaram com a apresentação dos conceitos que norteiam o estudo e do protocolo de verbalização do pensamento. Também verificamos se eles tinham caneta e papel à mão e revisamos rapidamente os principais pontos do termo de consentimento para que pudessem fazer perguntas. Em seguida, o entrevistador informou ao participante que a gravação seria iniciada e o estudo começou.

Tipo de pergunta	Pergunta	Abordado conceitos	Testado por
1. Execução:	Qual é o resultado da Consulta 1? Qual é o equivalente em linguagem natural?		11
2. Formulação:	Liste todos os IDs e nomes de clientes que moram em Eindhoven. Consulta simples: 12. 3.		21
	Formulação: Liste todos os pares de IDs de clientes que moram em uma rua com o mesmo nome, mas em uma cidade diferente.	Inscrição própria	
4. Formulação:	Liste todos os IDs de clientes, datas e quantidades de transações que contenham produtos denominados "Maças".	Junção natural	21
5 Avançado	Encontre os nomes de todos os itens do estoque que têm um preço unitário maior que o das bananas.	Subconsulta única	16
6 Avançado	Retorne uma lista com o número de lojas por cidade.	Agrupar por	7
7 Avançado	Retorne a tabela de lojas ordenada alfabeticamente por cidade. Ordenar por		5
8. Execução	Qual é o resultado da Consulta 2? Qual é o equivalente em linguagem natural?		6
9 Avançado	Uma cadeia de lojas consiste em pelo menos duas lojas com o mesmo nome, mas IDs diferentes. Encontre os nomes dos cadeias de lojas que, em média, vendem produtos em quantidades superiores a 4.	Alta complexidade	3

Tabela 3: Conjunto de perguntas disponíveis para a entrevista.

Apresentamos o esquema do banco de dados e alguns dados de exemplo (ver Figura 1) que serviram de base para os problemas de formulação de consultas, e demos aos participantes tempo para estudá-los e tirar dúvidas. Dependendo do nível de conhecimento em SQL que cada participante havia relatado, começamos com a questão 1 ou a questão 3 da Tabela 3. Os alunos foram instruídos a ler cada questão em voz alta e expressar seus pensamentos, para incentivar a discussão sobre o processo de resolução de problemas.

Durante a formulação da pergunta, e especialmente quando ocorriam erros, os participantes foram solicitados a detalhar o como e o porquê de sua abordagem, a fim de tentar descobrir as razões por trás dos erros. Às vezes, a pergunta era corrigida pelos alunos (que eram instruídos a deixar a resposta errônea visível), outras vezes eles cometiam novos erros e a discussão recomençava.

Em geral, o estudo foi encerrado após o tempo estipulado e na ausência de novos problemas, exceto nos casos em que os participantes sugeriram a prorrogação. Em seguida, os participantes foram questionados se tinham alguma dúvida ou comentário. A gravação foi interrompida e o entrevistador solicitou que o participante enviasse fotos de suas anotações e perguntas. Por fim, o entrevistador perguntou ao participante se ele desejava ser mantido informado sobre a pesquisa e agradeceu-lhe pela participação.

3.4 Processamento de dados

Para a análise de dados, utilizamos as anotações dos participantes sobre suas respostas intermediárias e finais às perguntas da entrevista na Tabela 3, bem como as transcrições das entrevistas.

O primeiro passo em nossa análise foi extrair todos os erros, tanto nas tentativas intermediárias quanto nas finais. Fizemos uma lista de todos os erros distintos que ocorreram e classificamos cada erro de acordo com a palavra-chave SQL à qual estavam associados. Esses erros foram então organizados de acordo com as categorias de erros SQL identificadas em trabalhos existentes [8, 34]. A categorização dos erros é apresentada na Seção 4.

```
SELECT c.cID, s.sID, c.city FROM
customer AS c, store AS s
```

```
ONDE c.rua = s.rua
E c.cidade = s.cidade
```

Consulta 1: Primeira pergunta sobre o rastreamento da execução.

```
SELECIONE AVG(preço), pName
A partir de produto AS p,
transação AS t
ONDE p.pID = t.pID
AGRUPAR POR pName
TENDO MÉDIA(preço) > 1
```

Consulta 2: Segunda pergunta sobre o rastreamento da execução.

Após a identificação dos erros, utilizamos as transcrições das entrevistas para explorar suas causas. Para cada erro identificado no resultado final ou intermediário da consulta, buscamos indícios de sua causa no processo de pensamento expresso pelo participante. As causas foram identificadas tanto no processo de pensamento que levou aos erros quanto em suas respostas às perguntas de esclarecimento do entrevistador. Adotamos uma abordagem orientada por dados, gerando rótulos apropriados de acordo com as concepções errôneas expressas [6]. Concluído esse processo, os três autores analisaram separadamente os rótulos, juntamente com citações representativas para cada um, e elaboraram, de forma independente, categorizações das concepções errôneas. Durante a categorização, levamos em consideração a interferência e a transferência de conhecimento prévio no desenvolvimento de novos conceitos.

Em seguida, os pesquisadores compararam e discutiram suas categorizações e concordaram com quatro categorias principais: concepções errôneas baseadas em conhecimento prévio do curso, concepções errôneas baseadas em generalização, concepções errôneas baseadas na linguagem e concepções errôneas devido a um modelo mental incompleto ou incorreto.

4. ERROS DE SQL IDENTIFICADOS Após as

entrevistas, o primeiro passo intermediário para explorar as concepções errôneas dos alunos foi rotular os erros que eles cometeram em suas consultas. Para isso, utilizamos todas as consultas intermediárias e finais escritas pelos participantes.

Como nosso foco é explorar as ideias equivocadas que levam a esses erros, não apresentaremos a lista completa de erros neste artigo. Em vez disso, agrupamos os erros em categorias e apresentamos este resumo. Dividimos as categorias de erros semânticos e lógicos em grupos menores, pois acreditamos que essas categorias são muito genéricas e, portanto, pouco descritivas. Utilizamos as seguintes categorias: problemas de sintaxe, tabela/coluna incorreta ou ausente, palavra-chave incorreta ou ausente, retorno de resultados incorretos, problemas com o esquema, problemas de alias, contrações e complicações.

Cliente			
clD	Rua	cName	cidade
0	Noé	Rua da Vaca	Utrecht
1	Como	Rua Rosemary Breda	
2	Lucas	Rua dos Lírios Velhos, Amsterdã	
3	Estrada	Kalverstraat	Amsterdã

Lista de compras			
clD	plD	1	2
			data de quantidade
			1 2020-05-13
1	3	6	13/05/2020
3	1	2	15/05/2020

Loja			
slD	Rua	sName	cidade
	Cooperativa	Kalverstraat	Amsterdã
0 1	Lidl	Rua Principal	Utrecht
2	Lidl	Rua Molen	Eindhoven
3	Hoogvliet	Rozemarijnstraat Breda	
4	Sligro	Praca da Estação	Breda

Inventário			
slD	plD	1	2
			data
0			2020-05-15 55
			quantidade
			0,55
			preço unitário
			2.3
0 1	2 4		2020-05-15 12
			1.8
1	1		2020-05-15 46
			0,6

Transação					
	clD	slD	plD	data	quantidade
	0	4		2020-05-12 5	0,4
	0	4	3 1		2 0,65
2	2	0	4	2020-05-13 2	1.3
3	3	0	1	2020-05-15 1	0,67

Produto		
plD	pNome	sufixo
	Leite	""
1 2	Cogumelos	""
3	Maças	""
4	Chá	""
5	Banana	""

Figura 1: Dados de amostra apresentados aos participantes. O esquema do banco de dados é baseado em um grupo de supermercados.

A apresentação dos erros abaixo é um primeiro passo na análise dos nossos dados. A rotulagem desses erros nos ajuda a ordenar os dados antes de examinarmos suas causas subjacentes na Seção 5.

4.1 Problemas de sintaxe

Erros de sintaxe são uma categoria comum de erros, presentes em vários outros casos. artigos sobre erros de SQL [1, 21, 34–36].

Como é de se esperar ao escrever em uma língua tão rigorosa quanto Em SQL, muitos erros de sintaxe ocorreram durante as entrevistas. Alguns Algumas dessas eram muito básicas, como esquecer vírgulas e parênteses. bem como as aspas em torno dos dados da string. Estes podem ser atribuídos às distrações e à negligência. Outros estavam mais envolvidos, e Apresenta alguns problemas na compreensão de como o SQL funciona. Um básico O exemplo mostra a escrita incorreta dos operadores. Para 'diferente de', ambos <> e != são formas válidas, mas alguns participantes escreveram ou 'IS'. NÃO'. Para 'igual a', o SQL exige =, mas alguns participantes escreveram ==. Outros erros diziam respeito ao uso da vírgula e do operador "E", que são não são intercambiáveis. Os participantes substituíram a vírgula por "E", ou omitiu completamente o "E" ou a vírgula.

Outra subcategoria de problemas de sintaxe é a de palavras-chave e cláusulas ordenadas incorretamente. Descobrimos que os participantes, incorretamente, colocando a palavra-chave GROUP BY no início da consulta, e Reordenando SELECT, FROM e WHERE.

4.2 Tabela/coluna incorreta ou ausente

Um problema semelhante ao das palavras-chave ausentes ou incorretas também ocorreu com os próprios dados. Alguns participantes usaram tabelas incorretas ou Nomes de tabelas e colunas confusos. Outros projetados apenas em parte das colunas necessárias, ou esqueceu-se de incluir uma tabela para auto-junção.

Ahadi et al. coletam erros nesta e na categoria anterior sob 'erros de omissão' [3]. De Presler-Marshall et al. esta categoria pode Incluir subcláusulas incorretas na cláusula WHERE, faltar o JOIN e Incompatibilidade de colunas. Também está relacionado ao problema indefinido de Taipalus et al. erros de objeto de banco de dados e projeção [34], e o erro menor de Welty et al. erro de operando [36]. Erros relativos a atributos e seus tipos são categorizados por Welty como erros complexos [35]. Esta categoria não ocorrem na lista de erros semânticos de Brass et al. [8].

4.3 Palavra-chave incorreta ou ausente

Outros pesquisadores classificam esses erros como erros de sintaxe [8, 34], mas Acreditamos que haja uma diferença entre a ausência de vírgulas e outros problemas. elementos menores, por um lado, e cláusulas completamente ausentes, por outro. Por outro lado, Presler-Marshall et al. incluem isso como dado faltante ou operador extra em sua categoria semântica [21]. Incluímos o mudança de palavras-chave em uma categoria separada. Às vezes há Houve algumas confusões, mas também algumas invenções criativas por parte dos nossos... participantes.

Alguns participantes também cometeram erros com base em sinônimos: SUM versus CONTAR e CLASSIFICAR versus ORDENAR POR. Também tínhamos alguns casos de palavras-chave ausentes: omissão de BY em ORDER BY, ausência de LIGADO para JOINS explícitos e FROM ausente. As perguntas que fizemos Todas as consultas eram de recuperação de informações. No entanto, um participante queria... Use INSERT em vez de SELECT. Por fim, um participante pensou que para obter o primeiro item de uma lista, eles devem usar DISTINCT.

4.4 Retornando resultados incorretos

Esta categoria inclui consultas que estavam sintaticamente corretas, mas resultaria em resultados incorretos. Algumas consultas incluem resultados incorretos. operadores (= em vez de !=) ou funções incorretas, como a adição. CONTAGEM quando não necessário. Resultados incorretos também ocorreram porque de problemas com os JOINS, como omissão da condição JOIN, condições JOIN incorretas e comparação de itens incompatíveis (rua = cidade). As projeções também davam errado com frequência. Os participantes projetaram Na ordem errada, em colunas extras ou colunas omitidas.

Taipalus et al. chamam esses erros lógicos nas subcategorias de operadores e junções [34]. Da mesma forma, inclui alguns erros listados por Welty e Stemple: pequeno erro de linguagem, pequeno erro de conteúdo e erro grave de substância [36]. Resultados incorretos também incluem alguns erros relatados por Presler-Marshall et al.: valores incorretos em where, Ordenação incorreta, operador incorreto em WHERE [21]. Não ocorre na lista de erros semânticos de Brass et al. [8].

4.5 Problemas com o esquema do banco de dados

Esta categoria está relacionada ao processo dos participantes e, portanto, não havia sido relatado em pesquisas anteriores.

Como discutimos na seção de trabalhos relacionados deste artigo, problemas na formulação de consultas podem surgir da necessidade de memorizar o esquema do banco de dados. Encontramos vários erros intimamente relacionados ao esquema, a maioria dos quais envolve confusão sobre qual tabela ou atributo usar. Outros problemas de esquema incluem confundir o nome de uma tabela com o nome de uma coluna e erros de ortografia tanto nos nomes das tabelas quanto nos das colunas.

4.6 Problemas com aliases Um

dos problemas que muitos participantes enfrentaram foram os aliases. Parece que os alunos nem sempre compreendem corretamente a finalidade dos aliases e quando usá-los. Isso se relaciona tanto à sintaxe dos aliases (escrever o alias após o nome da coluna, usar um alias sem defini-lo) quanto à sua aplicabilidade. Por exemplo, algumas consultas continham nomes de coluna ambíguos devido à ausência de aliases. Outras consultas incluíam aliases quando não eram necessários.

Taipalus et al. classificam alguns desses erros como erros de sintaxe e outros como complicações [34]. De acordo com Presler-Marshall et al., os problemas de alias são classificados como erro de referência de coluna [21]. Essa categoria não está incluída na lista de erros semânticos de Brass et al. [8].

4.7 Contrações

Este é um conjunto de erros que se sobrepõe a erros de sintaxe, mas reflete casos em que nossos participantes quiseram escrever as consultas de forma mais curta, mesmo que isso não fosse sintaticamente permitido (por exemplo, Consulta 3).

Alguns participantes perderam a noção da sintaxe básica de SQL e cometeram erros ao combinar ou confundir várias partes das consultas. Um participante fundiu as cláusulas SELECT e FROM e escreveu: `SELECT customer AS a, customer AS b`, onde customer é o nome de uma tabela no esquema. Algo semelhante aconteceu com as cláusulas SELECT e WHERE, onde os participantes projetaram os itens que deveriam ser selecionados.

Outras confusões incluíram subconsultas, onde as condições não foram colocadas no nível de aninhamento correto, e agregação. A agregação já havia sido demonstrada por outros pesquisadores (ver [8]) como sendo difícil. O principal problema de agregação que encontramos está relacionado ao uso de GROUP BY, o que resultou em diversas respostas incorretas.

```
SELECIONE cliente AS a, cliente AS b ONDE
a.rua = b.rua E a.cidade <>
b.cidade;
```

Consulta 3: Participante 16, pergunta 2, um exemplo de consulta contraída.

4.8 Complicações Complicação

é uma categoria comum, apoiada pela literatura anterior [8, 34], que descreve as partes da consulta que não alteram a resposta, mas complicam a formulação da consulta e tornam-na mais difícil de interpretar e verificar. Exemplos incluem GROUP BY em grupos singleton, JOIN desnecessário ou uso de aliases quando não necessário.

Algumas dessas complicações foram puramente visuais. Por exemplo, um participante escreveu todos os nomes das colunas por extenso em vez de usar asteriscos (*). Outros participantes escreveram colchetes desnecessários, renomearam colunas ou definiram aliases, mas não os utilizaram. Mais uma complicação para

O uso de aliases era uma forma impraticável de nomear as tabelas. A maioria dos participantes havia aprendido a usar a primeira letra do nome da tabela. Outros participantes não haviam aprendido isso e, em vez disso, usavam A, B, C como aliases. Isso reduz significativamente a legibilidade e, nesses participantes, observamos alguns casos de aliases trocados, em que conjuntos incorretos de alias e coluna foram combinados.

Outras complicações eram funcionais e resultavam em processamento extra da consulta. Isso inclui aplicar DISTINCT a um resultado que não contém duplicatas e adicionar uma condição extra que já está contemplada por algum outro elemento da consulta. Outro processo que observamos algumas vezes foi a inclusão de tabelas na cláusula FROM caso fosse necessário retornar a chave primária da tabela, independentemente de ela também estar incluída como chave estrangeira em outra tabela. Isso resultava em JOINS extras que não eram necessários.

5 RESULTADOS

Nesta seção, apresentamos as concepções errôneas reveladas pela análise do processo de formulação de consultas SQL de nossos participantes, organizadas em quatro categorias principais: concepções errôneas baseadas em conhecimento prévio do curso, concepções errôneas baseadas em generalização, concepções errôneas baseadas na linguagem e concepções errôneas devido a um modelo mental incompleto ou incorreto.

5.1 Conceitos errôneos baseados em conhecimentos prévios do curso

SQL é um tópico presente na maioria dos cursos universitários de Ciência da Computação. Contudo, mesmo nesses programas, não será a primeira coisa ensinada aos alunos. Nas instituições dos autores, o curso introdutório de Bancos de Dados é ministrado apenas no segundo ano. Além disso, os alunos contextualizam o conhecimento com base no que já sabem.

Tudo o que eles aprenderam até agora pode influenciar o novo conhecimento. A causa de vários dos erros cometidos pelos participantes do nosso estudo foi a aplicação incorreta de conhecimentos prévios de matemática, programação e bancos de dados.

5.1.1 Matemática.

Acreditar que o operador de comparação `&` é válido em SQL é um erro. Os alunos utilizam conhecimentos de matemática como base para determinar quais operadores são válidos. Por exemplo, alguns alunos escreveram consultas contendo `&&` em vez de `!=` ou `<>`. Os dois últimos são operações válidas em SQL, enquanto o primeiro não é. No entanto, `&&` é frequentemente usado em cursos de matemática e os alunos estão familiarizados com ele. Vários participantes mencionaram que não se lembravam de qual(is) símbolo(s) usar para indicar a não igualdade e, aparentemente, `&&` é o mais acessível em sua memória.

5.1.2 Programação.

SQL é uma linguagem de consulta e, portanto, próxima das linguagens de programação e suscetível à transferência de conhecimento. Nossos participantes tinham experiência com diversas linguagens de programação, como Python, Java, C# e JavaScript. Portanto, algumas concepções errôneas que encontramos são semelhantes às relatadas na literatura sobre concepções errôneas em programação.

Confusão entre == e =. Os alunos usam esses dois sinais de forma intercambiável em vários contextos, como demonstrado por pesquisas sobre equívocos em programação. Também encontramos essa confusão em nossos experimentos com SQL. Esse erro faz sentido, pois em linguagens de programação = é

Em SQL, usa-se = para atribuição e == para comparação. No entanto, em SQL, == não é usado. Em vez disso, usa-se = para comparação, e não há atribuição.

```
COM u COMO (SELECT i.sID, i.date, i.unit_price FROM inventory
  AS i, product AS p WHERE i.pID = p.pID AND
    p.pName = "Bananas")

SELECT p.pName
FROM inventory AS i, product AS p WHERE
u.sID = i.sID AND
  u.date = i.date AND
  i.preço_unitário > u.preço_unitário E i.pID =
  p.pID
```

Consulta 4: Participante 3, consulta 5, não compreendeu o âmbito da consulta.

Mal-entendidos sobre o escopo de elementos em uma consulta.

Como discutido em trabalhos relacionados, alguns equívocos comuns em programação têm a ver com o escopo do código. Questões que comprovadamente causam confusão incluem atribuições de variáveis e a verificação de instruções condicionais (if). De maneira semelhante, encontramos dois erros relacionados a mal-entendidos sobre o escopo em SQL.

Primeiro, os alunos definiram uma visão escrevendo uma consulta com uma cláusula WITH. No entanto, uma visão ainda precisa ser chamada na consulta principal para ser usada corretamente. No caso da Consulta 4, o aluno pensou que, como já havia definido a consulta, isso seria suficiente.

Em segundo lugar, ocorreu um erro comum na auto-junção. Uma consulta de auto-junção é frequentemente usada para recuperar pares de entradas da mesma tabela, caso em que a mesma tabela precisa ser chamada duas vezes com valores diferentes. aliases. No entanto, vários participantes chamaram a tabela que desejavam usar apenas uma vez (veja um exemplo na Consulta 14) e, em seguida, tentaram descobrir como projetar um par distinto. Isso é impossível sem chamar a tabela duas vezes, o que levou a tentativas incompletas. Os participantes expressaram sua confusão sobre como resolver esse problema, seja porque não entenderam que precisavam usar a mesma tabela duas vezes, seja porque desconheciam a notação.

5.1.3 Bancos de dados.

Normalmente, os alunos que frequentam um curso sobre Bancos de Dados aprendem primeiro Álgebra Relacional e, posteriormente, SQL. Como as duas áreas estão intimamente relacionadas, é provável que os alunos apliquem o conhecimento de Álgebra Relacional ao SQL, o que pode levar a erros. Em nossa amostra, isso ocorreu com 13 dos 21 participantes.

```
SELECT B.pName
FROM inventory A, product B
WHERE A.pID = B.pID
AND B.unit_price >
  (SELECT C.unit_price
   FROM inventory C, product D
   WHERE C.pName = "Banana"
   E D.pID = C.pID)
```

Consulta 5: Participante 10, pergunta 5.

Acreditar que DISTINCT é o primeiro item de uma lista. Para a questão 5 da Tabela 3, havia uma pergunta complementar para obter mais informações.

na compreensão de subconsultas. Suponha que um usuário escreva uma subconsulta para encontrar o preço de 'Bananas'. Agora, como pID por si só não é uma chave primária na tabela de estoque (veja a Tabela 2), a subconsulta pode retornar mais de um preço correto. A pergunta seguinte aos alunos foi: "Como vocês selecionam um preço para garantir que a consulta faça o que vocês desejam?" A maioria dos alunos sugeriu usar MIN, MAX ou TOP para selecionar um preço. O participante 10 queria usar DISTINCT e acredita que isso garantirá que a subconsulta retorne apenas um resultado. Para referência, a consulta deste aluno está disponível na Consulta 5.

Eis o que eles têm a dizer sobre como resolver esse problema:

"Se eu tivesse usado um DISTINCT antes, no preço unitário, você teria pegado o primeiro preço unitário e o comparado com o preço unitário da consulta principal [...] Se eu usasse DISTINCT em C.unit_price, eu teria retornado apenas um preço unitário e provavelmente seria o primeiro, porque é o que ele encontra primeiro." - Participante 10. Quando o entrevistador pediu esclarecimentos sobre se isso ainda seria válido caso

as bananas tivessem preços diferentes, o aluno respondeu:

"Sim, apenas no caso de [...] se tiverem dois preços. Se tiverem o mesmo [preço], então também não faz diferença, certo?" - Participante 10. Esta

citação ilustra claramente a concepção errônea do aluno. Acreditamos que tal concepção errônea pode surgir quando os alunos são apresentados apenas a exemplos muito seletivos.

Acreditar que um operador de comparação é válido em SQL é um equívoco comum. Essa concepção errônea, também mencionada na Seção 5.1.1, pode ser causada por diversos conjuntos de conhecimento prévio. Já discutimos a possibilidade de uma relação com a matemática, mas outra opção é que os alunos apliquem conhecimentos da Álgebra Relacional, onde o operador de comparação é usado regularmente.

5.2 Conceitos errôneos baseados na generalização.

Uma das principais fontes de erros que identificamos é a generalização de itens previamente aprendidos relacionados a SQL. Isso pode envolver exemplos em um livro ou outro material didático, ou uma consulta que funcionou anteriormente, mas que pode não funcionar em todos os casos. Dentro dessa categoria de nível superior, consideramos dois tipos: modelos e consistência.

5.2.1 Aplicar um modelo de consulta incorreto.

Os modelos são (partes de) consultas que os alunos já usaram anteriormente com sucesso, o que os leva a reutilizá-los.

O primeiro modelo que encontramos é o de igualar chaves primárias. Normalmente, ao usar um produto cartesiano para criar um JOIN, pega-se um atributo de ambas as tabelas e os iguala-se. Durante nosso estudo, encontramos evidências de alunos aplicando esse modelo. No entanto, isso não está correto em todos os casos. Ao procurar todas as permutações ou tentar encontrar pares distintos, como pedimos na questão 3, nenhuma chave deve ser igualada.

Outro indício da utilização de um modelo é analisar quais itens devem ser projetados, quais deles são chaves primárias e, em seguida, incluir as tabelas correspondentes a cada uma dessas chaves primárias na consulta. Isso pode não ser necessário, visto que as tabelas podem estar conectadas por chaves estrangeiras. Poder-se-ia argumentar que isso não é necessariamente incorreto, apenas ineficiente, mas leva a consultas mais longas e, portanto, diminui a legibilidade.


```
SELECIONE cidade, CONTAR(cidade)
DA loja
AGROUPAR POR cidade;
```

Consulta 6: Participante 15, pergunta 6, contando a coluna em que eles se agrupam.

Por fim, um modelo concreto que encontramos sendo aplicado incorretamente dizia respeito à palavra-chave COUNT. Na questão 6 da Tabela 3, "Retorne o número de lojas por cidade", um participante contou a mesma coluna que usou para agrupar os dados, como pode ser visto na Consulta 6. A questão pressupunha a contagem dos IDs das lojas (a chave primária). O entrevistador perguntou se agrupar por um atributo e depois contá-lo resultaria em uma contagem de um. O aluno afirmou ter certeza de que não, pois haviam utilizado esse tipo de consulta com frequência recentemente em um projeto. No entanto, não soube explicar por que isso funcionava. Quando o pesquisador sugeriu que contassem uma coluna diferente, o aluno respondeu:

"Então eu realmente não sei [qual deles]." - Participante 15

Isso indica que eles aplicaram um modelo sem conseguir justificar o motivo.

5.2.2 Compreensão errônea da sintaxe SQL e sua (in)consistência interna.

A categoria de consistência é semelhante à de modelos, mas considera elementos da sintaxe SQL com os quais os alunos têm dificuldade porque são aplicados de forma diferente em casos diferentes.

Primeiramente, há a questão do uso de vírgulas. Tanto nas cláusulas SELECT quanto FROM, as vírgulas são usadas para separar os itens. No entanto, a cláusula WHERE exige o uso do operador AND para separar as condições. Essa inconsistência na sintaxe SQL foi difícil de perceber para alguns participantes, o que os levou a usar uma vírgula em vez do AND na cláusula WHERE.

Em segundo lugar, foi identificada uma inconsistência relacionada a agregações. Em SQL, as agregações só são permitidas nas cláusulas SELECT ou HAVING. No entanto, alguns participantes as utilizaram na cláusula WHERE. Uma agregação não pode ser aplicada aqui, pois não há um grupo sobre o qual agregar, mas isso não está claro para os alunos. Acreditamos que parte do erro decorre do fato de WHERE e HAVING serem locais para inserir condições. Tudo o que pode ser usado em WHERE pode ser usado em HAVING, mas não o contrário, o que é uma inconsistência que causou confusão e levou a erros.

```
SELECIONE cID.transação , data.transação ,
quantidade . transação
DE transação COMO t, produto COMO p
JOIN product ON
transaction . pID = product.pID WHERE
product.pName = "Apples";
```

Consulta 7: Participante 21, pergunta 4, nome da tabela por trás do atributo em SELECT.

Outra inconsistência que encontramos está relacionada ao uso de aliases. Neste caso específico, discutimos a inconsistência entre definir o alias por trás da relação e chamar o alias antes de um atributo. Na cláusula SELECT, os usuários devem escrever alias.atributo, enquanto que para a definição é alias de relação (AS). A opção de usar o

A palavra-chave pode tornar este último caso mais saliente, o que leva a mais erros no primeiro caso. Três dos alunos entrevistados

foram afetados por essa inconsistência, cometendo erros como os das consultas 7 e 8.

```
SELECT pName p
FROM product p
WHERE pID IN (SELECT pID FROM
inventory WHERE
unit_price > 2.3);
```

Consulta 8: Participante 4, pergunta 5, alias por trás do atributo em SELECT.

Por fim, há a questão do uso do ponto e vírgula. Os alunos normalmente aprendem que toda consulta deve terminar com um ponto e vírgula. O participante 19 levou isso a sério, como podemos ver na Consulta 9. No entanto, os pontos e vírgulas não devem ser usados em subconsultas. Dependendo do número de exemplos mostrados aos alunos e do método de ensino, essa exceção pode não ser clara para todos. Assim, eles podem aplicar consistentemente a regra que aprenderam: toda consulta deve ser finalizada com um ponto e vírgula.

```
SELECT p.pName
FROM inventory AS i
WHERE i.unit_price > (SELECT i.unit_price FROM
inventory AS i JOIN product
p ON i.pID = p.pID WHERE p.pName =
"Banana");;
```

Consulta 9: Participante 19, pergunta 5, usando um ponto e vírgula na subconsulta.

5.3 Conceitos errôneos relacionados à linguagem.

Embora as cláusulas em SQL possam ser lidas como algo próximo da linguagem natural, inerentemente, ainda existe uma grande diferença entre as duas. Portanto, a linguagem também pode ser uma fonte de mal-entendidos.

Acreditamos que o operador IS NOT seja válido em comparação em SQL. Na Seção 5.1.1, já mencionamos que muitos alunos não se lembravam de como escrever desigualdades. Além da opção de escrever IS NOT, alguns alunos em nosso estudo escreveram IS NOT. Isso faz sentido se considerarmos as palavras-chave disponíveis em SQL, já que IS também existe. IS pode não ser utilizável para afirmar (des)igualdade na cláusula WHERE, mas na linguagem natural é, o que levou os alunos a usarem IS ou IS NOT em vez de = ou !=<>.

Lembrar apenas a parte principal de uma palavra-chave. Um segundo aspecto da linguagem SQL é que muitas palavras-chave incluem preposições: INSERT INTO, GROUP BY, JOIN ON. Em várias questões, descobrimos que os alunos omitiam essas preposições durante a formulação da consulta e, portanto, escreviam apenas INSERT, GROUP e JOIN (veja a Consulta 10). Do ponto de vista da Linguagem Natural, essas palavras-chave podem ser a parte principal da cláusula, já que as preposições não são necessárias para que a consulta faça sentido ao ser lida. Infelizmente, sintaticamente, as cláusulas não funcionam sem a adição da preposição. As cláusulas podem ter sido armazenadas erroneamente na memória apenas por sua parte "principal", desconsiderando as preposições.


```
SELECT transaction.cID,
       transaction.date ,
       transaction.quantity FROM
transaction
JOIN transaction . pID = product.pName WHERE
pnamed = "Apples";
```

Consulta 10: Participante 18, pergunta 4, vários assuntos.

Uso de sinônimos em palavras-chave SQL. A categoria de erros de sinônimos usados na formulação de consultas foi observada por diversos autores [19, 27]. Encontramos a ocorrência de sinônimos em nomes de tabelas e atributos, bem como em palavras-chave SQL. O primeiro indica falta de conhecimento sobre o esquema do banco de dados usado no exercício, ou uma relação com a pergunta feita, como na Consulta 10, mas o segundo pode indicar uma concepção errônea baseada na linguagem. Um exemplo disso é mostrado na Consulta 11, onde um aluno escreveu SORT BY em vez de ORDER BY. SORT não é uma palavra-chave SQL válida. Acreditamos que a palavra sort seja mais acessível ao aluno durante o estudo. Isso é interessante, pois a questão 7 (ver Tabela 3) na verdade não mencionou sort, mas sim "ordenado alfabeticamente".

```
SELECCIONAR y
DA loja
ORDENAR POR cidade ASC;
```

Consulta 11: Participante 14, pergunta 7, o participante usou SORT em vez de ORDER.

Uso de um idioma não nativo. Por fim, durante o estudo, notamos alguns problemas com o idioma. Muitos participantes que não eram falantes nativos de inglês traduziram os problemas para seu idioma nativo e raciocinaram nesse idioma antes de traduzir de volta para o inglês para usar o SQL. Por exemplo, a questão 4 continha a palavra "quantidades", que indicava uma coluna em uma das tabelas. Alguns participantes traduziram a questão para seu idioma nativo, o que alterou as implicações da questão. No final, alguns dos participantes que traduziram (como o participante 20, Consulta 12) chegaram à conclusão de que precisavam contar algo e, portanto, aplicaram a palavra-chave COUNT.

```
SELECCIONE cID, COUNT(tID), data da transação FROM
cliente c
JOIN transação t ON c.cID = t . cID JOIN produto
p on t . pID = p.pID WHERE p.pName =
"Apples";
```

Consulta 12: Participante 20, pergunta 4, incluindo a tabela de clientes quando isso não for necessário.

5.4 Conceitos errôneos devido a um modelo mental incompleto ou incorreto.

Embora todos os equívocos discutidos acima decorram de modelos mentais incorretos, alguns erros demonstram isso de forma mais explícita do que outros. Nesta seção, discutiremos todos esses conceitos de SQL que

Os alunos tiveram dificuldades devido a modelos mentais incompletos ou incorretos.

```
SELECCIONE cID, cName
DO cliente
ONDE (cidade = "Eindhoven");
```

Consulta 13: Participante 17, questão 2, participante usou parênteses estranhos.

Utilizando parênteses como muleta. Primeiramente, partimos de uma indicação geral de modelos mentais incompletos. Alguns dos alunos deste estudo incluíram parênteses extras onde não fazem sentido, como na cláusula WHERE (ver Consulta 13). Embora isso não seja explicitamente incorreto, já que o SQL pode ignorar esses parênteses, eles reduzem a legibilidade. Além disso, o participante provavelmente tinha um motivo para incluir esses parênteses. Isso pode ocorrer porque ele associa WHERE a parênteses, por meio de subconsultas. Trabalhos existentes mostram que os participantes usam parênteses para tentar corrigir erros [18] em vez de tentar encontrar o erro real e corrigi-lo. Isso demonstra uma lacuna no conhecimento dos alunos.

Falta de conhecimento sobre chaves primárias. Vários participantes indicaram dificuldades quanto ao uso de chaves primárias em diferentes situações.

Por exemplo, ao tentar conectar duas tabelas por meio de um produto cartesiano, um participante disse: "Preciso

conectar as duas tabelas com uma chave primária. Ou será que já fiz isso? Não tenho certeza..." - Participante 8

Na verdade, eles já haviam redigido a cláusula WHERE correta para conectar as tabelas adequadamente.

Além disso, observamos evidências dessa dificuldade na aplicação do DISTINCT em atributos que eram chaves primárias. Quando um atributo é chave primária, por definição, ele deve ocorrer apenas uma vez nos dados. Portanto, essas chaves são únicas por definição e, consequentemente, o DISTINCT não é necessário. Alguns participantes mencionaram que provavelmente não era necessário, mas aparentemente não tinham certeza suficiente para omiti-lo, o que indica falta de conhecimento sobre os efeitos das chaves primárias.

```
SELECCIONAR cID
DE clientes
ONDE rua = rua
E cidade <> cidade;
```

Consulta 14: Participante 18, pergunta 3, uma tentativa de auto-junção sem uma segunda tabela presente.

Considerar o SGBD como uma caixa preta. O erro de auto-junção, descrito na Seção 5.1.2 em escopo, também pode ser explicado por uma concepção errônea diferente, ou seja, a de considerar o SGBD como uma caixa preta. Por exemplo, depois que os participantes não incluíram a segunda tabela para responder à pergunta 3 na Tabela 3, o entrevistador sugeriu a alguns participantes que eles precisavam incluir um JOIN, ou outra cópia da tabela. Um participante, que havia usado 'cópias' dos atributos nas cláusulas SELECT e WHERE, respondeu: "Eu gostaria de saber por quê...", indicando que não conseguia perceber que precisava de duas cópias. Isso significa que ele pensou que o SGBD poderia resolver a Consulta 14.

Outro participante não entendeu em quais casos era necessário adicionar condições JOIN. A consulta 15 é a consulta inicial dele.

O participante 9 explica: "Não

tenho certeza de como eles entram. Ou se entram. Se entram automaticamente pelos pIDs, ou se eu preciso dizer alguma coisa." [...] Porque eu já filtrei as linhas que contêm maçãs e estou selecionando de ambas." - Participante 9

Adotar uma perspectiva incorreta. A partir do raciocínio dos participantes durante o estudo, outra concepção errônea que encontramos foi a de uma perspectiva incorreta. A maioria dos participantes abordou cada problema a partir da descrição do problema. No entanto, alguns participantes se concentraram em como a tabela de resultados deveria ser, sem considerar as implicações para a consulta. Um exemplo disso é a Consulta 10. Este participante tenta unir duas tabelas, mas comete vários erros e seleciona dois atributos incompatíveis, tentando comparar um pID com um pName. Quando o entrevistador perguntou por que não usaram a mesma coluna duas vezes (pID = pID), eles argumentaram que pID já está contemplado na tabela de transações. Como a questão exige que encontrem o pName correspondente a cada pID, eles querem "mover" a consulta para o produto, onde pName está codificado. O fato de transaction.pID já estar incluído na consulta não significa necessariamente nada para o SGBD. Neste caso específico, isso inibe respostas, pois a condição JOIN está incorreta. Assim, esse participante abordou o problema a partir de uma perspectiva errada, resultando em uma tabela de resultados vazia.

Outro exemplo de perspectiva incorreta ocorreu com o Participante 9. Após ler a pergunta proposta, ele examinou o esquema do banco de dados para verificar qual(is) tabela(s) continha(m) todos os atributos necessários. Como a tabela "shoppinglist" era uma das tabelas exibidas no topo do esquema e continha os elementos requeridos, ele decidiu compor a consulta usando "shoppinglist" (veja a Consulta 15).

No entanto, a consulta indicava que eles precisavam usar a tabela de transações. Como a perspectiva deles estava incorreta, a consulta, por sua vez, também estava incorreta.

```
SELECT s.cID, s.date s.quantity FROM
shoppinglist s, product p WHERE
p.pName = "Apples";
```

Consulta 15: Participante 9, pergunta 4, condição JOIN ausente no produto cartesiano.

5.5 Outras observações

Todos os participantes cometeram erros de sintaxe. Isso inclui omitir aspas em torno de strings, escrever nomes de tabelas e colunas incorretamente, omitir o ponto e vírgula e usar operadores não padronizados. A maioria desses erros de sintaxe provavelmente ocorreu devido a lapsos de atenção e geralmente foram corrigidos posteriormente.

Durante as entrevistas, percebemos que os participantes frequentemente se mostravam confusos. A maior confusão surgiu em relação aos JOINS e aos aliases. Os participantes não sabiam quando usá-los, se já haviam concluído essa parte da consulta, como cada tipo era chamado (produto cartesiano, junção interna, junção natural) e assim por diante.

Outra causa de confusão foram os problemas na formulação da consulta, em que os dados correspondentes à pergunta (ou seja, o que deveria estar incluído na tabela de resultados) não estavam presentes no banco de dados de exemplo. Nesses casos,

Em alguns casos, os alunos tiveram muita dificuldade em escrever a consulta porque olhavam para os dados e não entendiam como escrever a consulta se os dados não estivessem lá. Por exemplo, no problema 5 da Tabela 3, vários participantes concluíram que não havia preço disponível para Bananas.

"Qual é o preço unitário que posso usar? Nesse caso, ninguém tem bananas, então... Não há bananas, então não faz sentido." -

Participante 8

Isso é interessante, pois normalmente só analisamos o esquema (e não os dados) ao escrever uma consulta. Encontrar os dados (neste caso, o preço da banana) é o objetivo da consulta, então analisar os dados em si parece improdutivo. Além disso, verificar se os dados estão presentes antes de escrever uma consulta é inviável em situações normais.

Os bancos de dados são muito grandes para serem consultados manualmente. Portanto, é interessante observar que três dos nossos participantes se envolveram nessa prática (participantes 4, 8 e 15).

Outro problema com o esquema é que, em vez de lerem a pergunta atentamente, os participantes olhariam para os atributos que precisam retornar e verificariam no esquema do banco de dados quais tabelas contêm esses elementos. Isso ignora completamente o significado dos dados. Por exemplo, em nosso esquema, "shoppinglist" e "purchase" contêm colunas semelhantes. No entanto, se você substituir uma pela outra cegamente, o significado da consulta muda completamente.

Por outro lado, alguns participantes demonstraram maior discernimento ao discutir as chaves primárias e o que isso significava para a formulação da consulta. Por exemplo, na questão 5 da Tabela 3, alguns participantes observaram que a data fazia parte da chave primária da tabela de estoque. Isso significa que esses participantes escreveram uma consulta diferente daqueles que não perceberam esse detalhe. Outro aspecto em que as chaves primárias desempenham um papel importante é a necessidade ou não do operador DISTINCT para as soluções.

5.5.1 Falta de conhecimento ou experiência. Outro fato notável é a generalizada falta de conhecimento ou experiência em vários conceitos de SQL. Isso inclui GROUP BY, JOIN, aliases e subconsultas.

Os problemas com esses conceitos foram tão graves para alguns participantes que se tornou inviável identificar equívocos específicos.

Para a cláusula **GROUP BY**, encontramos problemas com o posicionamento dentro da consulta, bem como confusão sobre quando ela é necessária. Por exemplo, ao tentar resolver o problema 7 da Tabela 3, que exige a ordenação de uma tabela, o participante 7 também incluiu uma cláusula GROUP BY:

"Acho que o GROUP BY é muito incômodo. Às vezes você precisa dele, outras vezes não. Nesse caso, acho que o ORDER BY provavelmente é suficiente. Então eu diria para remover o GROUP BY, mas não sei (não posso testar) se isso influencia a resposta. [...] Pelo que sei, não deve fazer mal."

- Participante 7

Ao buscarmos a reordenação de uma tabela, adicionar o comando GROUP BY, na maioria dos casos, altera significativamente o resultado. Nesse caso específico, agrupar por uma coluna e, em seguida, ordenar pela mesma coluna descarta muitas linhas da tabela. Seria interessante analisar essas situações com mais detalhes em estudos subsequentes.

```
SELECT c1.cID, c2.cID
FROM customer, customer
WHERE c1.street == c2.street
E c1.cidade != c2.cidade
```

Consulta 16: Participante 12, pergunta 3, usando um pseudônimo sem defini-lo.

Em relação aos **pseudônimos**, constatamos que eles foram usados de forma inconsistente pelos nossos participantes. Alguns participantes definiram pseudônimos, mas não os utilizaram, ou os utilizaram sem defini-los adequadamente (Questão 16).

Ao discutirmos mais detalhadamente, descobrimos que alguns participantes acreditavam que o SGBD analisava todos os nomes de colunas, em vez de apenas os das tabelas incluídas na cláusula FROM. Um exemplo disso foi...

Um exemplo é o participante 20. Para o problema 2 da Tabela 3, os participantes precisam usar apenas uma tabela e, portanto, não é necessário nenhum alias. Quando discutimos isso, eles dizem o seguinte:

"A tabela de clientes tem a cidade, que é o que você quer usar como filtro. Mas como também temos a cidade na tabela de lojas, você não pode simplesmente colocar a cidade nesta consulta, porque se fizer isso, [o SGBD] não saberá o que filtrar. Portanto, você precisa especificar que deseja cliente.cidade." - Participante 20. Outros participantes

comentam que sempre aplicam os aliases automaticamente, sem pensar.

"Eu sempre faço isso automaticamente, mas para uma mesa, acho que não precisamos fazer assim." - Participante 13

Por outro lado, houve participantes que deram a entender que os pseudônimos são opcionais, quando em alguns casos são obrigatórios: "Às vezes evita

problemas, mas às vezes só complica as coisas. Depende do nível de complicação."

"Isso economiza mais digitação, eu acho." - Participante 9

```
SELECT t.cID, t.date FROM, t. quantidade
transaction t
ONDE t.pID EM (SELECIONE p.pID DE
produto p ONDE
pName = "Maçãs")
```

Consulta 17: Participante 4 usando uma subconsulta em vez de uma junção.

O último conceito que os participantes pareceram não compreender bem foram **as subconsultas**. Elas foram usadas mesmo em casos onde não faziam sentido e dificultavam a resolução do problema e a compreensão da consulta.

O participante 4 decidiu usar uma subconsulta para o problema 4 na Tabela 3. Este problema de formulação de consulta é relativamente simples quando se utiliza um produto cartesiano (como foi feito no problema 3) ou uma junção natural, mas este participante não os utilizou. Em vez disso, escreveu as Consultas 8 e 17 usando a palavra-chave IN. Isso também demonstra falta de compreensão do operador JOIN, porém com uma solução criada. O esclarecimento de que não sabiam como usar subconsultas veio da Consulta 8. Nela, explicaram que não sabiam como fazer a subconsulta retornar um único número inteiro. Deveriam recuperar o preço para um determinado ID, mas sugeriram, em vez disso, inserir o preço diretamente no código da subconsulta.

"Não sei como fazer isso. Já fiz antes, era um dos exercícios da minha tarefa. Naquela época também foi muito difícil para mim extrair o número." - Participante 4. Outro mal-entendido sobre subconsultas

é demonstrado pelo participante 5. Sobre a questão 5 e as subconsultas que retornam resultados, ele diz: "A subconsulta retorna o produto cujo nome é

Banana, então só há uma resposta, mas vou calcular a média porque requer agregação. Se eu não fizer isso, [o SGBD] vai interpretar como uma lista de respostas." - Participante 5. Isso não é verdade. Se houver apenas um registro na subconsulta, omitir a agregação também

resulta em uma consulta válida.

6 DISCUSSÃO

Já se sabe, a partir de trabalhos existentes na área do ensino da computação, que as concepções errôneas de programação são frequentemente causadas pela transferência de conhecimentos prévios dos alunos provenientes de linguagem natural, matemática e outras linguagens de programação [9, 24]. Nossos resultados confirmam que esse também é o caso do SQL, destacando as áreas onde essa transferência ocorre e os erros que ela causa. A identificação

A transferência inadequada de conhecimento prévio é o primeiro passo para o refinamento e reorganização do conhecimento [12]. Diversas abordagens foram propostas para lidar com concepções errôneas na programação introdutória [24], as quais poderiam ser aplicadas às instruções SQL. Uma das abordagens que recentemente demonstrou ser eficaz para facilitar a transferência de conhecimento revisado são os textos de refutação, que explicitamente declaram e refutam concepções errôneas [5].

Um dos conceitos mais desafiadores para os participantes do nosso estudo, causando diversos problemas no processo de formulação de consultas, foram as junções de tabelas. Acreditamos que isso possa ter origem na variedade de métodos disponíveis para combinar tabelas. O participante 21, por exemplo, combinou dois métodos em uma única consulta (Consulta 8). Nossa impressão geral é que a junção de tabelas é um conceito confuso para muitos estudantes.

Isso também foi demonstrado por outros pesquisadores. Kearns et al. escrevem que "Os alunos frequentemente têm dificuldades com o conceito de junção relacional e acham difícil visualizar a aparência das tabelas unidas." [14, p. 226]. Mais recentemente, Taipalus e Perälä afirmam que "Erros de junção (LOG-2) foram comuns em quase todas as consultas com múltiplas tabelas, tanto em todas quanto na consulta final." [32, p. 202]. Também encontramos alunos que não tiveram problemas com produtos cartesianos ou junção natural, mas ficaram presos na auto-junção. Isso também foi demonstrado por Ahadi et al.: "62% de todos os alunos que conseguiram responder a uma questão de junção natural não conseguiram fornecer uma auto-junção correta." [2, p. 204]. Infelizmente, não obtivemos muitas informações sobre por que as junções parecem ser um conceito tão problemático.

Nossos participantes também frequentemente cometiam erros devido a uma perspectiva incorreta na formulação de consultas. Pesquisas sobre concepções errôneas em programação revelaram que os alunos frequentemente apresentam dificuldades em compreender a tarefa e decompor o problema [24]. Em SQL, isso é especialmente difícil porque é uma linguagem declarativa. A execução de consultas SQL, portanto, não pode ser rastreada da mesma forma que programas escritos em linguagens de programação imperativas. No ensino de programação, rastrear programas significa executar um modelo mental que engloba tanto a máquina conceitual quanto o programa rastreado [29]. A impossibilidade inerente de rastrear a execução de consultas SQL limita as representações mentais que os novatos podem ter dos elementos da consulta e pode reforçar sua visão de "caixa preta" do SGBD. Soluções que foram propostas

para auxiliar na visualização de resultados intermediários de consultas estão a ferramenta eSQL [14], bem como, mais recentemente, mapas conceituais do processo de evolução de resultados intermediários de instruções SQL [26].

Diversas das concepções errôneas que identificamos são específicas do SQL e de seu ensino. A partir de trabalhos existentes, sabe-se que a aplicação de modelos para alcançar uma abordagem de dividir para conquistar é eficaz no ensino de SQL [23]. Em nosso estudo, no entanto, observamos que os alunos ficavam confusos ou cometiam erros ao tentar aplicar modelos de consulta que não eram apropriados para o problema de formulação de consulta que lhes foi apresentado. Outra fonte de confusão foi a semântica da notação SQL. Essa última causa de concepções errôneas relaciona-se à consistência interna da sintaxe SQL. Há uma discussão em andamento sobre esse tópico, com vários aspectos da sintaxe SQL sendo considerados contraintuitivos [10, 16, 26].

Em contraste, Taipalus atribui muitos dos erros de formulação SQL mais comuns que encontraram anteriormente [34] à ignorância [31].

Dois exemplos de erros que eles atribuem à ignorância são a omissão de uma junção e um operador de comparação incorreto, ou um valor comparado. Em nosso estudo, vamos além dessa categoria superficial e encontramos evidências de problemas mais sérios, como completa confusão em relação ao conceito de junção.

Limitações. Notamos algumas possíveis limitações do nosso estudo. Em primeiro lugar, os erros e equívocos identificados podem ser resultado das estratégias de ensino e estilos didáticos aplicados. Os alunos que participaram do nosso estudo foram ensinados por pelo menos três professores diferentes, mas ainda assim os equívocos que eles apresentam e expressam podem não ser representativos de outra população estudantil, ensinada por outros instrutores e em outras instituições. No entanto, nosso objetivo neste estudo foi compreender os equívocos de alunos iniciantes independentemente do estilo de ensino, e as variações entre os três subgrupos participantes não impactam significativamente nossos resultados. Em segundo lugar, o uso de papel e lápis durante as entrevistas pode ter facilitado alguns erros de sintaxe que não teriam ocorrido no computador. No entanto, os alunos usaram sintaxe incorreta independentemente do meio, e, portanto, o impacto do papel em nossas conclusões sobre sintaxe é bastante limitado. Em terceiro lugar, a codificação e análise de erros pelos autores seguiram uma taxonomia de erros existente [34] e, portanto, herdaram quaisquer limitações desse trabalho anterior. No entanto, como a categorização de erros não era o foco do nosso trabalho, isso tem um impacto limitado em nossas descobertas. Por fim, dois alunos relataram dificuldades em resolver os problemas enquanto pensavam em voz alta. Whalley e Kasto [37] introduzem uma fase de retrospectiva em seu estudo de erros de programação usando reprodução de áudio. Seguimos uma abordagem semelhante, mas não reproduzimos o áudio para os alunos. Uma reprodução de áudio tão explícita poderia ter nos ajudado a obter mais informações.

7. CONSIDERAÇÕES FINAIS

Neste artigo, apresentamos uma categorização de concepções errôneas para aprendizes de SQL. Baseamos essa categorização em um estudo qualitativo no qual utilizamos uma metodologia de verbalização do pensamento para compreender o processo de raciocínio de iniciantes durante a formulação de consultas. Constatamos que as concepções errôneas se enquadram em quatro categorias principais: concepções errôneas baseadas em conhecimento prévio do curso, concepções errôneas baseadas em generalização, concepções errôneas baseadas na linguagem e concepções errôneas decorrentes de um modelo mental incompleto ou incorreto.

Nossos resultados fornecem uma base para pesquisas futuras visando aprimorar o ensino de linguagens de consulta. Concluímos indicando duas vias naturais para trabalhos futuros. Primeiro, a prevalência de concepções errôneas e a extensão em que essas concepções são dependentes do contexto (por exemplo, sensibilidade ao estilo de ensino) devem ser investigadas. Segundo, as abordagens e os materiais de ensino de linguagens de consulta devem ser revistos para compreender sua (in)adequação em abordar efetivamente as concepções errôneas dos iniciantes.

REFERÊNCIAS

- [1] Alireza Ahadi, Vahid Behbood, Arto Vihavainen, Julia Prior e Raymond Lister. 2016. Erros sintáticos de estudantes na escrita de sete tipos diferentes de consultas SQL e sua aplicação na previsão do sucesso acadêmico. In *Anais do 47º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 401–406.
- [2] Alireza Ahadi, Julia Prior, Vahid Behbood e Raymond Lister. 2015. Um estudo quantitativo da dificuldade relativa para iniciantes na escrita de sete tipos diferentes de consultas SQL. Em *Anais da Conferência ACM de 2015 sobre Inovação e Tecnologia no Ensino de Ciência da Computação*. 201–206.
- [3] Alireza Ahadi, Julia Prior, Vahid Behbood e Raymond Lister. 2016. Erros semânticos de estudantes na escrita de sete tipos diferentes de consultas SQL. Em *Conferência Anual sobre Inovação e Tecnologia no Ensino de Ciência da Computação, ITiCSE*. 272–277. <https://doi.org/10.1145/2899415.2899464> [4] Piraye Bayman e Richard E.
- Mayer. 1983. Um diagnóstico das concepções errôneas de programadores iniciantes sobre instruções de programação BASIC. *Commun. ACM* 26, 9 (set. 1983), 677–679. <https://doi.org/10.1145/358172.358408> [5] Katinka Beker, Jasmine Kim, Martin Van
- Boekel, Paul van den Broek e Panayiota Kendeou. 2019. Textos de refutação aprimoram a transferência espontânea de conhecimento. *Psicologia Educacional Contemporânea* 56 (2019), 67–78. <https://doi.org/10.1016/j.cedpsych.2018.11.004>
- [6] Erik Blair. 2015. Uma exploração reflexiva de duas técnicas de codificação de dados qualitativos. *Revista de Métodos e Medição nas Ciências Sociais* 6, 1 (2015), 14–29.
- [7] Benedict Du Boulay. 1986. Algumas dificuldades de aprendizagem de programação. *Journal of Educational Computing Research* 2, 1 (1986), 57–73. <https://doi.org/10.2190/3LFX-9RRF-67T8-UVK9>
- [8] Stefan Brass e Christian Goldberg. 2006. Erros semânticos em consultas SQL: Uma lista bastante completa. *Journal of Systems and Software* 79, 5 (2006), 630–644.
- [9] Michael Clancy. 2004. *Pesquisa em Educação em Ciência da Computação*. Taylor & Francis Group, Capítulo Conceitos errôneos e atitudes que interferem na aprendizagem de
- nossos resultados.
- [10] Mohammad Dadashzadeh. 2003. Uma abordagem mais simples para consultas de comparação de conjuntos em SQL. *Journal of Information Systems Education* 14, 4 (2003), 345–348. <https://aisel.aisnet.org/jise/vol14/iss4/1> [11]
- Kathi Fisler. 2014. O Problema da Chuva Recorrente. In *Anais da Décima Conferência Anual sobre Pesquisa Internacional em Educação Computacional (Glasgow, Escócia, Reino Unido) (ICER '14)*. Association for Computing Machinery, Nova York, NY, EUA, 35–42. <https://doi.org/10.1145/2632320.2632346>
- [12] John P. Smith III, Andrea A. diSessa e Jeremy Roschelle. 1994. Concepções errôneas reconhecidas: uma análise construtivista do conhecimento em transição. *Journal of the Learning Sciences* 3, 2 (1994), 115–163. https://doi.org/10.1207/s15327809jls0302_1 [13] Lisa C. Kaczmarczyk, Elizabeth R. Petrick, J. Philip East e Geoffrey L. Herman. 2010. Identificando concepções errôneas de programação em estudantes. In *Anais do 41º Simpósio Técnico da ACM sobre Educação em Ciência da Computação (Milwaukee, Wisconsin, EUA) (SIGCSE '10)*. Association for Computing Machinery, Nova York, NY, EUA, 107–111. <https://doi.org/10.1145/1734263.1734299> [14] R. Kearns, S. Shead e A.
- Fekete. 1997. Um sistema de ensino para SQL. In *Anais da 2ª Conferência Australiana sobre Educação em Ciência da Computação (Universidade de Melbourne, Austrália) (ACSE '97)*. Association for Computing Machinery, Nova York, NY, EUA, 224–231. <https://doi.org/10.1145/299359.299391> [15] L. Ma, J. Ferguson, M. Roper e M. Wood.
2011. Investigando e aprimorando os modelos de conceitos de programação mantidos por programadores iniciantes. *Computer Science Education* 21, 1 (2011), 57–80. <https://doi.org/10.1080/08993408.2011.554722> [16] Victor M. Matos e Rebecca Grasser. 2002. Uma abordagem SQL mais simples (e melhor) para divisão relacional. *Journal of Information Systems Education* 13, 2 (2002), 85–88. <https://aisel.aisnet.org/jise/vol13/iss2/2>
- [17] D. McCall e M. Kölling. 2014. Categorização significativa de erros de programadores iniciantes. Em *Anais da Conferência IEEE Frontiers in Education (FIE)* de 2014. 1–8. <https://doi.org/10.1109/FIE.2014.7044420>
- [18] Daphne Miedema. 2019. Rumo a uma interação bem-sucedida entre humanos e bancos de dados. Dissertação de mestrado. Universidade de Tecnologia de Eindhoven. https://pure.tue.nl/ws/portafiles/portal/143091031/Miedema_D.pdf [19]
- William C. Ogden e Susan R. Brooks. 1983. Linguagens de consulta para o usuário casual. Em *Anais da conferência SIGCHI sobre Fatores Humanos em Sistemas de Computação - CHI '83*. ACM Press, Nova York, Nova York, EUA, 161–165. <https://doi.org/10.1145/800045.801602>

- [20] Roy D. Pea. 1986. "Bugs" conceituais independentes de linguagem na programação para iniciantes. *Journal of Educational Computing Research* 2, 1 (1986), 25–36. <https://doi.org/10.2190/689T-1R2A-X4W4-29J2>
- [21] Kai Presler-Marshall, Sarah Heckman e Kathryn T Stolee. 2021. SQLRepair: Identificando e reparando erros em consultas SQL de autoria de estudantes. Em 2021 IEEE/ACM 43ª Conferência Internacional de Engenharia de Software: Educação e Treinamento em Engenharia de Software (ICSE-SEET). IEEE, 199–210.
- [22] Ralph T. Putnam, D. Sleeman, Juliet A. Baxter e Laiani K. Kuspa. 1986. Um resumo das concepções errôneas de programadores de BASIC do ensino médio. *Journal of Educational Computing Research* 2, 4 (1986), 459–472. <https://doi.org/10.2190/FGN9-DJ2F-86V8-3FAU>
- [23] Gang Qian. 2018. Ensinando SQL: um método de dividir para conquistar para escrever Consultas. *J. Comput. Sci. Coll.* 33, 4 (abril de 2018), 37–44.
- [24] Yizhou Qian e James Lehman. 2017. Concepções errôneas dos alunos e outras dificuldades na programação introdutória: uma revisão da literatura. *ACM Trans. Comput. Educ.* 18, 1, Artigo 1 (out. 2017), 24 páginas. <https://doi.org/10.1145/3077618>
- [25] Z. Scherz, D. Goldberg e Z. Fund. 1990. Implicações cognitivas da aprendizagem de Prolog — erros e concepções errôneas. *Journal of Educational Computing Research* 6, 1 (1990), 89–110. <https://doi.org/10.2190/UHFF-4LNQ-63VA-Q60C>
- [26] S. Shin. 2020. Aprendizagem de Linguagem de Consulta Estruturada: Instrução Baseada em Mapas Conceituais com Base na Teoria da Carga Cognitiva. *IEEE Access* 8 (2020), 100095–100110. <https://doi.org/10.1109/ACCESS.2020.2997934>
- [27] John B. Smelcer. 1995. Erros do usuário na composição de consultas de banco de dados. *International Journal of Human-Computer Studies* 42, 4 (1995), 353–381.
- [28] Juha Sorva. 2008. As mesmas, mas diferentes compreensões dos alunos sobre variáveis primitivas e de objeto. In *Anais da 8ª Conferência Internacional sobre Pesquisa em Educação Computacional (Koli '08)*. Association for Computing Machinery, Nova York, NY, EUA, 5–15. <https://doi.org/10.1145/1595356.1595360> [29] Juha Sorva. 2012. Simulação visual de programas no ensino introdutório de programação. Tese de doutorado. Universidade Aalto, Espoo, Finlândia.
- [30] Alaaeddin Swidan, Fellenne Hermans e Marileen Smit. 2018. Conceitos errôneos de programação para estudantes. In *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação Computacional (Espoo, Finlândia) (ICER '18)*. Association for Computing Machinery, Nova York, NY, EUA, 151–159. <https://doi.org/10.1145/3230977.3230995>
- [31] Toni Taipalus. 2020. Explicando as causas por trás dos erros de formulação de consultas SQL. *Anais da Conferência Frontiers in Education, FIE 2020 - Outubro (2020)*, 1–9. <https://doi.org/10.1109/FIE44824.2020.9274114>
- [32] Toni Taipalus e Piia Perälä. 2019. O que esperar e em que se concentrar no ensino de consultas SQL. Em *SIGCSE 2019 - Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 198–203. <https://doi.org/10.1145/3287324.3287359> [33] Toni Taipalus e Ville Seppänen. 2020. Educação em SQL: um estudo de mapeamento sistemático e agenda de pesquisa futura. *ACM Trans. Comput. Educ.* 20, 3, Artigo 20 (ago. 2020), 33 páginas. <https://doi.org/10.1145/3398377>
- [34] Toni Taipalus e Mikko Siponen. 2018. Erros e complicações na formulação de consultas SQL. *ACM Transactions on Computing Education* 18, 3 (2018), 29 páginas.
- [35] C. Welty. 1985. Corrigindo erros do usuário em SQL. *Relatório técnico*. 463–477 páginas.
- [36] Charles Welty e David W. Stemple. 1981. Comparação de fatores humanos de uma linguagem de consulta procedural e não procedural. *ACM Transactions on Database Systems* 6, 4 (dez 1981), 626–649.
- [37] Jacqueline Whalley e Nadia Kasto. 2014. Um estudo qualitativo de verbalização do pensamento sobre as estratégias de escrita de código de programadores iniciantes. *ITICSE 2014 - Anais da Conferência de Inovação e Tecnologia no Ensino de Ciência da Computação de 2014 (2014)*, 279–284. <https://doi.org/10.1145/2591708.2591762>
- [38] Daniel Zingaro, Cynthia Taylor, Leo Porter, Michael Clancy, Cynthia Lee, Soohyun Nam Liao e Kevin C. Webb. 2018. Identificando dificuldades dos alunos com estruturas de dados básicas. Nos *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação em Computação (Espoo, Finlândia) (ICER '18)*. Association for Computing Machinery, Nova York, NY, EUA, 169–177. <https://doi.org/10.1145/3230977.3231005>