

Usos, revisões e o futuro das avaliações validadas em Educação em Computação: Um Estudo de Caso do FCS1 e do SCS1

Miranda C. Parker
Universidade da Califórnia, Irvine
Irvine, CA, EUA
miranda.parker@uci.edu

Mark Guzdial
Universidade de Michigan
Ann Arbor, Michigan, EUA
mjguz@umich.edu

Allison Elliott Tew, AET
Consulting, Seattle,
Washington, EUA,
allisonetew@gmail.com

RESUMO

Instrumentos validados de conhecimento são importantes para a criação de uma medida aceita e compartilhada para a parte mais importante da educação: a aprendizagem do aluno. O Inventário de Conceitos de Força da Pesquisa em Educação em Física teve um impacto significativo na educação STEM (Ciência, Tecnologia, Engenharia e Matemática). As avaliações Foundational CS1 (FCS1) e Second CS1 (SCS1) foram criadas e validadas para impulsionar a pesquisa em educação computacional. Agora, dez anos após a publicação da avaliação FCS1 e cinco anos após o lançamento da avaliação SCS1, podemos acompanhar o uso e o impacto que esses instrumentos validados tiveram nas necessidades e no conhecimento da comunidade de educação em computação. Neste artigo, examinamos como as avaliações FCS1 e SCS1 foram usadas e adaptadas. Usamos essa discussão para orientar uma comparação entre nossa área e a educação em física, a fim de direcionar pesquisas futuras. Ao analisarmos o uso desses instrumentos validados, podemos compreender melhor nossas necessidades na pesquisa em educação computacional e nossas necessidades futuras em avaliação.

CONCEITOS CCS

• **Temas sociais e profissionais y Avaliação do aluno.**

PALAVRAS-CHAVE

avaliações, CS1, validade

Formato de referência da ACM:

Miranda C. Parker, Mark Guzdial e Allison Elliott Tew. 2021. Usos, revisões e o futuro das avaliações validadas no ensino da computação: um estudo de caso do FCS1 e do SCS1. In *Anais da 17ª Conferência Internacional da ACM sobre Pesquisa em Educação Computacional (ICER 2021)*, 16 a 19 de agosto de 2021, evento virtual, EUA. ACM, Nova York, NY, EUA, 9 páginas. <https://doi.org/10.1145/3446871.3469744>

1 INTRODUÇÃO

Quando o argumento para a validade da avaliação Foundational CS1 (FCS1) foi publicado pela primeira vez em 2011 [65], a comunidade de educação em computação tinha poucos instrumentos validados para o conhecimento em ciência da computação (CS). Inventários de conceitos haviam sido criados para alguns tópicos introdutórios de computação [22, 26, 62]. O primeiro instrumento validado para o conhecimento em CS1 em uma linguagem (Java) é



Esta obra está licenciada sob uma Licença Internacional Creative Commons Atribuição-NãoComercial-Compartilhável 4.0.

ICER 2021, 16 a 19 de agosto de 2021, Evento Virtual, EUA ©
2021 Direitos autorais reservados ao(s) proprietário(s)/autor(es).
ACM ISBN 978-1-4503-8326-4/21/08. <https://doi.org/10.1145/3446871.3469744>

provavelmente de Decker em 2007 [12]. No entanto, o FCS1 foi notável por fornecer uma medida validada de conhecimento em várias linguagens de programação para um curso de ciência da computação de primeiro semestre de graduação (CS1), que sempre foi um foco na pesquisa em educação em computação [49]. Distinguimos aqui entre medidas validadas de conhecimento e medidas validadas de outras variáveis importantes na educação, como atitudes [14].

A FCS1 foi construída utilizando pseudocódigo para os problemas de programação, o que lhe conferiu uma ampla gama de aplicações. A avaliação FCS1 foi criada com a intenção inicial de comparar o aprendizado entre cursos de CS1 ministrados em diferentes linguagens. A avaliação FCS1 baseada em pseudocódigo foi então validada com alunos aprendendo Java, Python e MATLAB. No entanto, a mera existência de uma avaliação CS1 válida não a tornava inerentemente útil para a comunidade. O acesso à avaliação FCS1 foi limitado para evitar a saturação da avaliação, o que enfraqueceria o argumento da validade da FCS1. Em resposta, a avaliação FCS1 foi replicada e validada para criar a Segunda Avaliação CS1 (SCS1) em 2016 [43], que pôde ser distribuída gratuitamente sem o risco de enfraquecer a validação da FCS1. A SCS1, também multilíngue e baseada em pseudocódigo, foi disponibilizada à comunidade de ensino de computação mediante solicitação (em vez de ser disponibilizada publicamente) e tem sido usada pela comunidade em estudos de pesquisa.

Escrevemos este artigo para compreender o impacto e a utilização de um instrumento validado na comunidade de pesquisa em educação computacional. Analisamos o impacto das avaliações FCS1 e SCS1 por meio de trabalhos publicados que citam os artigos originais, destacando como as avaliações foram utilizadas e adaptadas. Embora a FCS1 e a SCS1 sejam apenas duas avaliações validadas, elas servem como exemplos para considerar de forma mais ampla o papel das avaliações na educação em ciência da computação e como as avaliações podem influenciar outros trabalhos.

A questão de pesquisa que esperávamos responder era se o uso do FCS1 e do SCS1 se manteve dentro do argumento de validade que construímos originalmente, ou se alguma das avaliações foi usada para fins além da intenção inicial. Também nos conectamos à visão original do FCS1 e do SCS1 comparando onde a pesquisa em educação em Ciência da Computação está hoje com onde a pesquisa em educação em Física estava, em termos de instrumentos de conhecimento validados. Explicitamente, o SCS1 foi originalmente desenvolvido e distribuído com a esperança de conduzir um estudo em larga escala de métodos para o ensino de computação, como Hake fez com o Force Concept Inventory (FCI) na pesquisa em educação. Concluímos este artigo, com base nas discussões, sugerindo possíveis rumos futuros para a avaliação no ensino da computação, considerando as necessidades atuais da comunidade.

RQ1: Os usos de FCS1 e SCS1 permaneceram dentro dos argumentos originais de validade?

RQ2: Podemos realizar um estudo em larga escala de métodos de CS com base no uso de FCS1 e SCS1?

2 DESENVOLVIMENTO E UTILIZAÇÃO DO FCS1

O FCS1 foi originalmente desenvolvido no contexto do trio de cursos CS1 no Instituto de Tecnologia da Geórgia (Georgia Tech) [19]. A Georgia Tech exigia ciência da computação para todos os seus alunos e descobriu que um único curso não atendia às necessidades de todos os alunos [23]. Ao final, foram oferecidos três cursos diferentes: um em MATLAB para estudantes de Engenharia, um em Python para estudantes de Ciência da Computação e Ciências Exatas, e um curso de Python diferente para estudantes de Humanas, Arquitetura e Administração. Surgiu a questão de como comparar esses cursos, visto que todos são ministrados em linguagens de programação diferentes, mas atendem ao mesmo requisito introdutório de computação. Elliott Tew desenvolveu o FCS1 em pseudocódigo para que pudesse ser usado para comparar o aprendizado em diferentes implementações do CS1 em Java, MATLAB ou Python. Ela escolheu MATLAB e Python devido aos cursos oferecidos no Georgia Tech e incluiu Java por sua popularidade como linguagem para o CS1. Ela validou o teste com estudantes de diversas instituições. Assim, desde o início, o FCS1 foi concebido para atender a um público amplo, que ultrapassasse uma única linguagem de programação e uma única instituição.

O primeiro desafio enfrentado por Elliott Tew foi definir o conteúdo do exame. Não existe um programa comum ou mesmo um conjunto de tópicos para o curso introdutório de Ciência da Computação (CS) nos Estados Unidos ou em todo o mundo. A abordagem mais comum para definir a lista de tópicos para um inventário de conceitos é consultar especialistas [61]. Uma abordagem Delphi estava sendo usada para identificar o conteúdo de um inventário de conceitos para CS1, mas a gama de tópicos era ampla [21]. Ao contrário do FCI no ensino de Física, um inventário de conceitos para CS1 não poderia se basear em décadas de pesquisa sobre as conceitualizações alternativas dos alunos sobre o mundo real. A Ciência da Computação é uma ciência do artificial [56]. Os tópicos de CS1 são inventados e alguns são relativamente novos, com poucos trabalhos empíricos descrevendo as conceitualizações dos alunos. Por exemplo, Elliott Tew tinha pouco conteúdo sobre programação orientada a objetos no FCS1 devido a uma grande variação entre as turmas sobre o que constituía programação orientada a objetos e devido à correspondente falta de literatura explorando as conceitualizações dos alunos sobre diferentes tipos de programação orientada a objetos [63]. Os desenvolvedores do FCS1 precisavam de um conjunto central de conceitos para os quais um conjunto razoável de distratores pudesse ser definido. Elliott Tew usou uma técnica de análise de livros didáticos para definir um conjunto comum de conceitos, que foram então filtrados por meio do uso de padrões curriculares recomendados e, em seguida, revisão de especialistas [64].

Um dos desafios na elaboração de uma questão de múltipla escolha é determinar as alternativas incorretas. A resposta correta é óbvia, mas as respostas incorretas precisam estar suficientemente próximas da resposta correta para permitir a distinção entre diferentes compreensões conceituais. Elliott Tew apresentou os problemas do FCS1 a alunos que estudavam MATLAB, Java e Python como questões abertas, sem opções de resposta. Ela então selecionou as respostas incorretas mais frequentes como alternativas incorretas. Elliott Tew descobriu que as respostas incorretas mais comuns eram praticamente as mesmas nas três linguagens [63]. Algumas das respostas incorretas foram facilmente explicadas por características específicas de cada linguagem; por exemplo, o pseudocódigo de Elliott Tew utilizava indexação de arrays baseada em zero (como em Python e Java), o que foi uma fonte de erro para os

Tabela 1: Pontuações médias na avaliação FCS1 por quartil. Reproduzido de [63] com permissão.

Quartil	n	Média	ȳ	ȳ
4	203	2.31	3,649	
3	231	3.76	3,313	
2	226	4.81	3,495	
1	190	6.20	3,671	

que aprenderam MATLAB em seu primeiro curso de Ciência da Computação (já que o MATLAB indexa arrays a partir de um). A similaridade de erros entre linguagens também é uma descoberta interessante que merece investigação adicional – a existência de uma similaridade em conceitualizações alternativas em diferentes contextos de linguagens de programação.

O argumento para a validade do FCS1 teve três partes [64]. Primeiro, um painel de especialistas revisou o conteúdo para chegar a um consenso de que os conceitos abordados faziam parte de um curso de Introdução à Ciência da Computação (CS1). Em seguida, ela aplicou duas provas a todos os alunos participantes do CS1: uma na linguagem que haviam estudado (Java, MATLAB ou Python) e outra em pseudocódigo. Os problemas foram elaborados para serem isomórficos, e as provas foram aplicadas com um intervalo de tempo e contrabalançadas para controlar os efeitos da ordem de aplicação. Ela buscou uma correlação entre a avaliação em pseudocódigo e a avaliação na linguagem "nativa", para validar se o pseudocódigo mensurava os mesmos conceitos que a linguagem estudada. Por fim, ela coletou as notas finais dos alunos do CS1 para validar se a avaliação em pseudocódigo estava testando o que os instrutores do CS1 valorizavam.

2.1 O uso do FCS1

O principal uso do FCS1 foi na dissertação de Elliott Tew [63]. Ela descobriu que o desempenho no FCS1 diferia entre os três cursos de CS1 da Georgia Tech. Ela também descobriu que o uso de pseudocódigo tinha um custo . Os alunos que obtiveram as melhores pontuações na avaliação de pseudocódigo apresentaram a maior similaridade entre as pontuações na avaliação de pseudocódigo e na avaliação específica da linguagem — com uma diferença média de 2,31 respostas em 27 questões nas provas (ver Tabela 1). Mas a diferença média aumenta drasticamente. Para os dois quartis inferiores, a diferença é de 17% (4,8 questões em 27) e 22% (6,2 questões em 27). Não é muito difícil para os alunos do quartil de melhor desempenho transferir seu conhecimento para o pseudocódigo, mas é um desafio significativo para os dois quartis de pior desempenho.

O FCS1 também foi usado no Grupo de Trabalho ITiCSE de 2013 [69], que revisitou o influente relatório do Grupo de Trabalho McCracken de 2001 [41]. O relatório do Grupo de Trabalho McCracken de 2001 foi um dos primeiros estudos a mostrar que os problemas com a aprendizagem de programação em CS1 eram um fenômeno generalizado, observado em várias instituições em vários países [41]. O estudo de 2013 replicou a descoberta original e usou o FCS1 como uma medida de conhecimento conceitual. As pontuações no FCS1 foram fortemente correlacionadas positivamente com a capacidade de programar com sucesso [69]. Houve outros usos não publicados do FCS1 para examinar a eficácia de intervenções de aprendizagem. Estudos que compararam estratégias de ensino na Universidade da Colúmbia Britânica, no contexto da Iniciativa Carl Wieman para o Ensino de Ciências (CWSEI), utilizaram o FCS1 para

Estabelecer uma base de referência e fazer comparações. O objetivo do projeto CWSEI era aprimorar o ensino e a aprendizagem dos alunos no contexto local específico. Como esses resultados não podem ser generalizados para um contexto mais amplo, eles permanecem inéditos.

Devido a preocupações com a possibilidade de o FCS1 ser invalidado por meio de ampla disseminação (por exemplo, sendo publicado publicamente na Internet), houve poucos usos diretos do FCS1 por estudantes. No entanto, o FCS1 foi usado com sucesso como modelo para a criação de outras avaliações. Por exemplo, Lee e Ko [38] criaram uma avaliação em pseudocódigo para medir a aprendizagem em diferentes contextos de aprendizagem online, desde jogos a tutoriais. Eles usaram os exemplos, descrições e o guia de pseudocódigo de duas páginas do FCS1 para gerar seu exame. Validaram seu instrumento replicado usando trabalhadores do Amazon Mechanical Turk e, em seguida, usaram seu instrumento para comparar vários cenários diferentes.

Não incluímos uma análise mais aprofundada da literatura, visto que muitas das citações de qualquer um dos artigos sobre o FCS1 [63–65] o referenciam como um exemplo de uma medida validada de conhecimento para o CS1. Em vez de uma busca sistemática na literatura, incluímos aqui todos os usos legais do FCS1. Trata-se de todos os estudos sobre o FCS1 cujos autores solicitaram acesso por meio dos criadores do FCS1.

3 DESENVOLVIMENTO E UTILIZAÇÃO DO SCS1

Para proteger o FCS1 e ainda ter um instrumento disponível para a comunidade, o SCS1 foi criado como uma réplica do FCS1 que poderia ser distribuída sem comprometer potencialmente o FCS1 [43]. O SCS1 teve um processo de replicação e validação mais simples.

Em vez de comparar com testes isomórficos em Java, MATLAB e Python, o SCS1 é um teste baseado em pseudocódigo que foi validado apenas em relação ao FCS1. Próximo ao final dos cursos introdutórios de computação em uma instituição, 183 alunos fizeram o SCS1 e o FCS1, com uma semana de intervalo e contrabalançados para efeitos de ordem. A correlação entre o SCS1 e o FCS1 foi alta e suficiente para estabelecer um argumento de validade. No entanto, como o SCS1 foi criado a partir de questões isomórficas ao FCS1 para manter o argumento de validade deste último, poucas alterações foram feitas para modificar ou aprimorar o FCS1. Consequentemente, a dificuldade anterior da avaliação FCS1, conforme apresentada em [63], foi transferida para o SCS1. A dificuldade e a discriminação de cada item do SCS1 podem ser vistas na Tabela 2, onde 22 itens foram identificados como “difíceis” e nenhum item foi identificado como “fácil”.

3.1 A utilização do SCS1

No artigo original que detalha a replicação e validação da avaliação SCS1, Parker et al. incentivaram o uso livre e aberto de sua avaliação. Desde então, a avaliação SCS1 tem sido usada em muitos estudos de pesquisa de inúmeras maneiras. Para entender o uso e a evolução da avaliação SCS1, realizamos uma busca no Google Acadêmico no início de janeiro de 2021 por artigos que citam a publicação SCS1 [43]. Nossa busca retornou 70 artigos, que lemos e registramos como eles usaram a SCS1 ou citaram a publicação original. Nossa abordagem envia nossa compreensão de como a SCS1 está sendo usada, uma vez que examinamos apenas trabalhos publicados ou dissertações. O viés de publicação é um problema persistente em qualquer revisão de literatura [18]. Também reconhecemos as limitações de usar um banco de dados de pesquisa em um determinado momento. Por exemplo,

Devido à forma como o Google Acadêmico indexa artigos, alguns artigos que ainda não haviam sido publicados formalmente (por exemplo, SIGCSE 2021) foram incluídos em nossa análise se versões preliminares dos artigos tivessem sido disponibilizadas nos sites dos autores e indexadas pelo Google Acadêmico. Artigos que mencionavam o SCS1 apenas brevemente foram excluídos de nossa análise. Isso inclui 13 artigos que citam o SCS1 como um exemplo de avaliação em Ciência da Computação com argumentos a favor de sua validade; seis artigos que fazem referência ao SCS1 na seção de trabalhos relacionados, geralmente como um exemplo de trabalho sendo realizado na área de educação em Ciência da Computação; dois artigos que utilizam o artigo do SCS1 para fundamentar argumentos sobre a confiabilidade e a validade de avaliações; e dois artigos que utilizam partes do artigo do SCS1, mas não a avaliação em si (por exemplo, o gráfico de dispersão foi reproduzido em [24] e os métodos de verbalização do pensamento foram utilizados em [29]). Além disso, três artigos utilizaram a avaliação do SCS1 para criar um novo instrumento, mas o processo não foi descrito com detalhes suficientes para ser incluído em nossa discussão. A seguir, detalhamos algumas das diferentes maneiras pelas quais a avaliação SCS1 tem sido utilizada na comunidade de ensino de computação. Um resumo dessas descobertas pode ser e

3.1.1 Para aprender sobre aprendizagem. Os criadores da avaliação SCS1 escreveram que incentivavam a comunidade de pesquisa a usar a avaliação SCS1 para medir o desempenho ou os ganhos de aprendizagem [43]. Muitos estudos foram publicados desde então usando a avaliação SCS1 exatamente dessa maneira [5, 31–33, 42, 75, 76]. Aqui, detalhamos esses estudos e as descobertas que a avaliação SCS1 ajudou a comprovar.

Uma área de estudo que frequentemente utiliza a avaliação SCS1 é o tópico de rastreamento de programas. Em um estudo, a avaliação SCS1 foi usada para demonstrar suporte a uma pedagogia de rastreamento de programas centrada na compreensão e fundamentada teoricamente, por meio de um tutorial interativo chamado PLTutor [42]. Nesse estudo, alunos de graduação foram recrutados no início de um curso de Introdução à Ciência da Computação (CS1) em Java. Além disso, algumas questões da avaliação SCS1 foram utilizadas em um pré e pós-teste em um estudo que demonstrou que o ensino de uma estratégia de rastreamento de programas aos alunos pode levar a notas mais altas em problemas de rastreamento de programas e na prova intermediária do curso [76]. Foram recrutados 24 alunos que haviam concluído um ou menos cursos de Ciência da Computação, todos de graduação, com exceção de um que possuía mestrado.

A avaliação SCS1 também foi utilizada para investigar ambientes e ferramentas de aprendizagem online [31–33, 75]. A avaliação SCS1 foi usada para demonstrar que alunos de graduação online podem alcançar resultados de aprendizagem comparáveis aos de alunos em ambientes de aprendizagem presenciais tradicionais [32]. De fato, entre os alunos que relataram ter se esforçado ao máximo para realizar a avaliação SCS1, os alunos do curso CS1 online obtiveram pontuações estatisticamente significativamente mais altas no SCS1 como pós-teste do que os alunos da turma presencial [32]. Esses resultados foram replicados em um estudo posterior com novos alunos [33]. Além disso, esses resultados continuam válidos quando o curso CS1 online é apoiado por uma IA para feedback e avaliação [31]. Questões da avaliação SCS1 também foram usadas para investigar uma ferramenta de aprendizagem autodirigida de Python online. Em um estudo com 79 programadores iniciantes (definidos como aqueles que tiveram, no máximo, um curso de programação que não fosse Python e nunca aprenderam ou usaram Python), os resultados apoiaram a afirmação de que mais autonomia e informação podem levar a uma maior motivação do aluno, mas não necessariamente a uma melhor aprendizagem [75].

Tabela 2: Classificações da teoria de resposta ao item das questões SCS1. Reproduzido de [43] com permissão.

		Dificuldade (0-100%)			Total
		Difícil (0-50%)	Moderado (50-85%)	Fácil (85-100%)	
Discriminação	Ruim (<0,1)	5, 8, 15, 18, 20, 24, 27 –		–	7 itens
	Regular (0,1-0,3)	4,6,7,9,10,11,12,13,16, 23		–	15 itens
		17,21,22,25,26			
	Bom (>0,3)	14	1, 2, 3, 19	–	5 itens
	Total	22 itens	5 itens	0 itens	27 itens

Tabela 3: Um resumo das formas como o FCS1 e o SCS1 foram utilizados e os artigos correspondentes.

Para aprender sobre aprendizagem	Diferenças na linguagem de programação FCS1 [63] Grupo de Trabalho ITICSE 2013 [69]	
	Rastreamento do programa SCS1: [42, 76] Aprendizagem online: [31–33, 75] Comparação entre modelos baseados em blocos e modelos baseados em texto: [5]	
Para construir instrumentos mais válidos FCS1 Gidget	[38] SCS1 [43]	
	Instrumento de Autoavaliação SCS1 (SEI): [15] Inventário de Estruturas de Dados Básicas (BDSI): [48, 61, 77]	
Melhorando	SCS1	Teoria da Resposta ao Item: [74]
Adaptação		Subconjunto de 12 perguntas: [45] 9 subconjunto de perguntas: [6] (SCS1R)
Traduzindo		Java: [17] Python: [37] (mSCS1), [58] MATLAB: [2, 3] (MCS1) Alemão: [66, 67] Finlandês: [15]

Com o surgimento de ambientes de programação baseados em blocos, surgiram questionamentos sobre como a programação baseada em blocos e Comparação entre programação baseada em blocos e programação baseada em texto (programação de modalidade dupla) com programação baseada em texto. um estudo comparando ambientes de programação de dupla modalidade e instrução com abordagens de ensino baseadas em texto, participante A aprendizagem foi medida através da avaliação SCS1 e dos exames do curso. para 673 alunos de graduação em um curso CS1 de um semestre [5]. O Um estudo descobriu que os alunos tiveram um melhor desempenho nas provas do curso quando Eles foram ensinados usando representações de dupla modalidade e foram forneceram ferramentas de dupla modalidade. No entanto, as pontuações não foram estatisticamente diferentes na avaliação SCS1, possivelmente devido a às perguntas difíceis e à falta de opções de resposta livre.

3.1.2 Construir mais instrumentos de aprendizagem de informática. Muitos dos Trabalhos publicados que citam o artigo seminal SCS1 o utilizam como base para fundamentação. seus argumentos para mais avaliações [4, 13, 16, 35, 36, 39, 46], citando a frase “não existem muitos instrumentos válidos para CS1” [43]. No entanto, como apontam Margulieux et al., existem múltiplas avaliações de medição padronizadas por computação [40]. Nem todas estas As avaliações buscam mensurar o conhecimento em computação, assim como algumas medem a autoeficácia, as atitudes em relação à programação ou a carga cognitiva, para citar alguns exemplos. algumas. A afirmação de que sempre pode haver mais instrumentos de avaliação padronizados em computação talvez seja uma afirmação mais forte. do que dizer que “não existem muitos” instrumentos desse tipo. Movendo

além das declarações da comunidade que necessitam de mais padronização avaliações, alguns grupos embarcaram na empreitada de criar Instrumentos de avaliação totalmente novos com questões do SCS1 avaliação e o processo descrito na publicação SCS1 [43], como inspiração.

Recomenda-se que a avaliação SCS1 leve uma hora para ser concluída. completo e apresenta questões difíceis que foram identificadas na fase inicial. processo de validação. Esses fatores podem tornar a avaliação inacessível para muitos estudantes e pesquisadores. Em um esforço para criar um ambiente mais Duran et al. criaram uma avaliação leve e menos intrusiva. o SEI (instrumento de autoavaliação) para avaliar rapidamente a compreensão dos alunos sobre conhecimentos básicos de programação [15]. Duran et al. utilizaram a avaliação SCS1, após traduzi-la para finlandês, para criar uma Argumento a favor da validade do SEI. Recrutado de um curso básico de Ciência da Computação. Ministrado em Java e oferecido como um MOOC, o curso foi concluído por 440 alunos. SCS1 finlandês. Os alunos eram mais propensos a se voluntariar para fazer o SEI. do que a avaliação SCS1, e os alunos forneceram feedback negativo. para a avaliação SCS1 com mais frequência do que para a SEI. No entanto, ambas As pontuações no SEI e na avaliação SCS1 correlacionaram-se com o exame do curso. Os pesquisadores também descobriram que algumas perguntas que foram difíceis para estudantes em outros estudos e contextos (por exemplo, [74]) eram fáceis para os alunos, e outras questões que eram fáceis. Para outros, foi difícil, sugerindo um caminho para o futuro. Pesquisa sobre avaliações em computação. O protótipo SEI pode ser

Encontrado em <https://goo.gl/nGR9Th>.

O Inventário de Estruturas de Dados Básicas (BDSI) foi criado como um inventário conceitual para abranger tópicos tipicamente incluídos em um curso CS2, ou seja, o curso que ensina estruturas de dados básicas [77]. A avaliação SCS1 não foi usada diretamente para a criação do BDSI, uma vez que a SCS1 foi destinada a cursos CS1 e, portanto, a um conjunto diferente de conceitos. No entanto, o pseudocódigo em que se baseia a avaliação SCS1 foi utilizado para o BDSI [77]. Além disso, o BDSI foi criado seguindo etapas semelhantes às do FCS1 e do SCS1, incluindo painéis de especialistas, questões de resposta curta que foram posteriormente convertidas em questões de múltipla escolha, entrevistas de validação e validação estatística, incluindo teoria clássica de testes e confiabilidade [48, 61]. O BDSI está disponível em <https://groups.google.com/forum/#!forum/cs2-inventário-de-conceitos-bdsi>.

4. ADAPTAÇÃO E REVISÃO DE UM VALIDADO

AValiação

Quando a avaliação SCS1 foi disponibilizada à comunidade, Parker et al. concluíram seu artigo com um apelo por mais avaliações, incluindo a revisão da avaliação SCS1 [43]. Nos últimos cinco anos, a avaliação SCS1 foi investigada, revisada e adaptada para um uso mais amplo. Parte da necessidade de revisão se deve à dificuldade da avaliação SCS1, conforme discutido anteriormente e apresentado na Tabela 2. Esse nível de dificuldade é apontado por alguns pesquisadores da comunidade como um motivo para não utilizar a avaliação [28]. Consequentemente, muitas equipes de pesquisa têm buscado aprimorar a avaliação SCS1 para um uso mais amplo pela comunidade.

4.1 Aprimorando o SCS1

Desde o lançamento da avaliação SCS1 para a comunidade, um grupo de pesquisa da Universidade de Washington conduziu análises adicionais sobre a avaliação SCS1 para identificar questões específicas que poderiam ser aprimoradas. Enquanto o artigo original do SCS1 incluía a Teoria Clássica dos Testes, Xie et al. utilizaram a Teoria da Resposta ao Item para identificar questões problemáticas [74]. Xie et al. utilizaram respostas do SCS1 de 425 alunos do pré-CS1 e 64 alunos do pré-CS2. Seu trabalho pode ajudar a identificar em quais questões focar para aprimorar a avaliação SCS1 como um todo. Xie et al. também concluem que a avaliação SCS1 pode ser melhor utilizada como um pós-teste e inadequada para uso como um pré-teste devido à sua dificuldade e potenciais efeitos de piso. Isso levou alguns estudos a se absterem de usar a avaliação SCS1 devido a preocupações com sua adequação como um pré-teste administrado antes de uma experiência de aprendizagem de Ciência da Computação [57, 70]. Essa não é uma categorização injusta do SCS1, especialmente considerando que ele não foi explicitamente projetado para ser usado como um pré-teste. Em vez disso, foi projetado como o FCS1: para ser usado para comparar diferentes turmas de CS1 com diferentes linguagens de programação. Embora o SCS1 seja conveniente para uso como pré e pós-teste, porque a pontuação está na mesma escala, facilitando a percepção de crescimento ou melhoria nos conceitos de CS1, mais trabalho deve ser feito para alterar o SCS1 ou criar um pré-teste complementar ao pós-teste do SCS1.

4.2 Redução da duração do SCS1

A avaliação original do SCS1 era administrada em um período de 60 minutos [43]. No entanto, esse tempo pode ser muito longo para uma aula, que normalmente dura 50 minutos. Isso, aliado ao reconhecimento de que se trata de uma avaliação difícil, pode reduzir a duração do SCS1.

viabilidade da avaliação SCS1 como ferramenta de pesquisa. Como tal, houve vários esforços para encurtar a avaliação SCS1 [6, 17, 45].

Parker e Guzdial, os criadores originais da avaliação SCS1, modificaram a própria SCS1, reduzindo-a de 27 para 12 questões [45]. As questões foram escolhidas com base em seus valores originais de dificuldade e discriminação, publicados [43]. O formato original da avaliação foi mantido, com três tipos de questões (definicionais, de rastreamento e de preenchimento de código), cada uma referente a uma das quatro áreas de conteúdo (instrução if, laços for, laços while e operadores lógicos). Esse esforço foi empreendido porque a avaliação SCS1 adaptada era apenas uma parte do estudo, no qual os autores solicitaram a estudantes de graduação, perto do final do primeiro curso de computação, que também respondessem a um questionário sobre acesso à computação, um teste de raciocínio espacial e um questionário sobre nível socioeconômico [45]. Os resultados do estudo mostraram uma relação entre o nível socioeconômico e o desempenho em Ciência da Computação (medido pela avaliação SCS1 adaptada), mediada pela habilidade espacial e não pelo acesso à computação.

Um grupo de pesquisa da Universidade de Nebraska-Lincoln também publicou um trabalho que utilizou uma versão reduzida da avaliação SCS1 [6–8]. A avaliação SCS1 revisada (denominada 'SCS1R') foi criada mantendo o conteúdo original da avaliação, em vez do formato dos tipos de questões [6]. Uma questão foi selecionada para cada um dos nove conceitos, a fim de tentar manter o teste com um máximo de 20 minutos. Para escolher qual questão representaria uma área de conteúdo, os autores afirmam que 'selecionaram a questão que consideramos mais adequada para o nosso estudo' [6]. Bockmon et al. recrutaram 635 alunos de graduação em cursos introdutórios de computação para testar a SCS1R. A equipe de pesquisa utilizou a SCS1R para aprofundar a conexão entre habilidades espaciais e ciência da computação, como, por exemplo, como o treinamento em habilidades espaciais pode melhorar o desempenho e o prazer em ciência da computação (n=197 alunos de graduação de CS1) [8] e conectar habilidades espaciais com a capacidade de programação (274 participantes do grupo de controle, 71 participantes do grupo experimental, todos de um curso de graduação de CS1) [7].

4.3 Traduzindo o SCS1

Um elemento crítico do design das avaliações FCS1 e SCS1 foi a linguagem de pseudocódigo em que foram escritas. Como as avaliações foram projetadas para serem usadas em cursos usando diferentes linguagens de programação, as avaliações não poderiam ser escritas em uma linguagem de programação específica [63], como discutido anteriormente.

Apesar do objetivo de criar uma avaliação que pudesse ser usada por uma grande variedade de alunos aprendendo diferentes linguagens, muitas equipes de pesquisa optaram por replicar a avaliação SCS1 em linguagens de programação específicas [2, 3, 17, 37, 58]. Em um caso, a motivação para abandonar a avaliação baseada em pseudocódigo foi a falta de intuitividade do pseudocódigo e as preocupações levantadas sobre sobrecarregar os alunos com a interpretação de uma pseudolinguagem, o que foi discutido como uma preocupação com os resultados dos estudos de validação do FCS1 [37]. Nesse caso, a avaliação SCS1 foi traduzida para Python, além de ser encurtada por questões de tempo e alinhamento de conteúdo, e aplicada a 44 alunos de graduação no início de um curso de CS2 baseado em Python. Layman et al. encontraram uma correlação entre sua versão do SCS1 (mSCS1; SCS1 modificado) e o desempenho em CS2 [37]. Outras equipes de pesquisa adotaram uma abordagem semelhante, traduzindo um subconjunto

avaliação em Python, embora também adicionando 127 questões curtas de prática deliberada, para uso em uma avaliação pré-CS2 [58]. Outro caso optou por traduzir algumas questões das questões SCS1 para Java para uso com 42 alunos em um curso CS1 ministrado em Java [17]. Duvall et al. mencionaram que a linguagem de pseudocódigo era muito semelhante ao Python e que seus alunos tiveram dificuldade em entender as perguntas. Em outro caso, a avaliação SCS1 foi traduzida para MATLAB para fornecer um inventário de conceitos específico para MATLAB (MCS1; Avaliação de Ciência da Computação 1 em MATLAB) [2, 3]. O MCS1 foi testado durante entrevistas de verbalização do pensamento com seis alunos do primeiro ano de engenharia.

A avaliação SCS1 é um ponto de partida razoável para o desenvolvimento de ferramentas específicas para cada idioma, dados os argumentos de validade que a sustentam. A criação de avaliações específicas para cada idioma também deve incluir erros e concepções errôneas específicas de cada idioma [60]. Weintrop e Wilensky descobriram, com sua avaliação comutativa, que a programação em blocos e em texto levava a diferentes erros e concepções errôneas [73]. Elliott Tew encontrou alguns desses problemas em sua validação do FCS1, mas projetou o FCS1 explicitamente levando-os em consideração, concentrando-se nas características comuns em vez das questões específicas de cada idioma [64]. Uma ferramenta específica para um idioma poderia partir do SCS1 para validação, mas teria que desenvolver diferentes elementos de distração que destacassem os desafios de aprendizagem específicos de cada idioma.

Além da tradução da avaliação SCS1 para diferentes linguagens de programação, também houve esforços para traduzi-la para outros idiomas além do inglês. Uma equipe de pesquisa na Alemanha detalhou os passos que seguiu para traduzir a SCS1 para o alemão [66, 67]. Timmerman et al. então usaram a tradução alemã da SCS1 para monitorar o aprendizado dos alunos em um curso de CS1 à medida que o curso era revisado. Uma equipe na Finlândia seguiu os passos de Timmerman et al. e traduziu a SCS1 para o finlandês [15]. Esta tradução foi então usada para criar o SEI, descrito na Seção 3.1.2. Pode haver ainda mais traduções da SCS1 para outros idiomas, dado o uso da SCS1 em todo o mundo, mas estes são os únicos exemplos publicados até o momento em que realizamos nossa busca no Google Acadêmico.

5. Comparando o uso da avaliação em

DA EDUCAÇÃO EM COMPUTAÇÃO À FÍSICA EDUCAÇÃO

O Inventário de Conceitos de Força (FCI, na sigla em inglês) teve um impacto dramático no ensino de física e muito além. Aqui, discutimos artigos importantes no desenvolvimento e uso do FCI, a fim de compará-los e contrastá-los com o desenvolvimento e uso do FCS1 e do SCS1. Não realizamos uma revisão sistemática da literatura sobre o FCI, mas consideramos um dos objetivos originais do SCS1, que era realizar uma análise semelhante à feita por Hake.

O FCI era um instrumento validado que se concentrava exclusivamente em conceitos de força a partir de uma perspectiva introdutória de física [27]. Destacava-se por se basear no conhecimento das concepções alternativas de força dos alunos. Elliott Tew teve que desenvolver um processo para identificar boas alternativas incorretas para seu instrumento FCS1. Hestenes e seus colegas puderam recorrer a décadas de pesquisa que lhes mostraram como os alunos explicavam a força para si mesmos de forma incorreta. Sabia-se que as respostas erradas no FCI eram comuns entre os alunos.

Diretamente, o FCI levou a uma descoberta significativa no desenvolvimento do argumento a favor de métodos de pesquisa baseados em evidências. O artigo de Hake, de 1998, utilizou dados de mais de 6.000 participantes para argumentar que técnicas de aprendizagem ativa (na época, o termo usado era "aprendizagem interativa") levavam a melhores resultados de aprendizagem [25]. Hake coletou as respostas dos alunos ao FCI antes e depois dos cursos (pré e pós) em um repositório central, juntamente com dados sobre os cursos nos quais os participantes estavam matriculados¹. Usando esse repositório central, ele pôde fazer uma afirmação abrangente que influenciou o ensino de física e também desenvolver um argumento mais amplo sobre técnicas de aprendizagem ativa em aulas de STEM (Ciência, Tecnologia, Engenharia e Matemática). Hake tinha dados sobre cada aplicação do FCI e relatou separadamente os resultados de escolas de ensino médio, faculdades e universidades.

Indiretamente, o FCI influenciou o desenvolvimento de novas técnicas de aprendizagem ativa, como a instrução por pares. Eric Mazur, notoriamente, aplicou o FCI aos seus alunos em Harvard, esperando que eles tivessem um ótimo desempenho. Quando seus alunos tiveram um desempenho pior do que o esperado, ele percebeu que precisava aprimorar seu próprio ensino – um instrumento validado havia demonstrado o que seus alunos estavam realmente aprendendo [9]. Mazur inventou a instrução por pares como uma forma de melhorar o desempenho de seus alunos no FCI [10]. A instrução por pares agora se expandiu muito além da física e é uma das técnicas de aprendizagem ativa de maior sucesso também na ciência da computação [47].

Quando a validação da avaliação SCS1 foi publicada inicialmente, os autores escreveram uma visão intitulada "Seguindo o exemplo de Hake". Parker et al. propuseram que sua avaliação poderia ser usada em um estudo em larga escala para determinar a eficácia de intervenções de aprendizagem. No entanto, embora a avaliação SCS1 tenha sido aplicada muitas vezes, é improvável que um estudo "Hake" seja desenvolvido em breve, o que responde à nossa pergunta de pesquisa 2 (RQ2). Parte disso se deve ao contexto em que a SCS1 é aplicada. A SCS1 tem sido usada em diversos ambientes de aprendizagem para responder a uma infinidade de questões de pesquisa. Embora todos esses pontos de dados pudessem ser agrupados para analisar a avaliação em larga escala, a grande variedade de variáveis que se confundem com cada ponto de dados tornaria questionáveis quaisquer conclusões derivadas de tal análise.

No fim, os criadores do SCS1 optaram por não seguir a linha de raciocínio de Hake, e essa decisão pode revelar algo profundo e interessante sobre a diferença entre a pesquisa em ensino de computação e a pesquisa em ensino de física. O trabalho de Hestenes, Hake, Mazur e outros em torno do FCI ocorreu em cursos introdutórios de física no ensino superior nos Estados Unidos. Considerando a faixa etária de adolescentes a jovens adultos apenas nos Estados Unidos, aqueles que frequentam aulas de física no ensino superior representam um subconjunto restrito. Além disso, o FCI (como o nome sugere) trata apenas de força. Não visa abranger todo o conteúdo de um curso introdutório de física. Trata de um tópico específico da física introdutória, um tópico amplamente considerado fundamental. Em contraste, o SCS1 já foi utilizado em uma gama muito mais ampla de aulas e contextos do que o FCI, conforme refletido no estudo de Hake. A variação no SCS1 é grande demais para ser ignorada, e seu uso em contextos diretamente comparáveis é insuficiente para viabilizar uma análise semelhante à de Hake.

¹A partir do pedido de acesso ao FCI, "nome e instituição do instrutor, número de alunos matriculados, pontuações pré/pós-teste, desvios padrão quando disponíveis e ganhos normalizados" e, em seguida, por meio de pesquisa de acompanhamento, "método de pré/pós-teste; resultados estatísticos; instituição; tipo de alunos; atividades dos alunos; e experiência educacional, perspectiva, crenças, orientação, recursos e métodos de ensino do instrutor" [25]

6. DISCUSSÃO: NECESSIDADES DA COMUNIDADE E

O FUTURO DA AVALIAÇÃO EM EDUCAÇÃO EM COMPUTAÇÃO

Os argumentos a favor do ensino da computação variam em todo o mundo. Os estados dos Estados Unidos (frequentemente associados ao movimento "CS for All") tendem a apresentar um argumento vocacional [71]. Há escassez de mão de obra em computação, ciência da computação e desenvolvimento de software. O argumento é ensinar ciência da computação a todos para preencher essas vagas. O movimento "Computing at School" (CAS) no Reino Unido argumenta que a computação é um campo fundamental, como a física e a matemática [30].

Da mesma forma que todos deveriam ter algum conhecimento da ciência do mundo físico (por exemplo, física, química e biologia), o movimento CAS defende que os alunos também devem aprender sobre a ciência do mundo digital.

Se os objetivos variam, então podemos esperar que o ensino também varie. Um curso que prepara os alunos para o mercado de trabalho pode ser bem diferente de um curso que ensina ciência da computação introdutória como uma ciência.

Nos Estados Unidos, essa distinção pode ser observada ao comparar o exame e o curso Advanced Placement para "CS A" (APCSA), que visa preparar os alunos para CS1 em um currículo de graduação em Ciência da Computação, e o exame e o curso para "CS Principles" (APCSP), que visa ser uma ampla introdução ao campo da ciência da computação [1]. O ensino com diferentes objetivos de aprendizagem provavelmente será mais adequado.

variár.

Se os cursos variam significativamente, então podemos esperar que o perfil dos alunos e o sucesso neles também variem. Observamos isso em A distinção entre APCSA e APCSP. O APCSP atrai alunos mais diversos do que o APCSA, e os alunos do APCSP têm resultados diferentes [54]. Cursos diferentes com objetivos de aprendizagem diferentes provavelmente atrairão alunos diferentes e certamente exigirão avaliações diferentes. Avaliações diferentes são necessárias não apenas devido ao conteúdo do curso, mas também para promover a equidade entre as populações estudantis. Os métodos de Funcionamento Diferencial do Item não foram usados com o FCS1 nem com o SCS1, mas deveriam ser para entender como diferentes grupos de alunos se saem nas avaliações [11]. A construção de cursos e currículos para promover a equidade só funcionará se as avaliações para medir a aprendizagem e o desempenho também forem atualizadas para apoiar as metas de equidade.

Para responder à nossa primeira questão de pesquisa (RQ1), sobre como o uso do FCS1 e do SCS1 corresponde aos argumentos de validade utilizados em seu desenvolvimento, constatamos que o FCS1 e o SCS1 têm sido usados para avaliar cursos introdutórios de ciência da computação em geral e, mais especificamente, para avaliar cursos introdutórios de programação. Esses objetivos de avaliação são mais amplos do que os argumentos de validação do FCS1 e do SCS1. Ambos os instrumentos fazem apenas perguntas sobre conceitos de programação, pois esse era o denominador comum que Elliott Tew encontrou.

quando ela analisou os livros didáticos e padrões de CS1 [64]. FCS1 e SCS1 foram validados apenas com alunos de graduação em Ciência da Computação que frequentavam aulas presenciais em ambientes universitários residenciais. Embora várias instituições e cursos tenham participado dos estudos de validação, todos os cursos se dirigiram a um segmento restrito da população em um contexto específico.

Na maioria dos estudos publicados, o FCS1 e o SCS1 estão sendo usados em ambientes universitários residenciais em torno de um curso de CS1 ministrado em Python ou Java – portanto, nossa resposta à RQ1 é "na maioria dos casos". No entanto,

O SCS1 também está sendo usado com públicos e contextos para os quais não há argumentos de validade [34]. Isso se mostrou verdadeiro mesmo quando o SCS1 foi publicado e casos de uso foram apresentados, incluindo o uso do SCS1 com professores [43]. Também notamos que o SCS1 está sendo usado em trabalhos publicados em ambientes online ou no CS2, ambientes diferentes daquele em que o SCS1 foi validado.

A revisão se limita a artigos publicados. O SCS1 e o FCS1 podem ser usados com professores em formação, com alunos do ensino fundamental e médio, com linguagens diferentes dessas três, em cursos introdutórios cujos objetivos (e instrução) sejam diferentes do CS1, ou em contextos de modalidade diferentes de aulas presenciais em faculdades residenciais. O FCS1 e o SCS1 foram desenvolvidos como avaliações multilíngues, mas as linguagens escolhidas foram relativamente semelhantes em comparação com linguagens para programação funcional ou programação lógica declarativa. Não podemos afirmar a validade além dessas linguagens imperativas. Embora pesquisadores possam usar o FCS1 e o SCS1 em um contexto diferente do CS1 em uma faculdade residencial com essas três linguagens de programação, o argumento da validade precisa ser feito. O objetivo principal de uma avaliação validada é estabelecer uma medida comumente aceita.

Se não houver argumentos que justifiquem o uso dessa medida em um determinado contexto de pesquisa, a comunidade de pesquisadores da área de educação em computação não tem motivos para aceitar os resultados.

Pesquisadores que utilizam o FCS1 ou o SCS1 em contextos de pesquisa inovadores

Pode-se estar tratando "programação" como um tópico ou unidade conceitual isolada, como "força" na FCI. É improvável que programação seja um conceito unitário, que "programação" seja um conjunto único de conceitos ou habilidades que possamos avaliar. Temos ampla evidência de que a transferência entre linguagens de programação é difícil [55, 68]. Quão mais complicada essa transferência pode ser se as aulas em que ensinamos programação tiverem objetivos, públicos-alvo, níveis e modalidades diferentes? Programação significa coisas diferentes em contextos diferentes. Programação em APCSA é diferente de programação em APCSP.

O FCS1 e o SCS1 ainda são úteis para pesquisadores da área de informática educacional quando usados em contextos para os quais foram validados. Eles também podem ser úteis como modelos para outras avaliações; por exemplo, o desempenho nas novas avaliações pode ser comparado ao desempenho no FCS1 e no SCS1, como vemos em vários dos artigos publicados.

O SCS1 também pode ser validado para novos contextos, como em novos idiomas. Mas é bastante claro que os pesquisadores de educação em computação podem querer avaliar a aprendizagem em outras áreas relacionadas ao grande conceito de programação e avaliar outros aspectos importantes de sua experiência educacional, desde o senso de pertencimento [14, 72] até a autoeficácia [50, 59].

Uma lição final da FCI é que FCS1 e SCS1 estão em um nível dramaticamente diferente. granularidade diferente. Força é uma parte de um curso de física. CS1 é um curso inteiro com muitas partes. A comunidade de pesquisa em educação computacional poderia se beneficiar de inventários de conceitos mais detalhados. Poderíamos nos concentrar em instruções de programação, como if e for, embora pesquisas anteriores sugiram que elas não funcionam como unidades de conhecimento [53]. Poderíamos, em vez disso, nos concentrar em unidades conceituais, como testes condicionais, expressões booleanas, repetição (combinando iteração e recursão), mutabilidade ou mesmo apenas execução sequencial, que sabemos ser um desafio para muitos aprendizes [52].

Poderíamos combinar essas unidades conceituais para focar em trajetórias de aprendizagem [20, 44, 51, 52]. Ou poderíamos focar em habilidades, como a capacidade

Para rastrear a execução ou depurar. Ou podemos nos concentrar em conceitos mais profundos , como a ideia de que o computador transforma representações (de código para HTML) em execução ou páginas da Web. A pesquisa em educação computacional deve buscar um consenso sobre avaliações validadas e também sobre o que estamos avaliando. Precisamos encontrar um acordo sobre quais são os conceitos centrais – sejam eles variáveis, estado ou mutabilidade – se quisermos abordar os mesmos temas em diferentes artigos. Se desejamos um diálogo científico sobre a compreensão de um conceito ou habilidade computacional por parte dos alunos, precisamos de uma definição comum, e avaliações validadas comuns podem formar uma base mais sólida para nossa disciplina.

AGRADECIMENTOS

Gostaríamos de agradecer à comunidade de pesquisa em educação computacional por usar o SCS1 e compartilhar seus comentários e resultados. A avaliação não teria sido tão bem-sucedida sem o trabalho de vocês.

REFERÊNCIAS

[1] Owen Astrachan e Amy Briggs. 2012. O Projeto de Princípios de CS. ACM Inroads 3, 2 (2012), 38–42.

[2] Ada Barach. 2020. Um inventário de conceitos de programação MATLAB para avaliação de cursos de engenharia do primeiro ano: uma replicação da segunda avaliação de Ciência da Computação 1. Dissertação de doutorado. Universidade Estadual de Ohio.

[3] Ada E. Barach, Connor Jenkins, Serendipity S. Gunawardena e Krista M. Kecskemeti. 2020. MCS1: Um Inventário de Conceitos de Programação em MATLAB para Avaliação de Cursos de Engenharia do Primeiro Ano. In 2020 ASEE Virtual Annual Conference. Acesso ao conteúdo.

[4] Brett A. Becker e Thomas Fitzpatrick. 2019. O que os programas de CS1 revelam sobre nossas expectativas de alunos de programação introdutória?. Em Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação. 1011–1017.

[5] Jeremiah Blanchard, Christina Gardner-McCune e Lisa Anthony. 2020. Instrução e aprendizagem de modalidade dupla: um estudo de caso em CS1. Em Anais do 51º Simpósio Técnico da ACM sobre Educação em Ciência da Computação. 818–824.

[6] Ryan Bockmon, Stephen Cooper, Jonathan Gratch e Mohsen Dorodchi. 2019. (Re)Validação de instrumentos cognitivos introdutórios de computação. In Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação. 552–557.

[7] Ryan Bockmon, Stephen Cooper, Jonathan Gratch, Jian Zhang e Mohsen Dorodchi. 2020. As habilidades espaciais dos alunos podem prever suas habilidades de programação? Em Anais da Conferência ACM de 2020 sobre Inovação e Tecnologia no Ensino de Ciência da Computação. 446–451.

[8] Ryan Bockmon, Stephen Cooper, William Koperski, Jonathan Gratch, Sheryl Sorby e Mohsen Dorodchi. 2020. Uma intervenção de habilidades espaciais CS1 e o impacto nas habilidades introdutórias de programação. Em Anais do 51º Simpósio Técnico da ACM sobre Educação em Ciência da Computação. 766–772.

[9] Catherine H. Crouch e Eric Mazur. 2001. Instrução por pares: dez anos de experiência e resultados. American Journal of Physics 69, 9 (2001), 970–977. <https://doi.org/10.1119/1.1374249> arXiv:<https://doi.org/10.1119/1.1374249> [10] Catherine H. Crouch, Jessica Watkins, Adam P. Fagen e Eric Mazur. 2007. Instrução por pares: envolvendo os alunos individualmente, todos ao mesmo tempo. Research-based reform of university physics 1, 1 (2007), 40–95.

[11] Matt J. Davidson, Brett Wortzman, Amy J. Ko e Min Li. 2021. Investigando o viés de itens em um exame CS1 com funcionamento diferencial de itens. Em Anais do 52º Simpósio Técnico da ACM sobre Educação em Ciência da Computação. 1142–1148.

[12] Adrienne Decker. 2007. Como os alunos se comparam: um instrumento de avaliação para ciência da computação introdutória. Dissertação de doutorado. Universidade Estadual de Nova York em Buffalo.

[13] Ömer Demir e Süleyman Sadi Seferoğlu. 2019. Desenvolvimento de um teste de desempenho de programação baseado em Scratch . Information and Learning Sciences (2019).

[14] Brian Dorn e Allison Elliott Tew. 2015. Validação empírica e aplicação da Pesquisa de Atitudes em Computação. Educação em Ciência da Computação 25, 1 (2015), 1–36.

[15] Rodrigo Duran, Jan-Mikael Rybicki, Juha Sorva e Arto Hellas. 2019. Explorando o valor da autoavaliação do aluno na programação introdutória. In Anais da Conferência ACM de 2019 sobre Pesquisa Internacional em Educação Computacional. 121–130.

[16] Rodrigo Silva Duran, Jan-Mikael Rybicki, Arto Hellas e Sanna Suoranta. 2019. Em direção a um instrumento comum para medir o conhecimento prévio de programação. In Anais da Conferência ACM de 2019 sobre Inovação e Tecnologia no Ensino de Ciência da Computação. 443–449.

[17] Shannon Duvall, Scott Spurlock, Dugald Hutchings e Robert Duvall. 2021. Aprimorando o aprendizado de conteúdo e as percepções dos alunos em CS1 com Scrumage.

Anais do 52º Simpósio Técnico da ACM sobre Educação em Ciência da Computação.

[18] Phillipa J. Easterbrook, Ramana Gopalan, JA Berlin e David R. Matthews. 1991. Viés de publicação em pesquisa clínica. The Lancet 337, 8746 (1991), 867–872.

[19] Andrea Forte e Mark Guzdial. 2005. Motivação e não-especialistas em Ciência da Computação: Identificando Públicos Discretos para Cursos Introdutórios. IEEE Transactions on Education 48, 2 (2005), 248–253.

[20] Brian D. Gane, Maya Israel, Noor Elagha, Wei Yan, Feiya Luo e James W Pelle- grino. 2021. Design and Validation of Learning Trajectory-Based Assessments for Computational Thinking in Upper Elementary Grades. Computer Science Education (2021), 1–28.

[21] Ken Goldman, Paul Gross, Cinda Heeren, Geoffrey Herman, Lisa Kaczmarczyk, Michael C. Loui e Craig Zilles. 2008. Identificando conceitos importantes e difíceis em cursos introdutórios de computação usando um processo Delphi. Em Anais do 39º simpósio técnico SIGCSE sobre educação em ciência da computação. 256–260.

[22] Ken Goldman, Paul Gross, Cinda Heeren, Geoffrey L. Herman, Lisa Kaczmarczyk, Michael C. Loui e Craig Zilles. 2010. Definindo o escopo dos inventários de conceitos para disciplinas introdutórias de computação. ACM Transactions on Computing Education (TOCE) 10, 2 (2010), 1–29.

[23] Mark Guzdial. 2009. Ensinando computação a todos. Commun. ACM 52, 5 (2009), 31–33.

[24] Patricia Haden. 2019. Métodos quantitativos. Em The Cambridge Handbook of Computing Education Research, Sally A. Fincher e Anthony V. Robins (Eds.). Cambridge University Press, 102–132.

[25] Richard R. Hake. [s.d.]. Envolvimento interativo versus métodos tradicionais: uma pesquisa com seis mil alunos sobre dados de testes de mecânica para cursos introdutórios de física. American journal of Physics 66, 1 ([s.d.]).

[26] Geoffrey L. Herman, Michael C. Loui e Craig Zilles. 2010. Criando o Inventário de Conceitos de Lógica Digital. Em Anais do 41º simpósio técnico da ACM sobre educação em ciência da computação. 102–106.

[27] David Hestenes, Malcolm Wells e Gregg Swackhamer. 1992. Inventário de Conceitos de Força. The physics teacher 30, 3 (1992), 141–158.

[28] Franc Jakoš e Domen Verber. 2017. Aprendendo habilidades básicas de programação com jogos educativos: um caso de escolas primárias na Eslovênia. Journal of Educational Computing Research 55, 5 (2017), 673–698.

[29] Brittany Itelia Johnson. 2017. Uma teoria de (des)comunicação de ferramentas e abordagem adaptativa para apoiar o uso de ferramentas de desenvolvimento. Tese de doutorado. Universidade Estadual da Carolina do Norte.

[30] Simon Peyton Jones, Tim Bell, Quintin Cutts, Sridhar Iyer, Carsten Schulte, Jan Vahrenhold e ByoungRae Han. 2011. Computação na escola. Comparações internacionais. Recuperado em 7 de maio (2011), 2013.

[31] David Joyner. 2018. Avaliação e feedback inteligentes em apoio a um MOOC com créditos. Em Conferência Internacional sobre Inteligência Artificial na Educação. Springer, 166–170.

[32] David Joyner. 2018. Rumo ao CS1 em escala: Construindo e testando um candidato a MOOC para crédito. Em Anais da Quinta Conferência Anual da ACM sobre Aprendizagem em Escala. 1–10.

[33] David Joyner e Melinda McDaniel. 2019. Replicando e desvendando as diferenças de desempenho e comportamento entre um curso de CS online e um tradicional . Em Anais da Conferência ACM sobre Educação em Computação Global. 157–163.

[34] Michael T. Kane. 1992. Uma abordagem baseada em argumentos para a validade. Psicológico boletim 112, 3 (1992), 527.

[35] Amy J. Ko e Sally A. Fincher. 2019. Um processo de projeto de estudo. Em The Cambridge Handbook of Computing Education Research, Sally A. Fincher e Anthony V. Robins (Eds.). Cambridge University Press, 81–101.

[36] Thomas Lancaster, Anthony Robins e Sally Fincher. 2019. Avaliação e plágio. Em The Cambridge Handbook of Computing Education Research, Sally A. Fincher e Anthony V. Robins (Orgs.). Cambridge University Press.

[37] Lucas Layman, Yang Song e Curry Guinn. 2020. Rumo à previsão de sucesso e fracasso em CS2: uma análise de métodos mistos. Em Anais da Conferência ACM Sudeste de 2020. 218–225.

[38] Michael J. Lee e Amy J. Ko. 2015. Comparando a eficácia de abordagens de aprendizagem online nos resultados de aprendizagem de CS1. Em Anais da Décima Primeira Conferência Internacional Anual sobre Pesquisa em Educação em Computação Internacional (Omaha, Nebraska, EUA) (ICER ’15). Association for Computing Machinery, Nova York, NY, EUA, 237–246. <https://doi.org/10.1145/2787622.2787709> [39] Linda Mannila, Fredrik Heintz, Susanne Kjällander e Anna Åkerfeldt. 2020. Programação no Ensino Fundamental: Rumo a um Modelo de Avaliação Baseado em Pesquisa. In Anais do 15º Workshop sobre Educação em Computação no Ensino Fundamental e Médio. 1–10.

[40] Lauren Margulieux, Tuba Ayer Ketenci e Adrienne Decker. 2019. Revisão das medidas utilizadas na pesquisa em educação computacional e sugestões para aumentar a padronização. Computer Science Education 29, 1 (2019), 49–78.

[41] Michael McCracken, Vicki Almstrum, Danny Diaz, Mark Guzdial, Dianne Hagan, Yifat Ben-David Kolikant, Cary Laxer, Lynda Thomas, Ian Utting e Tadeusz Wilusz. 2001. Um estudo multinacional e multi-institucional sobre a avaliação das habilidades de programação de alunos do primeiro ano de Ciência da Computação. Em Relatórios do Grupo de Trabalho do ITICSE sobre Inovação e Tecnologia no Ensino de Ciência da Computação (Canterbury,

- Reino Unido) (ITICSE-WGR '01). Association for Computing Machinery, Nova Iorque, NY, EUA, 125–180. <https://doi.org/10.1145/572133.572137>
- [42] Greg L. Nelson, Benjamin Xie e Amy J. Ko. 2017. Compreensão em primeiro lugar: avaliando uma nova pedagogia e sistema de tutoria para rastreamento de programas em CS1. Em *Anais da Conferência ACM de 2017 sobre Pesquisa Internacional em Educação em Computação*. 2–11.
- [43] Miranda C. Parker, Mark Guzdial e Shelly Engleman. 2016. Replicação, validação e uso de uma avaliação de conhecimento CS1 independente de idioma. Em *Anais da conferência ACM de 2016 sobre pesquisa internacional em educação em computação*. 93–101.
- [44] Miranda C. Parker, Yvonne S. Kao, Dana Saito-Stehberger, Diana Franklin, Susan Krause, Debra Richardson e Mark Warschauer. 2021. Desenvolvimento e Validação Preliminar da Avaliação de Computação para Alunos do Ensino Fundamental (ACES). Em *Anais do 52º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 10–16.
- [45] Miranda C. Parker, Amber Solomon, Brianna Pritchett, David A. Illingworth, Lauren E. Margulieux e Mark Guzdial. 2018. Status socioeconômico e desempenho em ciência da computação: habilidade espacial como variável mediadora em um novo modelo de compreensão. Em *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação em Computação*. 97–105.
- [46] Markeya S. Peteranetz, Patrick M Morrow e Leen-Kiat Soh. 2020. Desenvolvimento e Validação do Teste de Conceitos e Habilidades de Pensamento Computacional. Em *Anais do 51º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 926–932.
- [47] Leo Porter, Dennis Bouvier, Quintin Cutts, Scott Grissom, Cynthia Lee, Robert McCartney, Daniel Zingaro e Beth Simon. 2016. Um estudo multi-institucional de instrução por pares em computação introdutória. Em *Anais do 47º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 358–363.
- [48] Leo Porter, Daniel Zingaro, Soohyun Nam Liao, Cynthia Taylor, Kevin C. Webb, Cynthia Lee e Michael Clancy. 2019. BDSI: Um inventário de conceitos validado para estruturas de dados básicas. Em *Anais da Conferência ACM de 2019 sobre Pesquisa Internacional em Educação em Computação*. 111–119.
- [49] Keith Quille e Susan Bergin. 2019. CS1: Como eles se saíram? Como podemos ajudar? Uma década de pesquisa e prática. *Educação em Ciência da Computação* 29, 2-3 (2019), 254–282.
- [50] Vennila Ramalingam e Susan Wiedenbeck. 1998. Desenvolvimento e validação de pontuações em uma escala de autoeficácia em programação de computadores e análises de grupo da autoeficácia de programadores iniciantes. *Journal of Educational Computing Research* 19, 4 (1998), 367–381.
- [51] Kathryn M. Rich, T. Andrew Binkowski, Carla Strickland e Diana Franklin. 2018. Decomposição: Uma Trajetória de Aprendizagem do Pensamento Computacional do Ensino Fundamental I e II. In *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação Computacional*. 124–132.
- [52] Kathryn M. Rich, Carla Strickland, T. Andrew Binkowski, Cheryl Moran e Diana Franklin. 2017. Trajetórias de aprendizagem do jardim de infância ao 8º ano derivadas da literatura de pesquisa: sequência, repetição, condicionais. In *Anais da Conferência ACM de 2017 sobre Pesquisa Internacional em Educação Computacional* (Tacoma, Washington, EUA) (ICER '17). ACM, Nova York, NY, EUA, 182–190. <https://doi.org/10.1145/3105726.3106166> [53] Kelly Rivers, Erik Harpstead e Kenneth R Koedinger. 2016. Análise da curva de aprendizagem para programação: com quais conceitos os alunos têm dificuldade?. Em *ICER*, Vol. 16. 143–151.
- [54] Linda J. Sax, Kaitlin NS Newhouse, Joanna Goode, Max Skorodinsky, Tomoko M. Nakajima e Michelle Sendowski. 2020. Os princípios do AP CS ampliam a participação na computação? Uma análise dos participantes do APCSA e do APCSP. In *Anais do 51º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 542–548.
- [55] Jean Scholtz e Susan Wiedenbeck. 1990. Aprendendo a segunda e as subsequentes linguagens de programação: um problema de transferência. *International Journal of Human-Computer Interaction* 2, 1 (1990), 51–72.
- [56] Herbert A. Simon. 2019. *As ciências do artificial*. MIT Press.
- [57] David H. Smith IV, Qiang Hao, Filip Jagodzinski, Yan Liu e Vishal Gupta. 2019. Quantificando os efeitos do conhecimento prévio em cursos de programação para iniciantes. Em *Anais da Conferência ACM sobre Educação em Computação Global*. 30–36.
- [58] Yang Song, Yunkai Xiao, Jonathan Stephens, Emma Ruesch, Sean Roginski e Lucas Layman. 2020. Adequação do SCS1 como instrumento de avaliação pré-CS2: uma comparação com questões curtas de prática deliberada. Em *Anais da Conferência ACM Sudeste de 2020*. 313–314.
- [59] Phil Steinhart, Andrew Petersen e Jan Vahrenhold. 2020. Revisitando a autoeficácia na programação introdutória. Em *Anais da Conferência ACM de 2020 sobre Pesquisa Internacional em Educação em Computação*. 158–169.
- [60] Alaaeddin Swidan, Feliene Hermans e Marileen Smit. 2018. Conceitos errôneos de programação para alunos do ensino fundamental e médio. Em *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação em Computação*. 151–159.
- [61] Cynthia Taylor, Michael Clancy, Kevin C. Webb, Daniel Zingaro, Cynthia Lee e Leo Porter. 2020. Os detalhes práticos da construção de um inventário de conceitos de CS. Em *Anais do 51º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 372–378.
- [62] Cynthia Taylor, Daniel Zingaro, Leo Porter, Kevin C. Webb, Cynthia Bailey Lee e Michael Clancy. 2014. Inventários de Conceitos de Ciência da Computação: Passado e Futuro. *Educação em Ciência da Computação* 24, 4 (2014), 253–276.
- [63] Allison Elliott Tew. 2010. Avaliando o conhecimento de conceitos fundamentais de informática introdutória de maneira independente da linguagem. Dissertação de doutorado. Faculdade de Computação, Instituto de Tecnologia da Geórgia.
- [64] Allison Elliott Tew e Mark Guzdial. 2010. Desenvolvimento de uma avaliação validada de conceitos fundamentais de CS1. Em *Anais do 41º Simpósio Técnico da ACM sobre Educação em Ciência da Computação* (Milwaukee, Wisconsin, EUA) (SIGCSE '10). Association for Computing Machinery, Nova Iorque, NY, EUA, 97–101. <https://doi.org/10.1145/1734263.1734297>
- [65] Allison Elliott Tew e Mark Guzdial. 2011. O FCS1: Uma avaliação independente de idioma do conhecimento CS1. Em *Anais do 42º simpósio técnico da ACM sobre educação em ciência da computação*. 111–116.
- [66] Dion Timmermann e Christian Kautz. 2016. Design de recursos educacionais abertos para um curso de programação com foco na compreensão conceitual. Nos *Anais da 44ª Conferência Anual da SEFI*.
- [67] Dion Timmermann, Christian Kautz e Volker Skwarek. 2016. Redesenho baseado em evidências de um curso introdutório “Programação em C”. Em *2016 IEEE Frontiers in Education Conference (FIE)*. IEEE, 1–5.
- [68] Ethel Tshukudu e Quintin Cutts. 2020. Compreendendo a transferência conceitual para alunos que aprendem novas linguagens de programação. Em *Anais da Conferência ACM de 2020 sobre Pesquisa Internacional em Educação em Computação*. 227–237.
- [69] Ian Utting, Allison Elliott Tew, Mike McCracken, Lynda Thomas, Dennis Bouvier, Roger Frye, James Paterson, Michael Caspersen, Yifat Ben-David Kolikant, Juha Sorva, et al. 2013. Uma nova perspectiva sobre o desempenho de programadores iniciantes e as expectativas de seus professores. In *Anais da conferência do grupo de trabalho ITICSE sobre Inovação e tecnologia no ensino de ciência da computação - relatórios do grupo de trabalho*. 15–32.
- [70] Kristina Von Hausswolff e Anna Eckerdal. 2018. Medindo o conhecimento de programação em um contexto de pesquisa. Em *2018 IEEE Frontiers in Education Conference (FIE)*. IEEE, 1–9.
- [71] Jennifer Wang. 2017. O sistema educacional dos EUA está pronto para a ciência da computação para todos? *Commun. ACM* 60, 8 (2017), 26–28.
- [72] Alicia N. Washington, Shaefny Grays e Sudhipta Dasmohapatra. 2016. A Pesquisa de Atitudes e Identidade em Ciência da Computação (CSAIS): Uma ferramenta inovadora para medir o impacto da identidade étnica em estudantes de ciência da computação sub-representados. Em *123ª Conferência e Exposição Anual da Sociedade Americana de Educação em Engenharia*.
- [73] David Weintrop e Uri Wilensky. 2015. Usando avaliações comutativas para comparar a compreensão conceitual em programas baseados em blocos e em texto. Em *ICER*, Vol. 15. 101–110.
- [74] Benjamin Xie, Matthew J. Davidson, Min Li e Amy J. Ko. 2019. Uma avaliação da teoria de resposta ao item de uma avaliação de conhecimento CS1 independente de idioma. Em *Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 699–705.
- [75] Benjamin Xie, Greg L. Nelson, Harshitha Akkaraju, William Kwok e Amy J. Ko. 2020. O efeito da agência informativa em ambientes de aprendizagem online autodirigida. In *Anais da Sétima Conferência ACM sobre Aprendizagem em Escala*. 77–89.
- [76] Benjamin Xie, Greg L. Nelson e Amy J. Ko. 2018. Uma estratégia explícita para estruturar o rastreamento de programas iniciantes. Em *Anais do 49º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*. 344–349.
- [77] Daniel Zingaro, Cynthia Taylor, Leo Porter, Michael Clancy, Cynthia Lee, Soohyun Nam Liao e Kevin C. Webb. 2018. Identificando dificuldades dos alunos com estruturas de dados básicas. Em *Anais da Conferência ACM de 2018 sobre Pesquisa Internacional em Educação Computacional*. 169–177.