

FCS1: Uma Avaliação Independente de Idioma do CS1

Conhecimento

Allison Elliott Tew

Departamento de Ciência da Computação
Universidade da Colúmbia Britânica
Vancouver, BC V6T 1Z4
aetew@cs.ubc.ca

Marco Guzdial

Escola de Computação Interativa
Instituto de Tecnologia da Geórgia
Atlanta, GA 30332-0760
guzdial@cc.gatech.edu

RESUMO

Um dos principais objetivos de muitos projetos de educação em ciência da computação é determinar em que medida uma determinada intervenção teve um impacto significativo. impacto na aprendizagem dos alunos. No entanto, a computação carece de validade Avaliações para fins pedagógicos ou de pesquisa. Sem Com avaliações tão válidas, é difícil medi-las com precisão. aprendizagem do aluno ou estabelecer uma relação entre o ambiente de ensino e os resultados da aprendizagem.

Desenvolvemos a Avaliação Fundamental CS1 (FCS1). instrumento, o primeiro instrumento de avaliação para introdução Conceitos de ciência da computação que são aplicáveis a uma variedade de pedagogias e linguagens de programação atuais. Nós métodos aplicados de testes educacionais e psicológicos desenvolvimento, adaptando-os conforme necessário para se adequarem ao contexto disciplinar. Realizamos um estudo empírico em larga escala. para demonstrar que o pseudocódigo era um mecanismo apropriado para alcançar a independência da linguagem de programação. Finalmente, estabelecemos a validade da avaliação usando Uma argumentação multifacetada, que combina dados de entrevistas, análise estatística dos resultados da avaliação e o exame CS1.

pontuações.

Categorias e Descritores de Assunto

K.3.2 [Computadores e Educação]: Educação em Ciência da Computação e Informação — educação em ciência da computação, currículo

Termos Gerais

Experimentação, medição

Palavras-chave

Avaliação, CS1, programação, validade

1. INTRODUÇÃO

Medir a aprendizagem dos alunos é fundamental para qualquer empreendimento educacional. Um objetivo primordial de muitos cursos de ciência da computação é avaliar a aprendizagem dos alunos.

É concedida permissão para fazer cópias digitais ou impressas de todo ou parte deste trabalho para O uso pessoal ou em sala de aula é permitido sem custo, desde que as cópias sejam não foi feito ou distribuído com fins lucrativos ou comerciais e as cópias Apresente este aviso e a citação completa na primeira página. Para copiar de outra forma, para A republicação, seja para postar em servidores ou redistribuir para listas, requer autorização prévia específica. permissão e/ou uma taxa. SIGCSE'11, 9 a 12 de março de 2011, Dallas, Texas, EUA. Direitos autorais 2011 ACM 978-1-4503-0500-6/11/03 ...\$10,00.

O objetivo dos projetos educacionais é determinar em que medida um Considerando que a intervenção instrucional teve impacto na aprendizagem dos alunos, o campo da computação carece de dados válidos. e instrumentos de avaliação confiáveis para fins pedagógicos ou de pesquisa. Sem essas avaliações válidas, é difícil medir com precisão a aprendizagem do aluno ou estabelecer um relação entre o ambiente de ensino e a aprendizagem resultados. O objetivo da pesquisa em avaliação na ciência da computação é ter maneiras válidas de mensurar as concepções dos alunos. de tópicos fundamentais, o que permitirá a pesquisa sobre como a compreensão do conhecimento no domínio se desenvolve como bem como possibilitar a inovação e a reforma curricular fundamentadas em esse conhecimento.

Muitas áreas da ciência, tecnologia, engenharia e matemática.

As disciplinas STEM (Ciência, Tecnologia, Engenharia e Matemática) possuem ferramentas de avaliação padronizadas e validadas.

que permitem que educadores e pesquisadores meçam com precisão aprendizagem do aluno e avaliação de inovações curriculares (por exemplo, [6, 9]). No entanto, a ciência da computação não possui algo semelhante. Conjunto de ferramentas de avaliação validadas. Existem quatro ferramentas já existentes. Exames validados de conhecimento conceitual em ciência da computação. Em segundo lugar, o exame CS Advanced Placement (AP) e o Certificado Geral de Educação de Nível Avançado (A-level) em Na área da computação, o foco está na sequência introdutória. Esses exames, escritos na linguagem de programação Java, são controlados e administrados por bancas examinadoras educacionais específicas e, portanto, não são amplamente aplicáveis.

Disponível para educadores e pesquisadores para uso geral. Restam dois exames, o Exame de Área Principal para Computação. Ciência e o Teste de Conhecimento Específico em Ciência da Computação do GRE, capa uma ampla gama de materiais, pois são projetados para avaliar Objetivos de aprendizagem ao final do programa de graduação.

A comunidade de ensino de Ciência da Computação tem demonstrado um interesse crescente. em pesquisa de avaliação, e dois projetos relacionados estão em andamento. Em seu trabalho de dissertação, Decker [3] projetou uma avaliação para uma sequência introdutória de cursos de programação (CS1) e CS2) em Java. O instrumento foi desenvolvido e testado. em uma única instituição e, portanto, suas alegações de validade não podem ser generalizadas além desse contexto. Craig Zilles e Os colegas receberam financiamento para desenvolver um conjunto de conceitos. inventários para computação, em matemática discreta, projeto de lógica digital e fundamentos de programação. Os pesquisadores têm obtiveram um conjunto de conceitos problemáticos de especialistas em educação [4] e estão realizando entrevistas de verbalização do pensamento para capturar as concepções errôneas dos alunos [7]. O trabalho é preliminar. e os instrumentos ainda estão sendo desenvolvidos.

Nosso trabalho difere desses esforços porque criamos um exame rigorosamente validado que poderia ser amplamente adotado e usado em qualquer curso introdutório de Ciência da Computação. O objetivo era criar

Um exame para avaliar a compreensão de conceitos fundamentais de computação, independentemente da linguagem de programação, que não seja excessivamente influenciado por nenhum paradigma pedagógico específico. Nos concentramos em três questões relativas à avaliação de conceitos introdutórios em ciência da computação: Como os métodos de desenvolvimento de testes existentes podem ser aplicados e adaptados para criar um instrumento de avaliação válido para o conhecimento conceitual de CS1? Em que medida o pseudocódigo pode ser usado como mecanismo para alcançar a independência da linguagem de programação em um instrumento de avaliação? E em que medida o instrumento independente de linguagem fornece uma medida válida do conhecimento conceitual de CS1?

Este artigo começa com uma visão geral do método utilizado para desenvolver o primeiro instrumento de avaliação de conceitos introdutórios de ciência da computação, aplicável a uma variedade de pedagogias e linguagens de programação atuais.

2. MÉTODO PARA DESENVOLVER UMA AVALIAÇÃO CS1 VALIDADA

Os campos da educação e da psicologia desenvolveram uma rica história no desenvolvimento e validação de instrumentos de medição para uma variedade de propósitos [1]. Aplicamos esses métodos e práticas estabelecidos para o desenvolvimento de medidas válidas, resumidos abaixo, adaptando-os quando necessário para o campo da ciência da computação.

O primeiro passo no desenvolvimento de um teste é estabelecer seu propósito e definição — o que será medido e o que os resultados significam. A especificação do teste inclui a definição do conteúdo conceitual, ou construtos, que serão medidos, o formato das questões e os procedimentos de pontuação. A especificação do teste deve ser revisada por um painel de especialistas para fornecer evidências de validade de conteúdo e garantir que todos os construtos estejam adequadamente representados e que construtos irrelevantes não sejam incluídos.

Após a elaboração e verificação da especificação do teste, deve-se desenvolver um banco de questões que abranja todos os construtos identificados na especificação. Em seguida, realiza-se a aplicação de testes-piloto para avaliar a adequação das questões e permitir que as revisões necessárias sejam feitas antes da seleção das questões finais.

As últimas etapas do desenvolvimento de testes são estudos empíricos de respostas individuais para estabelecer a validade e a confiabilidade. Os testes de validade garantem que o teste esteja medindo os construtos pretendidos, e os testes de confiabilidade verificam se os resultados são consistentes em exames repetidos e, portanto, confiáveis.

Para criar a Avaliação FCS1, duas adaptações foram necessárias. A primeira mudança metodológica centrou-se na criação de um exame focado em conceitos, e não na sintaxe da linguagem de programação, para que a avaliação pudesse ser o mais amplamente aplicável possível. O método exigiu a adição de uma etapa para verificar a independência do exame em relação à linguagem de programação. Para alcançar a independência de linguagem para um exame CS1, utilizamos um pseudocódigo detalhado como linguagem de programação do exame. Avaliamos a eficácia dessa abordagem usando uma combinação de pensamento em voz alta e estudos empíricos¹. Esses estudos foram necessários para garantir que os alunos sejam capazes de transferir adequadamente a compreensão da linguagem de programação utilizada como instrução para o pseudocódigo e para garantir

¹Devido a limitações de espaço, restringimos nossa discussão aqui ao estudo empírico. Veja [12] para mais detalhes.

que os alunos sejam capazes de demonstrar adequadamente sua compreensão no novo exame independente de idioma.

A segunda alteração se fez necessária porque os métodos padrão para validar o instrumento em relação a medidas válidas existentes não se aplicavam a este exame, o primeiro do gênero na área da computação. Portanto, um argumento de validade foi elaborado utilizando uma combinação de entrevistas de verbalização do pensamento e técnicas de análise estatística.

Os três primeiros passos deste processo foram descritos anteriormente em [13]. A Seção 3 contém os resultados do nosso estudo empírico que investiga o uso de pseudocódigo como mecanismo para alcançar a independência de linguagem, e o processo usado para validar o exame é explicado na Seção 4. Os dados coletados permitirão uma análise preliminar da confiabilidade interna do exame. No entanto, testes de confiabilidade em larga escala serão realizados em trabalhos futuros.

3. ESTUDO DE AVALIAÇÃO FCS1

Realizamos um estudo empírico em larga escala comparando o desempenho dos alunos na Avaliação FCS12 com uma versão comparável do instrumento de avaliação escrita na linguagem de programação CS1 dos alunos. Os participantes foram selecionados ao final dos cursos de CS1 ministrados em Java, Matlab ou Python, e análises estatísticas foram utilizadas para buscar correlações no desempenho dos alunos entre as duas avaliações.

3.1 Desenho do Estudo

Recrutamos participantes de quatro cursos introdutórios diferentes, ministrados em duas universidades por quatro professores distintos, de modo que a definição e a compreensão do conhecimento de CS1 não estivessem vinculadas a um professor ou instituição específica. Houve um total de 952 participantes matriculados em um curso de CS1 em Java ($n = 80$), Matlab ($n = 520$) ou Python ($n = 352$).

O estudo consistiu em duas avaliações aplicadas com uma semana de intervalo, em condições de teste — sem perguntas e sem colaboração entre os participantes. Os participantes realizaram a Avaliação FCS1 e uma versão comparável da FCS1 reescrita na linguagem de programação utilizada em seu curso introdutório de Ciência da Computação. A versão comparável foi criada utilizando as questões alternativas para cada conceito do banco de questões. Um delineamento quase-experimental contrabalançado foi utilizado para reduzir o viés decorrente do efeito de ordem.

3.2 Resultados da Análise de Dados Antes de

iniciar a análise de dados, foram removidos os valores discrepantes do conjunto de dados que poderiam enviesar ou distorcer os resultados. Um pesquisador externo verificou as regras de exclusão e revisou de forma independente todos os exames removidos do conjunto de dados para confirmar se atendiam a um ou mais dos critérios de exclusão.

3.2.1 Pontuação do FCS1

As versões em pseudocódigo e em linguagem CS1 do FCS1 foram avaliadas, atribuindo-se 1 ponto para resposta correta e 0 para resposta incorreta. (Questões deixadas em branco não foram pontuadas.) Os alunos participantes responderam, em média, a 8,82 (33,78%, $\bar{y} = 3,649$) questões corretamente na versão em pseudocódigo.

Infelizmente, para a validade e confiabilidade do instrumento de avaliação, as questões do exame devem permanecer privadas e não podem ser publicadas. Isso evita possíveis vieses nos participantes envolvidos em estudos de validação.




Figura 1: Diagrama de dispersão das pontuações para correlação de Pseudocódigo e versões de linguagem do FCS1

do FCS1. A pontuação máxima foi 23 e a mínima, 1. Os alunos tiveram mais sucesso respondendo perguntas da prova específica de linguagem CS1. Uma média das 13,13 questões (48,61%, $\bar{y} = 4,195$) foram respondidas corretamente, e tanto a pontuação mínima quanto a máxima aumentaram. por dois pontos, para 3 e 25, respectivamente. Embora as pontuações gerais tenham sido mais altas nesta versão do exame, similar Os conceitos aparecem entre os identificados como menos e mais importantes. difícil para todas as populações.

Questões sobre operadores matemáticos e instruções condicionais foram Entre as questões mais frequentemente respondidas corretamente, estavam as construções de programação relacionadas a parâmetros de função, valores de retorno de função e recursão, que foram as mais difíceis. Questões sobre o pseudocódigo e a versão específica da linguagem do FCS1.

3.2.2 Correlação com a versão linguística do CS1

Investigamos a eficácia do pseudocódigo como o mecanismo para alcançar a independência da linguagem de programação examinando se os alunos foram capazes de transferir seus compreensão de conceitos fundamentais de computação a partir de seus Da linguagem de programação CS1 ao pseudocódigo. Uma correlação. Foi realizada uma análise para procurar evidências de um resultado positivo. correlação entre as pontuações gerais, ou seja, o número de perguntas respondidas corretamente, para cada participante em ambos os versões da Avaliação FCS1.

O coeficiente de correlação de Pearson foi calculado para avaliar a relação entre a pontuação no versão em pseudocódigo e a pontuação na linguagem específica versão do instrumento de avaliação. Houve uma forte, correlação positiva entre as duas variáveis, Pearson $r(850) = 0,572$, $p \leq 0,001$. Um gráfico de dispersão resume o resultados na Figura 1.

Tendo encontrado uma correlação positiva, que atende às diretrizes para um tamanho de efeito grande ($r \geq .37$) nas ciências sociais [2]. As análises subsequentes se concentraram em correlacionar as notas dos exames para cada subpopulação de linguagem de programação CS1. Os alunos de cada uma das linguagens de programação CS1 examinadas – Java, Matlab e Python – conseguiram transferir seu entendimento para pseudocódigo? Ou a sintaxe do pseudocódigo é...

código muito diferente do que os participantes aprenderam para facilitar a expressão da compreensão conceitual em uma nova linguagem de programação?

Os coeficientes de correlação de Pearson foram calculados para avaliar a relação entre a pontuação no versão em pseudocódigo e a pontuação na linguagem específica versão da avaliação para cada linguagem de programação grupo de participantes (ver Tabela 1). Houve uma forte correlação positiva entre as pontuações no pseudocódigo e Versões linguísticas da avaliação para cada uma das linguagens de programação estudadas. Participantes da turma CS1. em Java teve a correlação mais forte, Pearson's $r(74) = .665$, $p \leq 0,001$. Embora a sintaxe do pseudocódigo tivesse mais O grupo de participantes que estudou Python apresentou mais elementos em comum com o Python do que com as outras linguagens de programação estudadas. o menor coeficiente de correlação, r de Pearson (285) = 0,415, $p \leq 0,001$. A população Python era composta por estudantes, normalmente estudantes de cursos de STEM (Ciência, Tecnologia, Engenharia e Matemática), matriculados em um curso introdutório de informática, bem como alunos que estavam matriculados em um curso não tradicional de computação de mídia. Projetado para estudantes de artes liberais. Uma correlação de Pearson. O coeficiente também foi calculado para cada uma dessas subpopulações do grupo de participantes do Python. Houve uma forte correlação. correlação positiva, (r de Pearson (43) = 0,615, $p \leq 0,001$). Para alunos matriculados no curso CS1 de Python com foco em Ciência da Computação. que era semelhante à força da correlação encontrada em as populações Java e Matlab. Enquanto o tamanho do efeito para O curso de Python baseado em mídia era menor, $r = 0,372$, e atendeu aos critérios estabelecidos. diretrizes para serem classificadas como uma correlação forte e positiva. De forma geral, os resultados demonstram que houve uma forte, Correlação positiva entre as pontuações no pseudocódigo e versões em linguagem CS1 do FCS1 para ambos os formatos tradicionais e abordagens pedagógicas não tradicionais para o ensino de CS1.

4. ESTABELECENDO A VALIDADE

Após o teste piloto da Avaliação FCS1, a etapa final em O processo de desenvolvimento visava estabelecer a validade do exame. Em geral, existem duas classes de evidências usadas para Alegações de validade que sustentam o conteúdo. Evidências relacionadas ao conteúdo garantem que o conteúdo da avaliação operacionalize adequadamente Os construtos que se pretende medir. Validade de conteúdo. para o FCS1 foi previamente estabelecido por revisão de um painel de especialistas. Evidências relacionadas ao construto fornecem o segundo conjunto de O apoio à validade é o foco da discussão aqui. Em conjunto, a validade de conteúdo e a validade de construto permitem que o desenvolvedor de um teste forneça evidências de que o instrumento está medindo. conhecimento do aluno conforme o esperado.

Considerando que este exame é o primeiro do seu gênero em o campo, os métodos de correlação padrão para estabelecer A validade não se aplica. Uma vez que a validação de construto depende de inferências extraídas de uma variedade de dados [8, 10], nós propôs uma abordagem tríplice para estabelecer a validade do instrumento de avaliação. As evidências de validade é triplo: dados de entrevistas com verbalização do pensamento, respostas dos alunos para FCS1 e notas do exame CS1 dos alunos.

4.1 Análise Qualitativa das Entrevistas com Estudantes

A análise qualitativa das transcrições de entrevistas em que os alunos verbalizam seus pensamentos fornece evidências sobre se os alunos estavam respondendo a perguntas com base em seu conhecimento de conteúdo conceitual. O objetivo da análise foi determinar se os alunos estavam utilizando o conhecimento sobre o construção pretendida para responder à pergunta. Alternativamente,

Tabela 1: Correlações de Pearson significativas da avaliação FCS1†

Versão da População	Idioma Prova	Intermediária 1 Prova	Prova Intermediária 2	Prova Intermediária 3	Prova Final	
Total	Pseudo .111 Linguagem	.572 *	.120	.149 .128	.309 .491	.499 .542
Java	Pseudo Linguagem	0,665 *	.408 .406	.446 .582	— .511 — .680	
Matlab	Pseudo Linguagem	.547 *	.500 .531	.527 .536	.443 .488	.438 .505
Python	Pseudo Linguagem	.415 *	.200 .424	.216 .429	ns .392	.453 .539
CS-Python	Pseudo Linguagem	.615 *	.719 .525	.685 .445†	.625 .429†	0,679 .437†
Mídia Python	Pseudo .220 Linguagem *	305 Linguagem .453 305 Linguagem *	.542 ± 246 0,001.	Todas as correlações, salvo indicação em contrário, são significativas ao nível de p <= 0,01.		.262 .601

† A correlação é significativa ao nível de p <= 0,01.

* Autocomparação entre idiomas omitida.

— Nenhuma avaliação da terceira prova intermediária foi analisada porque apenas duas provas intermediárias foram aplicadas no período. curso.

Informações adicionais podem ser necessárias para responder corretamente à pergunta, ou outras pistas podem estar possibilitando a resposta correta. respostas sem conhecimento do conceito.

Treze estudantes participaram, com diferentes níveis de habilidade, Foram recrutados em cursos introdutórios ministrados em três linguagens de programação diferentes (Java, Matlab e Python). Os alunos foram convidados a participar de uma entrevista de verbalização do raciocínio enquanto completavam o pseudocódigo. versão do FCS1. Os dados da entrevista foram transcritos.

e a análise de conteúdo foi utilizada para analisar o participante. respostas. Especificamente, as respostas foram codificadas quanto à correção, erros cometidos e evidências de raciocínio usando o novo Sintaxe da linguagem de pseudocódigo.

As respostas válidas demonstraram evidências de raciocínio do aluno sobre o conceito pretendido na questão e de como ele chegou a uma conclusão. Resposta correta ou incorreta com base no nível de compreensão. Ou seja, se um aluno tinha ideias erradas sobre Se eles escolherem um tópico, selecionarão uma resposta incorreta. Caso contrário, eles A maioria (83,07%) das respostas foi respondida corretamente. As questões analisadas foram categorizadas como válidas. O formato de teste de múltipla escolha permitiu poucas respostas corretas (5,92%), apesar de A incompreensão conceitual dos alunos em relação às questões aborda a questão conceitual. conteúdo. Além disso, houve um pequeno número de respostas. (4,44%) onde os alunos têm concepções errôneas sobre outro tópico impediu-os de responder à pergunta corretamente. No entanto, não houve casos em que os alunos raciocinassem sobre outra construção possibilitou uma resposta correta a uma pergunta. sem conhecimento do conceito.

De modo geral, as evidências das entrevistas fornecem uma argumentação qualitativa que os alunos conseguem ler e com a qual conseguem raciocinar. sintaxe de pseudocódigo. Além disso, eles estão usando seus conhecimentos. sobre a construção pretendida para responder à pergunta.

4.2 Análise quantitativa utilizando a TRI

Os dados e análises do estudo de avaliação FCS1 fornecem uma argumento quantitativo em relação à validade de construto. A análise de correlação de Pearson demonstrou que os alunos têm conhecimento comparável ao avaliado em uma versão específica do exame para cada idioma. Se as questões forem representativas

medidas ativas de conhecimento na programação CS1 dos alunos idioma, então a validade do exame depende do perguntas em si. A teoria da resposta ao item (TRI) é a A técnica de análise estatística empregada para validar essa afirmação alegação. Se as perguntas forem consideradas "boas" (ou seja, de dificuldade e discriminação apropriadas) e estudantes demonstrar conhecimento comparável a um falante nativo de um idioma exame, então argumenta-se que esta é uma representação precisa Representação da compreensão dos alunos sobre os tópicos.

Utilizando um modelo logístico de três parâmetros (3PL) [5], a TRI foi usado para analisar as respostas dos participantes do FCS1 para discernir Os pontos fortes e fracos de cada item do teste. No geral, A maioria (24 de 27) das questões apresentou forte discriminação entre os itens, dificuldade adequada e baixa probabilidade de acerto por palpite. Duas As questões Q12 e Q13 eram muito difíceis. Ou seja, bi > 3,0. o que implica que menos de 10% dos candidatos obtiveram 50%. probabilidade de responder à pergunta corretamente. No geral, o Os itens da prova demonstraram níveis adequados de discriminação. No entanto, devido ao elevado nível geral de dificuldade do no exame, o teste demonstra melhor discriminação entre os alunos participantes com maior capacidade do que aqueles com menor capacidade.

A questão 2 apresentou uma probabilidade de acerto por palpite que excedeu os limites recomendados. O parâmetro do item de palpite, ci = 0,442, uma probabilidade de um participante com baixa habilidade acertar a resposta em mais de 40% das vezes. Outros dois As questões Q21 e Q25 tinham valores de parâmetros de estimativa que estavam elevados, mas dentro de um desvio padrão do Valor esperado de ci = 0,20 para uma questão de múltipla escolha com 5 itens.

No geral, a análise IRT identificou apenas quatro questões, Q2, As questões Q12, Q13 e Q25 precisam ser revisadas ou descartadas. da prova. A questão 2 tem uma alta probabilidade de ser respondida por palpite. As questões 12 e 13 são muito difíceis, e a questão 25 tem um probabilidade de acerto por palpite relativamente alta e fornece relativamente Poucas informações adicionais sobre a capacidade do candidato. nível.




Figura 2: Diagrama de dispersão das pontuações para correlação de Pontuação da Avaliação FCS1 e Pontuação do Exame Final CS1

4.3 Correlação com medidas externas de CS1 Conhecimento

As notas dos alunos nos exames, como definição e medida externa do conhecimento de CS1, fornecem a evidência final para Validade de construto. Foi utilizada a análise de correlação de Pearson, investigar se as pontuações dos alunos no FCS1 podem ser correlacionaram-se positivamente com suas notas nos exames CS1.

O coeficiente de correlação de Pearson foi calculado para avaliar a relação entre a pontuação em a Avaliação FCS1 e a pontuação no exame final em

CS1. Houve uma forte correlação positiva entre o duas variáveis, r de Pearson (931) = 0,499, $p < 0,001$. Um gráfico de dispersão resume os resultados (Figura 2). Além disso, houve correlações significativas, embora mais fracas, entre as pontuações em a avaliação e as notas nos exames individuais de meio de semestre (ver Tabela 1).

Tendo encontrado uma forte correlação positiva subsequente As análises se concentraram em correlacionar as notas dos exames com cada um população da linguagem de programação CS1. Os coeficientes de correlação de Pearson foram calculados para avaliar a relação entre a pontuação na versão em pseudocódigo de a avaliação e a nota do exame final para cada grupo de participantes da linguagem de programação (ver Tabela 1). Houve um Forte correlação positiva entre as pontuações na avaliação e no exame final para cada uma das linguagens de programação estudadas. Participantes do CS1 com ensino em Java, apresentou a correlação mais forte com a nota do exame final, r de Pearson (79) = 0,511, $p < 0,001$. A população de Python era novamente composta por alunos das versões de Ciência da Computação e Computação de Mídia do CS1. O coeficiente de correlação de Pearson foi calculado para cada uma dessas subpopulações do Python grupo de participantes. Houve a correlação positiva mais forte (r de Pearson (69) = 0,679, $p < 0,001$) para os estudantes. matriculado no curso CS1 de Python baseado em Ciência da Computação. Tamanho do efeito para o curso de Python baseado em mídia foi menor, $r = 0,262$, no entanto Ainda havia uma correlação positiva significativa com o meio. tamanho do efeito.

Os coeficientes de correlação de Pearson também foram calculados para cada pontuação do meio do semestre para cada grupo de participantes de linguagem de programação (ver Tabela 1). Houve uma forte correlação positiva.

correlação positiva entre as pontuações na avaliação e

Notas das provas de meio de semestre para todos os cursos de CS1 em Java, Matlab ou Python, exceto pela abordagem não tradicional de computação de mídia. Os participantes do curso de Python baseado em Ciência da Computação tinham as correlações mais fortes com cada nota da prova intermediária.

O coeficiente de correlação mais forte foi para a primeira prova parcial, r de Pearson (69) = 0,719, $p < 0,001$. A correlação entre a pontuação da avaliação e as pontuações da prova parcial para a disciplina baseada em mídia foi de 0,719.

O curso de Python apresentou correlações significativas com o nível médio. tamanho do efeito.

De forma geral, os resultados demonstram que houve uma forte, Observou-se uma correlação positiva entre as pontuações na Avaliação FCS1 e as pontuações do exame final, tanto para abordagens pedagógicas tradicionais quanto não tradicionais do CS1. Além disso, houve uma forte correlação positiva com o desempenho individual no meio do semestre. notas dos exames para abordagens tradicionais de CS1 ensinadas em Java, Matlab e Python.

4.4 Argumento de Validade

Duas questões são centrais para a validação de construto de um instrumento de avaliação: sub-representação do construto e variância irrelevante ao construto [10]. Essas questões são exploradas pelas seguintes questões: (1) A avaliação operacionaliza adequadamente o construto pretendido? e (2) É O desempenho na avaliação foi influenciado por fatores que são acessórios à construção?

A questão da sub-representação de construtos foi resolvida. pela banca de revisores especialistas, confirmando uma definição adequada dos conceitos fundamentais de CS1 incluídos no teste. Além disso, a análise da teoria de resposta ao item indicou que a maioria (24 de 27) dos itens da avaliação fornece informações adequadas sobre a capacidade do aluno participante. Portanto, de modo geral, a definição e a mensuração dos construtos especificados são apropriadas para o FCS1.

Diversas métricas foram utilizadas para identificar as fontes potenciais. de variância irrelevante ao construto, com quase todas as medidas apresentando evidências em contrário. Entrevistas com verbalização do pensamento. As pesquisas com os participantes revelaram que os alunos foram capazes de fornecer respostas válidas sobre o conceito pretendido em mais de 85% dos casos. as perguntas. As pontuações na versão em pseudocódigo da avaliação apresentaram uma forte correlação positiva com as pontuações na CS1 é a versão específica da linguagem do exame. Quando combinada. Com resultados da TRI que demonstram que 85,18% das questões apresentavam nível de dificuldade e discriminação adequados, é É apropriado inferir que o FCS1 é uma medida razoável. de conhecimento CS1.

De forma geral, os estudos de validade fornecem evidências de que os alunos estão lendo e raciocinando com o pseudocódigo para responder perguntas da maneira pretendida. Além disso, há evidências empíricas da qualidade das perguntas usadas para medir a compreensão, que se correlacionam ainda mais com as definições e medidas externas do corpo docente em relação ao conhecimento de CS1. Portanto, O FCS1 fornece uma medida válida de conceitos introdutórios de computação para cursos introdutórios de computação baseados em procedimentos, ministrados em Java, Matlab ou Python. nível universitário.

5. CONCLUSÃO E TRABALHOS FUTUROS

A pesquisa e o desenvolvimento da Avaliação FCS1 são prosseguindo por diversos caminhos, esta pesquisa concentrou-se em estabelecer a validade do exame para um grupo limitado. número de construções com uma população específica de estudantes universitários que cursam o programa introdutório comum de CS1-

línguas ming. Extensões naturais deste trabalho incluem a adição de conceitos adicionais, o estabelecimento da confiabilidade do exame e a implementação do teste online para reduzir os recursos necessários para a coleta de dados e administração do teste.

Estamos também a explorar a aplicabilidade e a validade da utilização do FCS1 para medir o conhecimento dos alunos em diferentes paradigmas pedagógicos e linguagens de programação, tais como abordagens gráficas ou funcionais.

A disponibilidade de um instrumento de avaliação válido para medir a compreensão dos alunos sobre os conceitos de CS1 possibilita uma variedade de direções para a pesquisa em educação em Ciência da Computação envolvendo o primeiro curso de Ciência da Computação (CS1). Por exemplo, um instrumento de avaliação independente da linguagem de programação permite a comparação de abordagens pedagógicas de maneiras que não eram possíveis anteriormente. Em particular, agora é possível investigar se existem diferenças identificáveis e persistentes na compreensão dos alunos sobre conceitos fundamentais de Ciência da Computação com base na abordagem pedagógica ou na linguagem de programação utilizada no primeiro curso. Quando combinado com outros métodos de pesquisa, seria possível começar a identificar quais dos muitos fatores em um ambiente de aprendizagem de CS1 (por exemplo, o instrutor, a linguagem de programação, o ambiente de desenvolvimento integrado (IDE), a abordagem pedagógica, a motivação do aluno) são as alavancas que impulsionam o domínio dos conceitos de computação pelos alunos.

A avaliação é uma parte importante da agenda de pesquisa em educação em ciência da computação. Mas como as práticas de avaliação “moldam a compreensão das pessoas sobre o que é importante aprender” [11, p. 111], é vital que a área continue a expandir o escopo e a disponibilidade de ferramentas de avaliação validadas.

6. AGRADECIMENTOS

Este material baseia-se em trabalho financiado pela Fundação Nacional de Ciência (National Science Foundation) sob os números de concessão 0512213 e 0634629. Quaisquer opiniões, conclusões ou recomendações expressas neste material são de responsabilidade do(s) autor(es) e não refletem necessariamente as opiniões da Fundação Nacional de Ciência.

7. REFERÊNCIAS

- [1] Associação Americana de Pesquisa Educacional, Associação Americana de Psicologia e Conselho Nacional de Medição em Educação. Padrões para testes educacionais e psicológicos. Associação Americana de Pesquisa Educacional, Washington, DC, 1999.
- [2] J. Cohen. Análise de Poder Estatístico para o
- Ciências Comportamentais. Lawrence Erlbaum Associates, Hillsdale, NJ, 2ª edição, 1988.
- [3] AM Decker. Como os alunos se comparam: um Instrumento de Avaliação para Introdução à Ciência da Computação. Tese de doutorado, Universidade de Buffalo (SUNY), Buffalo, NY, 2007.
- [4] K. Goldman, P. Gross, C. Heeren, G. Herman, L. Kaczmarczyk, MC Loui e C. Zilles. Identificação de conceitos importantes e difíceis em cursos introdutórios de computação usando um processo Delphi. In SIGCSE '08: Anais do 39º Simpósio Técnico da ACM sobre Educação em Ciência da Computação, páginas 256–260, 2008.
- [5] RK Hambleton, H. Swaminathan e HJ Rogers. Fundamentos da teoria da resposta ao item. Sage Publications, Newbury Park, CA, 1991.
- [6] D. Hestenes, M. Wells e G. Swackhamer. Força Inventário de conceitos. The Physics Teacher, 30:141–158, março de 1992.
- [7] LC Kaczmarczyk, ER Petrick, JP East e GL Herman. Identificando concepções errôneas de programação em estudantes. In SIGCSE '10: Anais do 41º Simpósio Técnico da ACM sobre Educação em Ciência da Computação, páginas 107–111, 2010.
- [8] MT Kane. Validação. Em RL Brennen, editor, Medição Educacional, páginas 17–64. American Council on Education/ Praeger Publishers, Westport, CT, 4ª edição, 2006.
- [9] JC Libarkin e S. Anderson. Avaliação de Aprendizagem em cursos introdutórios de geociências: Resultados do inventário de conceitos de geociências. Journal of Geoscience Education, 53:394–401, 2005.
- [10] MD Miller, RL Linn e NE Gronlund. Validade. Em Medição e avaliação no ensino, páginas 80–99. Pearson Education, Upper Saddle River, NJ, 10ª edição, 2009.
- [11] PA Moss, BJ Girard e LC Haniford. Validade na avaliação educacional. Revisão de pesquisa em educação, 30(1):109–162, 2006.
- [12] AE Tew. Avaliando o conhecimento de conceitos fundamentais de informática introdutória de forma independente da linguagem. Tese de doutorado, Georgia Institute of Technology, Atlanta, GA, 2010.
- [13] AE Tew e M. Guzdial. Desenvolvimento de um validado Avaliação de conceitos fundamentais de CS1. Em SIGCSE '10: Anais do 41º Simpósio Técnico da ACM sobre Educação em Ciência da Computação, páginas 97–101, 2010.