

BDSI: Um Inventário de Conceitos Validados para Estruturas de Dados Básicas

Leo Porter

Universidade da Califórnia, San Diego

Daniel Zingaro

Universidade de Toronto Mississauga

Soohyun Nam Liao

Universidade da Califórnia, San Diego

Cynthia Taylor

Faculdade de Oberlin

Kevin C. Webb,

Swarthmore College

Cynthia Lee

Universidade de Stanford

Michael Clancy

Universidade da Califórnia, Berkeley

RESUMO

Um Inventário de Conceitos (IC) é uma avaliação validada para medir a compreensão conceitual de um tópico específico por parte dos alunos. Este trabalho apresenta um IC para Estruturas Básicas de Dados (EBD) e o processo pelo qual o IC foi projetado e validado. Discutimos: 1) a coleta de opiniões de docentes de diversas instituições sobre o conteúdo do instrumento; 2) uma série de entrevistas com alunos para identificar suas concepções e concepções errôneas sobre o conteúdo; 3) um processo iterativo de desenvolvimento de questões preliminares, realização de entrevistas com alunos para garantir a interpretação correta das questões do instrumento e coleta de feedback dos docentes sobre as próprias questões; e 4) uma avaliação estatística das versões finais do instrumento para garantir sua validade interna. Também apresentamos resultados iniciais de testes piloto do IC.

CONCEITOS CCS

• **Temas sociais e profissionais** y **Educação em Informática.**

PALAVRAS-CHAVE

Inventário de conceitos, avaliação, estruturas de dados

Formato de referência da ACM:

Leo Porter, Daniel Zingaro, Soohyun Nam Liao, Cynthia Taylor, Kevin C. Webb, Cynthia Lee e Michael Clancy. 2019. BDSI: Um Inventário de Conceitos Validado para Estruturas de Dados Básicas. In Conferência Internacional de Pesquisa em Educação Computacional (ICER '19), 12 a 14 de agosto de 2019, Toronto, ON, Canadá. ACM, Nova York, NY, EUA, 9 páginas. <https://doi.org/10.1145/3291279.3339404>

1 INTRODUÇÃO

Um Inventário de Conceitos (IC) é uma avaliação validada do conhecimento conceitual do aluno sobre um tópico específico. A validação é o processo pelo qual se determina se um IC mede o que os criadores pretendiam que ele medisse [1]. Os ICs surgiram inicialmente na física com o Inventário de Conceitos de Força [14], uma avaliação projetada para medir o conhecimento dos alunos sobre Mecânica Newtoniana, e desde então se tornaram populares nas disciplinas STEM para estabelecer o que os alunos sabem. O valor de tal avaliação inclui

Facilitar a pesquisa educacional, fornecendo um parâmetro comum para o conhecimento dos alunos e apoiando os instrutores que buscam diagnosticar pontos fortes (ou fracos) em seus cursos específicos.

Na área da ciência da computação, foram criados dois instrumentos para serem usados dessa maneira: o Segundo instrumento CS1 [20] e o Inventário de Conceitos de Lógica Digital [13]. Nosso trabalho complementa a área adicionando o Inventário de Estruturas de Dados Básicas (BDSI), um novo IC que pode ser usado em conjunto com um curso CS2 (ou o curso correspondente que ensina Estruturas de Dados Básicas).

Neste trabalho, descrevemos nosso processo de criação e validação do CI. Desenvolvemos questões que abordam tanto os Objetivos de Aprendizagem [22] quanto as dificuldades comuns com Estruturas de Dados Básicas [33]. O desenvolvimento das perguntas (e o desenvolvimento da IC) foi iterativo. Foram elaboradas perguntas, os alunos foram entrevistados sobre essas perguntas e, com base na interpretação delas, as perguntas foram revisadas. Periodicamente, foi solicitado feedback de professores de diversas instituições. À medida que as perguntas se tornavam mais refinadas, uma versão preliminar do Inventário de Competências (IC) foi utilizada em várias instituições para avaliar o desempenho dos alunos e a interpretação das perguntas. Em seguida, uma versão quase completa do IC foi utilizada em várias instituições para testar estatisticamente o instrumento. Uma rodada final de revisão foi então realizada, juntamente com uma aplicação final e análise estatística.

Neste artigo, apresentamos o processo pelo qual o Índice de Competência (IC) foi desenvolvido e validado. Especificamente, em conformidade com as práticas modernas de elaboração de avaliações, fazemos afirmações sobre a validade do instrumento e as fundamentamos com métodos e resultados correspondentes. Na etapa final, a validação estatística, apresentamos resultados do IC com base em sua aplicação em diversos tipos de instituições. Concluímos com uma discussão sobre alguns desafios no desenvolvimento do IC e incentivamos docentes e pesquisadores a começarem a utilizar este instrumento para avaliar o conhecimento dos alunos sobre Estruturas Básicas de Dados.

2. CONTEXTO

Um Inventário de Conceitos (IC) é uma avaliação de múltipla escolha elaborada para medir a compreensão dos alunos sobre os conceitos fundamentais de um curso. O objetivo de um CI não é avaliar somativamente um aluno específico, mas sim criar um instrumento padronizado que possa ser usado para comparar entre instrutores, cursos e pedagogias [1].

2.1 Incertezas de Computação em STEM e Ciência da

Computação As Incertezas de Computação surgiram de observações feitas por educadores de física em meados da década de 1980, de que o ensino convencional da física newtoniana não estava funcionando. Parecia que as crenças cotidianas sobre movimento e força eram incompatíveis com os conceitos newtonianos; além disso, o ensino convencional produzia pouca mudança nessas crenças [14]. Isso

É concedida permissão para fazer cópias digitais ou impressas, totais ou parciais, desta obra para uso pessoal ou em sala de aula, sem custo, desde que as cópias não sejam feitas ou distribuídas para fins lucrativos ou comerciais e que as cópias contenham este aviso e a citação completa na primeira página. Os direitos autorais dos componentes desta obra que pertencem a terceiros que não a ACM devem ser respeitados. É permitido fazer resumos com a devida atribuição. Para copiar, republicar, postar em servidores ou redistribuir para listas, é necessária permissão específica prévia e/ou o pagamento de uma taxa. Solicite permissões pelo e-mail permissions@acm.org.
ICER '19, 12 a 14 de agosto de 2019, Toronto, ON, Canadá © 2019 Association for Computing Machinery.
ACM ISBN 978-1-4503-6185-9/19/08...\$15,00
<https://doi.org/10.1145/3291279.3339404>

O desenvolvimento do Inventário de Conceitos de Força (ICF) [14] visava mensurar essas concepções errôneas dos alunos. O ICF levou à adoção da Instrução por Pares e outras técnicas de aprendizagem ativa no ensino de física [4]. Um estudo posterior [11] aplicou o ICF a 6542 alunos em 62 cursos diferentes e constatou que todos os cursos tradicionais apresentaram ganhos de aprendizagem inferiores aos obtidos com a aprendizagem ativa. O impacto do ICF na comunidade da física levou ao desenvolvimento de outros ICFs tanto em física [3, 19] quanto em diversas outras áreas científicas, incluindo química [17], genética [25], estatística [26], cálculo [8], geociências [18], oceanografia [2], enfermagem [23], astronomia [24, 32] e biologia [6].

Na área da ciência da computação, relativamente poucos ICs foram desenvolvidos [27]. Tew e Guzdial desenvolveram o FCS1, uma avaliação para CS1 que utiliza um pseudocódigo para medir o conhecimento básico de programação dos alunos [28]. Devido à indisponibilidade do FCS1, a Segunda Avaliação CS1 (SCS1), uma versão isomórfica do FCS1, foi desenvolvida e disponibilizada aos instrutores [20]. Um IC também foi desenvolvido para Lógica Digital [13]. Trabalhos preliminares em direção a ICs estão disponíveis para diversos outros tópicos da ciência da computação, incluindo algoritmos [5, 9], recursão [12], estruturas de dados avançadas [16], arquitetura [21] e sistemas operacionais [30].

2.2 Processo de Criação de CI

Adams e Wieman [1] listam vários requisitos para uma CI útil:

- Deve ser fácil de administrar e avaliar sem qualquer treinamento, e dentro do contexto de um cronograma normal de curso.
- O instrumento deve testar o 'pensamento especializado' de valor óbvio. aos professores.
- É preciso demonstrar que mede o que alega medir. (evidência de validade).

Para atender a esses critérios, um IC deve passar por um processo de desenvolvimento rigoroso. Adotamos o processo de desenvolvimento estabelecido por Adams e Wieman [1], usado para pelo menos nove inventários de conceitos anteriores, e que consiste nas seguintes etapas: (1) Trabalhar com os instrutores para estabelecer quais tópicos são importantes abordar. Isso pode ser feito por meio do processo Delphi [10], pesquisando os planos de aula e as provas finais dos instrutores ou discutindo com os instrutores. (2) Identificar tópicos importantes sobre os quais os alunos têm concepções erradas e desenvolver questões abertas sobre esses tópicos. Isso pode ser feito por meio de entrevistas com instrutores ou alunos.

(3) Identificar concepções errôneas específicas dos alunos ao responderem a perguntas abertas e usá-las como respostas distratoras ao desenvolver versões de múltipla escolha das perguntas abertas.

Isso pode ser feito administrando versões abertas do CI e registrando as respostas erradas dos alunos, ou pedindo aos alunos que verbalizem seus pensamentos enquanto resolvem o teste aberto.

(4) Validar questões de testes de múltipla escolha através de entrevistas de pensamento em voz alta com os alunos para garantir que as questões não sejam mal interpretadas e que as respostas não sejam escolhidas por razões erradas.

(5) Validar estatisticamente o teste. Após administrar o teste a uma grande amostra de estudantes (de preferência em vários tipos diferentes de instituições), avalie estatisticamente os resultados.

Existem diversas medidas de validade estatística. O SCS1 foi originalmente validado usando a Teoria Clássica dos Testes (TCT) para medir a dificuldade e a discriminação de cada questão [20]. (A discriminação mede a probabilidade de alunos que respondem corretamente a uma questão)

problemas particulares são responder corretamente a outros problemas.)

Trabalhos posteriores de Xie et al. [31] usaram a Teoria de Resposta ao Item (TRI) para avaliar o SCS1 e descobriram que quatro questões do teste eram muito difíceis quando usado como pré-teste. Outras medidas estatísticas comumente usadas incluem o alfa de Cronbach, usado para medir a consistência interna [13, 20, 31]; e o Delta de Ferguson, uma medida da discriminação do teste como um todo [3].

3 CONTEÚDO E DESENVOLVIMENTO BDSI

As 13 questões da versão final do instrumento estão resumidas na Tabela 1. As questões abrangem uma variedade de tópicos de estruturas de dados, incluindo listas, árvores, pilhas e conjuntos, com forte ênfase em listas e árvores. Embora todas as questões sejam de múltipla escolha, elas são apresentadas em dois formatos — algumas pedem que os alunos selecionem apenas uma opção, enquanto outras pedem que os alunos selecionem todas as opções aplicáveis. Cada questão tem um objetivo de aprendizagem principal de acordo com os objetivos descritos por Porter et al. [22]; a tabela correspondente é reproduzida na Tabela 2.

Ao desenvolver as questões para o BDSI, enfrentamos um desafio devido às variações no conteúdo dos cursos, particularmente em relação à escolha da linguagem de programação. Para tornar o BDSI acessível ao maior número possível de cursos, buscamos desenvolver questões que fossem agnósticas à escolha da linguagem de programação. Assim, ampliamos a linguagem de pseudocódigo originalmente usada no FCS1 [28] e no SCS1 [20] com pequenas modificações para incluir objetos.

Ao apresentar o BDSI aos alunos, fornecemos um breve pacote de referência que abrange:

- Instruções para responder às perguntas, destacando as diferenças entre os estilos de perguntas de múltipla escolha e de múltipla escolha.
- Breves definições das interfaces e estruturas de dados utilizadas no BDSI.

Fornecemos essas definições para auxiliar os alunos que podem ter aprendido terminologia diferente dependendo da linguagem de programação que utilizam (por exemplo, listas de arrays em Java, listas em Python e vetores em C++). • Um resumo conciso da linguagem de pseudocódigo do BDSI com diversos exemplos.

Independentemente da linguagem em que os alunos aprenderam o conteúdo (Java, Python ou C++), eles raramente identificaram diferenças entre linguagens de programação, a linguagem do pseudocódigo ou a terminologia de estruturas de dados como fontes de confusão durante nosso trabalho de validação, conforme discutido na Seção 4.4. Embora nosso pseudocódigo tenha sido testado com alunos usando diversas linguagens de programação imperativas, não abordamos Estruturas de Dados Básicas em paradigmas funcionais como Scheme, cujo ensino e aprendizagem podem ser diferentes.

3.1 Equipe de Desenvolvimento do BDSI

Havia dois grupos principais de docentes participantes: a Equipe do Projeto BDSI, composta por seis docentes (os autores), e o Painel de Especialistas, composto por nove docentes. A Equipe do Projeto é formada por docentes com experiência em ensino, provenientes tanto de grandes universidades com forte foco em pesquisa quanto de pequenas faculdades de artes liberais. Reunimo-nos frequentemente durante o desenvolvimento do BDSI, elaboramos as perguntas, conduzimos (ou analisamos) entrevistas com alunos e analisamos os resultados dos testes-piloto do instrumento. Ao longo do processo de desenvolvimento do BDSI, consultamos um Painel de Especialistas: instrutores de CS2 de uma ampla gama de instituições.

Tabela 1: Resumo das questões, objetivos e estruturas de dados do BDSI.

Descrição da questão sobre estruturas de objetivos primários			
q1	4	LL	Adicione corretamente um elemento ao final de uma lista encadeada.
q2	1	LL	Compare o desempenho da lista com e sem um ponteiro de cauda.
q3	1	LL	Sem analisar o código, determine experimentalmente como um TAD foi implementado.
q4	1	LL	Analisar o desempenho da implementação de uma interface com uma lista ligada.
q5	5	BST	Identificar as ordens de inserção da BST que levam a árvores balanceadas.
q6	5	LL	Explique o comportamento de uma função que utiliza uma lista ligada.
q7	4	BT	Escreva uma função para calcular uma propriedade de uma árvore binária.
q8	3	Muitos	Compare o desempenho de satisfazer uma interface abstrata com várias estruturas.
q9	5	BST	Analisar o desempenho e o efeito da adição de elementos a uma BST (Árvore Binária de Busca) nas propriedades da árvore.
q10	2	LL, Stack	Avalie o desempenho da implementação da funcionalidade 'desfazer' com uma lista encadeada.
q11	6	BST:	Determine os casos apropriados para testar a correção de uma implementação de BST.
q12	4	BT	Calcule a largura de uma árvore binária.
q13	2	Lista, Conjunto	Compare a resolução de um problema com uma interface de lista versus uma interface de conjunto.

Tabela 2: Objetivos de aprendizagem adaptados de Porter et al. [22]

Objetivo #	Objetivo de Aprendizagem
1	Analisar a eficiência de tempo de execução de algoritmos relacionados a Projeto de estrutura de dados.
2	Selecione tipos de dados abstratos apropriados para uso em um aplicação dada.
3.	Compare as vantagens e desvantagens das estruturas de dados para selecionar a implementação apropriada para um tipo de dados abstrato.
4	Projetar e modificar estruturas de dados capazes de realizar operações de inserção , exclusão, busca e operações relacionadas.
5	Analisar e prever o comportamento de algoritmos (incluindo código) projetados para implementar dados.
	operações de estrutura.
6	Identificar e corrigir falhas na implementação de uma estrutura de dados que possam causar comportamentos diferentes.
	em relação ao projeto original.

de instituições norte-americanas, incluindo universidades com foco em pesquisa , universidades públicas regionais, faculdades de artes liberais e faculdades comunitárias. O Painel de Especialistas forneceu feedback periodicamente. durante o processo de desenvolvimento e foram extremamente úteis em contribuindo com seu contexto institucional para o trabalho. Nós expandimos sobre o papel que cada grupo desempenhou na Seção 4.

3.2 Versões BDSI

O BDSI passou por muitas versões antes de ser finalizado. No início do desenvolvimento, havia simplesmente uma coleção de perguntas. usado durante entrevistas para suscitar o pensamento dos alunos. Posteriormente, um coeso Uma sequência de perguntas surgiu e continuou a ser refinada. Existem duas versões principais que merecem destaque para os nossos propósitos aqui. Uma versão quase final, que chamamos de versão Beta, foi usada em execuções do instrumento no outono de 2018. Pequenas alterações em duas questões (q4 e As questões q5) foram posteriormente elaboradas com base no feedback e na análise. O resultado foi a versão que chamamos de versão final do BDSI; era usado no teste piloto final. Fornecemos análises para ambos. versões do instrumento na Seção 5.

3.3 Administração do Projeto Piloto

Para testar o BDSI, organizamos "sessões de revisão para o exame final" para ser realizada em conjunto com o final do período letivo para cursos que Ensinar Estruturas de Dados Básicas. Essas sessões foram conduzidas pelo curso. instrutores, assistentes de ensino ou outros membros do corpo docente do departamento e envolvidos alunos fazendo individualmente um "exame prático" de uma hora que era a versão atual do BDSI. Uma vez concluída, as apostilas de exame. foram recolhidas pela equipe que aplicou o exame, e a equipe então Revisamos as respostas do BDSI, bem como outros tópicos do curso. abordado pelo CI. Alunos que participaram da revisão do exame final. Os participantes da sessão podiam optar por participar ou não, conforme nossas diretrizes. protocolo aprovado pelo Comitê de Ética em Pesquisa com Seres Humanos (caso optassem por não participar, eles Eles poderiam ter concluído o exame prático, mas não utilizamos os dados deles.

4 MEDIDAS DE VALIDADE

O desenho de avaliação moderno envolve a organização de evidências para apoiar afirmações/interpretações [15]. Assim, a Tabela 3 fornece uma visão geral das alegações de validade e dos métodos e evidências em apoio a essas alegações. Cada alegação é discutida em detalhes no

segundo as subseções correspondentes. Como mencionado anteriormente, diversas instituições participaram. no projeto em vários pontos do processo de desenvolvimento. Um resumo das instituições e seu envolvimento pode ser encontrado na Tabela 4.

A tabela contém o tipo de instituição: Faculdade Comunitária (CC), Instituição de Ensino Superior com foco principal em graduação (PUI), Instituição de Artes Liberais (LAI) e Universidade de Pesquisa Intensiva (RIU); e o tamanho do Instituição: (P)equena (< 5000), (M)édia (5000 ≤ n < 10000) ou Grande (≥ 10.000 alunos). Existia uma Equipe de Projeto? membro e/ou membro do Painel de Especialistas em cada instituição também é indicado. (Observe que um membro da Equipe do Projeto mudou de instituição) durante o projeto, e que ambas as instituições estejam representadas; e que na IM havia dois membros no Painel de Especialistas devido à cobertura de tópicos em várias turmas.) Finalmente, a tabela indica o instituições onde as entrevistas foram realizadas e quantos alunos estiveram envolvidos no teste piloto das versões Beta e Final do instrumento. Para o fator de impacto institucional, houve duas execuções separadas do Versão beta durante dois períodos letivos distintos.

Tabela 3: Resumo das alegações de validade e métodos correspondentes

Seção de Reivindicação de Validade		Métodos que comprovam a validade
4.1	C1. CI aborda tópicos que importa para os instrutores	• Chegou-se a um consenso entre a Equipe do Projeto e o Painel de Especialistas, representando uma diversidade de grupos. conjunto de instituições, sobre os objetivos e tópicos de aprendizagem desejados [22]
4.2	C2. As perguntas de CI são significativas para os instrutores.	• Elaborei perguntas para abordar os objetivos de aprendizagem. • Muitas das perguntas iniciais foram elaboradas a partir de exercícios que haviam sido usados em sala de aula. configuração do quarto • Realizei reuniões com a Equipe do Projeto e o Painel de Especialistas para chegar a um consenso sobre as questões. foram valorizados • Questões adaptadas com base no feedback do Painel de Especialistas e dos instrutores. pilotando o instrumento
4.3	C3. As perguntas da CI abordam pontos-chave. conceitos e dificuldades dos alunos	• Alinhamento das perguntas com os objetivos de aprendizagem • Identificou possíveis equívocos e desenvolveu perguntas ao realizar um total de 50 entrevistas. Entrevistas com alunos de 3 instituições diferentes onde os alunos aprenderam o básico. Estruturas de dados em Java, C++ ou Python • Implementamos uma versão piloto aberta do CI com 408 alunos em 2 instituições para identificar dificuldades comuns e elaboração de questões de múltipla escolha com opções incorretas. • Publicamos as dificuldades dos alunos com Estruturas de Dados Básicas que identificamos [33]
4.4	C4. Os alunos interpretam corretamente as perguntas, incluindo perguntas escritas em pseudocódigo	• Realizei 49 entrevistas adicionais com verbalização do pensamento com alunos de 5 escolas diferentes. instituições à medida que analisavam as questões questões modificadas para atender à compreensão e interpretação dos alunos por aqueles que não são estudantes nativos de língua inglesa • Utilizou a discriminação de itens (como mostrado em C5) para demonstrar que os alunos estão corretamente interpretando perguntas
5	C5. O instrumento é interno consistente	• Realizei uma avaliação estatística utilizando a Teoria Clássica dos Testes e a Teoria da Resposta ao Item. Teoria para determinar se o instrumento é internamente consistente.

Tabela 4: Resumo das instituições e respectivos envolvimento nos projetos.

	IA	IB	IC	ID	IE	SE	IG	IH	II	IJ	IK	IL	IM	IN
Tipo de escola	CC	FR	AN	GO	LAI	RIU	LAI	RIU	RIU	CC	FR	AN	GO	LAI
Tamanho escolar	MLS				L	S	L	L	LLL	M	M	L	L	L
Equipe do Projeto					XXX		X	XX				X		
Painel de Especialistas	XX						X				X		XXXX	
Entrevistas					X			XXXX						
# Participantes Beta	16	17			12	14	63	82	408	110				
# Participantes finais					57	11		164						

4.1 C1: Objetivos de Aprendizagem

Nosso trabalho anterior entrevistou um grupo de professores de diversas áreas. Instituições norte-americanas para determinar quais tópicos e conceitos são comuns aos cursos de CS2 [22]. Descobrimos que os cursos de CS2 Dados básicos geralmente incluídos em diferentes instituições e instrutores. Estruturas como pilhas, filas, listas baseadas em arrays, listas ligadas, e árvores de busca binária. Trabalhando com nosso Painel de Especialistas em diversas instituições, elaboramos um conjunto de objetivos de aprendizagem para o nível Básico. Estruturas de Dados [22] (articuladas na Tabela 2). Esse trabalho é fundamental para alegação C1, pois estabeleceu o consenso necessário entre o corpo docente. sobre quais objetivos de aprendizagem eram mais importantes para Dados Básicos Estruturas. Utilizamos os objetivos de aprendizagem na construção da IC.

4.2 C2: Perguntas aceitas pelos instrutores

Para garantir que as perguntas no instrumento fossem aceitas. por instrutores, envolvemos os instrutores ao longo da questão processo de desenvolvimento. Os primeiros rascunhos de nossas perguntas foram feitos para estarem alinhados com os Objetivos de Aprendizagem, e foram retirados de experiências anteriores. estudos [5, 16, 33] ou de exercícios que haviam sido usados anteriormente nas turmas de CS2 em diversas instituições representadas pelo Projeto Equipe. A equipe do projeto (os autores) esteve profundamente envolvida no processo de desenvolvimento e aprimoramento de perguntas por meio do aluno entrevistas (descritas nas Seções 4.3 e 4.4). O Painel de Especialistas, Composta por docentes de um conjunto mais amplo e diversificado de instituições do que a Equipe do Projeto, a equipe foi envolvida em vários momentos. Logo no início do processo de desenvolvimento das perguntas, reunimo-nos com várias pessoas.

Membros do Painel de Especialistas participaram de uma conferência para coletar feedback sobre as primeiras versões do questionário. Esse feedback foi usado para refinar e reformular as perguntas. Um ano depois, as perguntas haviam sido bastante refinadas por meio de entrevistas, e o Painel de Especialistas recebeu uma versão quase final para revisão. Em uma discussão participativa entre a Equipe do Projeto e o Painel de Especialistas, o Painel deu algumas sugestões para aprimorar as perguntas. Mais importante ainda, durante essa reunião, os membros do Painel de Especialistas concordaram que as perguntas eram relevantes para eles como instrutores e que gostariam de usar o instrumento em seus cursos (posteriormente, alguns membros se voluntariaram para usar o instrumento para auxiliar na nossa validação).

Após o feedback positivo do Painel de Especialistas e as entrevistas de validação com os alunos descritas na Seção 4.4, a Equipe do Projeto começou a usar o instrumento em testes-piloto em diversas instituições. Durante os testes-piloto (incluindo os testes-piloto em larga escala descritos detalhadamente na Seção 5), instrutores de várias instituições participaram da aplicação do CI. Esses instrutores nos forneceram feedback, principalmente sugestões menores, que incorporamos à versão final do CI.

4.3 C3: Questões que abordam conceitos-chave Para melhor

compreender o pensamento dos alunos sobre conceitos-chave, nossa equipe realizou um total de 50 entrevistas em 3 instituições diferentes.

(ID, IG e IH). Essas entrevistas consistiram em pedir aos alunos que resolvessem questões de exemplo que visavam os objetivos de aprendizagem de Estruturas de Dados Básicas [22]. Os entrevistadores pediram aos alunos que verbalizassem seus pensamentos ao resolver os problemas e, ocasionalmente, fizeram perguntas de acompanhamento para esclarecer o raciocínio dos alunos sobre questões específicas. Além das entrevistas individuais, testamos versões abertas do exame entre o inverno de 2017 e o verão de 2017 com

408 alunos em 2 instituições (IG, IJ). A versão aberta solicitava que os alunos resolvessem os problemas sem opções de múltipla escolha ou, quando estas estivessem disponíveis, justificassem sua seleção em texto. No geral, esse processo de entrevistas e testes piloto com questões abertas identificou diversas dificuldades dos alunos com Estruturas Básicas de Dados, previamente publicadas em Zingaro et al. [33], e serviu de base para nossas alternativas de múltipla escolha. A elaboração das questões envolveu a intercalação da descoberta de concepções errôneas e o aprimoramento das questões, resultando, em última análise, em um conjunto de perguntas que estimulam o raciocínio dos alunos.

4.4 C4: As perguntas são interpretadas corretamente. Através das

entrevistas anteriores descritas na subseção anterior, tínhamos certa confiança de que as perguntas estavam sendo interpretadas corretamente. Para reforçar essa interpretação, utilizamos uma versão preliminar do instrumento completo em 26 entrevistas em 3 instituições (IG, IH e IJ) no verão e outono de 2017. Essas entrevistas foram realizadas com os participantes expressando seus pensamentos em voz alta.

onde os alunos respondiam às perguntas sozinhos, sem qualquer intervenção do entrevistador, exceto para que este os incentivasse a continuar pensando em voz alta caso ficassem em silêncio.

Essas entrevistas identificaram interpretações errôneas por parte dos alunos devido à ambiguidade nas perguntas, à falta de destaque suficiente em detalhes importantes para que os alunos reconhecessem sua relevância e às dificuldades com a terminologia por parte de alunos não nativos do inglês.

palestrantes. As perguntas foram revisadas em colaboração com a Equipe do Projeto ao longo dessas entrevistas.

Após obtermos mais segurança de que as perguntas estavam sendo interpretadas corretamente, uma segunda rodada de entrevistas foi realizada na primavera de 2018 com 23 alunos de 5 instituições (ID, IG, IH, IJ e II). Novamente, o formato foi de verbalização do pensamento com intervenção mínima do entrevistador. Essas entrevistas resultaram em algumas pequenas alterações na redação de algumas perguntas, mas a principal conclusão foi que as perguntas estavam sendo interpretadas corretamente.

Ao longo das entrevistas, os entrevistadores tiveram o cuidado de observar quaisquer confusões que pudessem surgir entre os alunos ao usar pseudocódigo em vez da linguagem de programação utilizada em suas respectivas aulas. Para surpresa da equipe, o pseudocódigo não representou uma barreira significativa para a interpretação das questões pelos alunos. A dificuldade dos alunos em compreender a linguagem era extremamente rara, mas quando isso acontecia (por exemplo, sobre como criar um novo objeto no pseudocódigo), eles consultavam o código de exemplo fornecido e resolviam a questão rapidamente.

Um indicador final de interpretação adequada é que as questões em todo o instrumento devem ser internamente consistentes. Essa consistência indica que, quando um aluno responde corretamente a uma determinada questão, é provável que ele a tenha compreendido e, consequentemente, que responda corretamente a outras questões do instrumento. Uma discussão mais aprofundada sobre consistência interna será apresentada na seção seguinte.

5 C5: BDSI É INTERNAMENTE CONSISTENTE

Nesta seção, descrevemos nossa análise das próprias questões com base em testes piloto realizados em diversas instituições. Para pontuar as questões, classificamos cada uma como correta ou incorreta (sem pontuação parcial). Para questões de múltipla escolha com uma única resposta correta, a resposta correta é obrigatória. Para questões de múltipla escolha com todas as alternativas selecionadas, todas as opções devem ser marcadas corretamente para que a questão receba a pontuação (por exemplo, se a resposta correta for as opções B, C e D, e um aluno selecionar apenas as opções B e C ou as opções B, C, D e E, a questão será considerada incorreta).

Como o BDSI foi aplicado em diversas escolas durante suas versões Beta e Final. Em algumas versões, apresentamos resumos desses resultados quando apropriado.

Para algumas medidas, combinamos resultados de instituições semelhantes para simplificar as comparações. Para a maior parte da avaliação, utilizamos técnicas estatísticas que exigem amostras de grande porte. Para realizar essa análise, incluindo o maior número possível de instituições, utilizamos dois conjuntos de dados principais: • Beta. Quatro

execuções piloto da versão Beta do instrumento incluíram mais de 50 participantes. A menor dessas quatro execuções piloto incluiu 63 participantes. Para incluir mais de uma instituição na análise, mas sem superestimar as amostras maiores (uma execução em uma instituição teve 408 participantes), selecionamos todos os 63 participantes do menor grupo e, em seguida, selecionamos aleatoriamente 63 alunos de cada uma das outras três execuções. Esse conjunto de dados de 252 alunos de 4 turmas diferentes em 3 instituições diferentes é denominado conjunto de dados Beta. • Final. Uma instituição teve 164 participantes na

versão Final.
versão do BDSI.

5.1 CTT vs. TRI

A Teoria Clássica dos Testes (TCT) é comumente usada para validar ICs [20, 29]. Ela fornece medidas úteis, como dificuldade da questão, questão

Tabela 5: Resumo da correção das questões

	Beta				Final						
CC FRANGO LAI RIU LAI RIU média.											
q1	0,81	0,41	0,87	0,5	0,67	0,61	0,65				
q2	0,31	0,37	0,12	0,14	0,09	0,18					
q3	0,81	0,71	0,65	0,7	0,81	q4	0,75	0,76	0,95	0,8	0,75
	0,85	0,79	0,72	0,81							
q5	0,62	0,35	0,4	0,27	0,33	0,33	0,39				
q6	0,56	0,47	0,63	0,66	0,51	0,61	0,58				
q7	0,31	0,18	0,33	0,45	0,33	0,39	0,33				
q8	0,88	0,47	0,75	0,67	0,58	0,72	0,68				
q9	0,38	0,06	0,31	0,22	0,18	0,21	0,23				
q10	0,56	0,47	0,66	0,48	0,6	0,48	0,54				
q11	0,69	0,71	0,78	0,69	0,77	0,7	0,73				
q12	0,5	0,35	0,45	0,46	0,53	0,48	0,46				
q13	0,94	0,65	0,91	0,83	0,82	0,78	0,82				

discriminação e confiabilidade interna, e essas medidas podem ser usado para identificar perguntas com baixo desempenho. No Ao mesmo tempo, apresenta diversas desvantagens importantes que o tornam inadequado. como a única fonte de dados quantitativos de validação. Primeiro, a CTT produz medidas que dependem das pessoas específicas que as tomam teste. Para cada aplicação de um teste, é necessário executar o CTT novamente. análise para verificar se a administração é “válida” [29]. Segundo, As pontuações do CTT confundem habilidade com propriedades das questões; as pontuações não podem ser consideradas medidas de capacidade sem qualquer influência externa. Em contrapartida, a Teoria da Resposta ao Item (TRI) é mais robusta: assumindo que os dados atendam às premissas da TRI, seus parâmetros são menos variáveis. sensível às particularidades da amostra submetida ao teste. No Seguindo as subseções, realizamos tanto a CTT (Seções 5.2–5.4) quanto a Análises IRT (Seções 5.5–5.6) para aprender sobre o IC a partir de ambas as perspectivas.

5.2 Correção

Um resumo da acerto de cada questão é apresentado na Tabela 5. Uma observação fundamental a partir desses resultados é que a exatidão variou. por tipo de instituição; também variava entre instituições individuais, mas Isso não é mostrado aqui para evitar que conclusões sejam tiradas sobre instituições participantes específicas. Identificar essa variabilidade em O desempenho dos alunos por questão e instituição é precisamente o O objetivo de tal instrumento é, no entanto, não fazer parte da validação. A segunda observação é que as perguntas variavam em dificuldade. Algumas eram mais fáceis para os alunos em geral (por exemplo, q4 e q13) e outros foram mais difíceis (por exemplo, q2 e q9). Uma ampla gama de dificuldades foi observada. O objetivo do projeto era garantir que alunos com diferentes níveis de habilidade fossem atendidos. capturado e que o corpo docente gostaria de usar o instrumento em seus aulas. Este último ponto foi levantado logo no início do desenvolvimento. processo, com a Equipe do Projeto e o Painel de Especialistas expressando preocupação de que o instrumento não seja nem muito difícil nem muito difícil Fácil no geral.

5.2.1 Correlações ponto-bisseriais. A correlação ponto-bisserial pode ser usado para medir o grau em que um item discrimina. entre alunos de alto e baixo desempenho. É um número entre -1 e 1: quanto maior o valor, maior o impacto positivo.

Tabela 6: Correlações ponto-bisseriais, quedas no alfa de Cronbach, e cargas fatoriais

Carregamento do fator de queda alfa ponto-bisserial						
Beta Final		Beta Final	Beta			Final
q1 0,34	q2	0,52	0	-0,03	0,1	0,22
0,52	q3 0,32	0,31	-0,03	-0,02	0,2	0,09
q4 0,43	q5	0,46	0	-0,03	0,07	0,17
0,44	q6 0,46	0,31	-0,02	-0,02	0,11	0,08
q7 0,53	q8	0,42	-0,01	-0,01	0,17	0,15
0,47	q9 0,49	0,47	-0,02	-0,01	0,16	0,19
q10 0,52		0,5	-0,03	-0,02	0,24	0,2
q11 0,45		0,51	-0,02	0	0,19	0,21
q12 0,52		0,49	-0,02	-0,01	0,2	0,17
q13 0,4		0,5	-0,03	-0,02	0,23	0,22
		0,52	-0,02	-0,02	0,16	0,21
		0,46	-0,03	-0,03	0,22	0,19
		0,41	-0,01	-0,02	0,11	0,15

relação entre a correção do item e a correção em o instrumento geral. Valores de pelo menos 0,2 são desejáveis [29]. Em Na metade esquerda da Tabela 6, apresentamos a correlação ponto-bisserial. para cada pergunta. Para cada conjunto de dados, descobrimos que cada medida é bem acima do limite de 0,2, oferecendo evidências de que cada questão é discriminatório.

5,3 Alfa de Cronbach

Os pesquisadores de IC frequentemente incluem uma medida de confiabilidade interna [7, 13, 20]. Se a confiabilidade for alta, então haverá uma quantidade significativa de variação. A variação nas pontuações dos testes resulta da variação na amostra que realizou o teste. (em vez de ser resultado da variabilidade nas respostas de indivíduos específicos) pessoas). Uma medida comum de confiabilidade interna é o alfa de Cronbach. alfa, e valores acima de 0,7 são considerados evidências suficientes para confiabilidade interna [13]. Os valores para Beta e Final foram 0,67 e 0,68, respectivamente, e estão próximos desse limite.

O alfa de Cronbach também pode ser usado para determinar se algum A questão individual está afetando negativamente a confiabilidade interna do teste . Especificamente, podemos remover cada item do teste separadamente. e calcular o alfa de Cronbach no teste excluindo esse item [13]. Em cada caso, esperamos que o valor alfa permaneça inalterado ou diminua: Se o valor alfa aumentasse, então teríamos evidências. que o teste é mais confiável sem a pergunta do que com ela. As duas colunas centrais da Tabela 6 fornecem as quedas alfa que observamos. obtido ao excluir cada questão do teste separadamente. Nós veja que as quedas alfa são zero ou negativas, portanto nenhum item é afetando negativamente a confiabilidade do teste. Além disso, a grande maioria de perguntas têm uma queda negativa, demonstrando que a pergunta está contribuindo para a confiabilidade da avaliação.

5.4 Delta de Ferguson

Ao contrário das correlações ponto-bisseriais que atribuem uma pontuação a cada questão, O delta de Ferguson é uma pontuação única para o teste como um todo. Ele mede o poder discriminatório de um teste através da quantificação da quantidade de dispersão observada nas pontuações dos respondentes [7]. Delta de Ferguson produz um valor entre 0 e 1, com pontuações de pelo menos 0,9 oferecendo

evidências de que o teste é discriminatório. Para nossos conjuntos de dados, o delta de Ferguson foi de 0,96 para a versão Beta e também de 0,96 para a versão Final. Em ambos os casos, podemos interpretar o resultado como evidência de que a avaliação é discriminatória.

5.5 Teoria da Resposta ao Item: Preliminares

Ao modelar com a TRI, é necessário escolher entre vários modelos concorrentes. Os modelos 1PL, 2PL e 3PL são frequentemente os de interesse [31]. Um modelo 1PL atribui um parâmetro de dificuldade a cada questão; um modelo 2PL adiciona um parâmetro de discriminação; e um modelo 3PL adiciona um parâmetro de acerto por acaso. Testamos cada um desses modelos e optamos pelo modelo 2PL. As medidas de ajuste do modelo 1PL foram as mais fortes entre os três modelos, mas três questões não se ajustaram a esse modelo. Todas as questões se ajustaram aos modelos 2PL e 3PL; escolhemos o modelo 2PL por apresentar medidas de ajuste mais fortes do que o modelo 3PL.

Para realizar nossa análise, precisamos estabelecer que o instrumento é unidimensional. Essa é uma premissa importante: a TRI pressupõe que os dados refletem uma única característica subjacente [31] — em nosso caso, o nível de desempenho de um aluno em Estruturas Básicas de Dados. Uma maneira de testar essa unidimensionalidade é por meio de uma Análise Fatorial Confirmatória (AFC). Em uma AFC, o pesquisador postula uma série de fatores subjacentes que são hipotetizados para explicar as relações entre as variáveis. Como estamos testando se um único fator (dimensão) explica o padrão dos dados, realizamos uma AFC com apenas um fator. Nossos resultados confirmam que o modelo se ajusta bem aos dados, sugerindo que estamos medindo uma única característica subjacente. Especificamente [31]:

- O valor do qui-quadrado do modelo é uma indicação geral de se o modelo se ajusta aos dados. Um valor p alto, de pelo menos 0,05, sugere que devemos rejeitar a hipótese de que o modelo não se ajusta aos dados. Aqui, temos evidências de ajuste do modelo: para Beta, $\chi^2(252) = 71,6$, $p = 0,29$; para Final, $\chi^2(164) = 52,7$, $p = 0,8$.
- Também analisamos outras medidas de ajuste e as comparamos com os valores de corte da literatura. Exigimos um Índice de Ajuste Comparativo (CFI) de pelo menos 0,9; nosso valor foi de 0,98 para Beta e 1,0 para Final. O Erro Quadrático Médio da Aproximação (RMSEA) deve ser de no máximo 0,1; o nosso foi de 0,02 para Beta e 0,00 para Final.

Nas duas colunas da direita da Tabela 6, apresentamos a carga fatorial para cada item. A carga fatorial representa a proporção da variância do item que o fator explica (entre 0 e 1). Todos os itens apresentaram um valor de $p < 0,01$, o que indica fortemente que a variância de cada item é significativamente explicada pelo fator.

Todas essas medidas apontam para um conjunto de dados unidimensional, e assim por diante. Prosseguimos com a análise IRT.

5.6 Teoria da Resposta ao Item: Discriminação.

Um modelo TRI (Teoria da Resposta ao Item) representa graficamente cada questão com base no desempenho relativo do aluno no restante do teste e, ao fazer isso, determina a discriminação e a dificuldade da questão. Por exemplo, na Figura 1, temos a curva TRI para a Q1 (Questão 1) do conjunto de dados Final. No eixo x , temos o escore z da habilidade do aluno com base em seu desempenho em outras questões do teste (todas as outras questões, exceto a Q1), onde um escore mais alto significa melhor desempenho. O eixo y representa a probabilidade de um aluno com aquele nível de habilidade responder corretamente à Q1. À medida que a habilidade do aluno melhora, sua probabilidade de responder corretamente à Q1 também aumenta. Idealmente, a curva no gráfico é íngreme, pois isso denota a questão.




Figura 1: Curva IRT para Q1 na Prova Final

A questão discrimina bem entre populações de estudantes (a Q1, de fato, discrimina bem). O valor de x correspondente ao ponto em que a curva cruza o limiar de probabilidade de 0,5 indica a dificuldade da questão; para a Q1, a dificuldade é -0,53. Valores mais negativos indicam questões mais fáceis, enquanto valores mais altos indicam questões mais difíceis.

Para cada questão que diferencie os alunos, exigimos que seu parâmetro de discriminação seja aceitável. Mas o limite para o que é aceitável não é consensual na literatura. Valores de 0,7 ou 0,8 são típicos [31].

A Tabela 7 apresenta a dificuldade e o poder de discriminação de cada questão para os dois conjuntos de dados. Constatamos que o poder de discriminação para quase todas as questões é superior a 0,8 em ambos os conjuntos de dados. Algumas questões (q1 e q3 para Beta e q4 para Final) apresentam poder de discriminação inferior a 0,8 em um conjunto de dados, mas não no outro. A variação nas populações estudantis pode ajudar a explicar essa diferença. Por exemplo, a questão q4 apresenta o segundo maior poder de discriminação em Beta, mas o menor em Final. Ao conversar com o professor de Final, descobrimos que ele havia ensinado exatamente essa questão aos seus alunos.

Constatamos que o teste apresenta uma mistura de questões de alta e baixa dificuldade. Corroborando as porcentagens de acertos na Tabela 5, as questões 2 e 9 são bastante difíceis, enquanto as questões 4 e 13 são relativamente fáceis.

De forma geral, esses resultados confirmam que as questões do BDSI discriminam bem e que apresentam diferentes níveis de dificuldade.

6 DISCUSSÃO

Nesta seção, discutimos dois exemplos dos desafios sutis envolvidos na validação de que os alunos interpretam as perguntas conforme o pretendido, nossa confiança na formulação atual e como o corpo docente pode acessar e usar o instrumento.

6.1 Alterações no BDSI: Um Conto de Advertência Para dar uma ideia dos tipos de problemas que surgem na validação de perguntas, apresentamos duas anedotas ilustrativas das experiências da Equipe do Projeto.

A questão 2 pergunta aos alunos sobre as operações cujo desempenho melhora ao adicionar um ponteiro de cauda a uma lista simplesmente encadeada. Em entrevistas de verbalização do raciocínio, os alunos frequentemente afirmavam inicialmente que isso melhorava tanto a adição na cauda (correto) quanto a remoção da cauda (incorreto). Mas, para aproximadamente metade desses alunos, à medida que discutiam suas escolhas, muitos se autocorrigiram, percebendo que a remoção

Tabela 7: Dificuldade e discriminação dos itens por questão

	Beta		Final	
	Discr.	Diferencial	Discr.	Diferencial
q1	-1,7	0,38	-0,53	1,12
q2	1.1	2.03	3	0,86
q3	-3,03	0,33	-1,38	1,31
q4	-1,69	1,7	-2,71	0,4
q5	0,88	q6	0,89	1.08
-0,86	q7	0,41	0,8	-0,66
q8	q9	q10	1,27	0,53
			1,02	
	-1,1	1.11	-1	1,33
	1.1	1,36	1,25	1,42
0,01	q11	-1,13	1,33	0,14
				1.05
0,95	-0,92	1,25		
q12	0,31	0,1	0,85	0,93
q13	-2,02	0,98	-1,69	0,86

Partindo da cauda, não será mais rápido, pois não há como ajustar rapidamente a cauda para o elemento precedente. No entanto, durante execuções em larga escala de Com o instrumento, descobrimos que a porcentagem de alunos corretamente...

Resolver a questão sem interromper os pensamentos em voz alta. Havia Há variação entre as instituições, mas uma taxa média de acerto (entre as instituições) de 17% está abaixo da nossa experiência com verbalizações simultâneas. Suspeitamos que...

O ato de discutir a sua escolha alterou a resposta deles.

A questão 9 aborda o impacto da adição de vários valores.

para uma BST cuja raiz atualmente detém seu valor mediano (onde todos (os novos valores são maiores que os maiores valores atualmente na BST), foi através de muitas iterações de redação. Uma opção escolhida certa vez disse "A raiz sustenta a parte mediana da árvore." Os alunos tiveram dificuldades com se nos referíamos à mediana da árvore original (uma afirmação verdadeira) ou Se nos referíamos à mediana da nova árvore (uma árvore falsa), então adicionamos. a nomenclatura T0 para se referir à árvore original e T1 para se referir a a árvore após as adições. Após essa mudança, os alunos corretamente interpretaram as opções (embora muitos ainda tenham respondido incorretamente).

Essas experiências ilustram a sutileza da formulação da pergunta. e podem ocorrer problemas com o formato da apresentação. Portanto, alertamos aqueles tentar alterar o instrumento ignora o processo de validação que realizamos para desenvolver o BDSI. Foi apenas com a combinação completa de elementos da Tabela 3 que obtivemos confiança na formulação da pergunta. Como tal, mesmo bem-intencionada As tentativas de aprimorar o teste provavelmente introduzirão imprevistos. problemas e limitarão a capacidade de realizar comparações cruzadas.

em comparação com os resultados do BDSI não modificado.

O corpo docente também deve estar atento a como exemplos de ensino inspirados diretamente pelo BDSI podem prejudicar a capacidade de mensuração do instrumento. Já vivenciamos uma situação acidental desse tipo durante um de nossos projetos-piloto (Final), conforme mencionado na Seção 5.6.

O instrutor havia ministrado uma palestra sobre as implicações de desempenho de Ao usar uma LinkedList para criar um armazenamento de chave-valor, diminui-se o poder de discriminação medido para essa questão em relação a questões idênticas. formulação dessa pergunta no piloto anterior na mesma instituição . (Observamos que o instrutor fez isso sem levar em consideração o

BDSI; eles simplesmente sempre ensinaram esse conceito explicitamente.)

6.2 Como usar o BDSI

Feita essa ressalva, vamos agora abordar como o corpo docente pode Adotar o BDSI como instrumento para comparar o desempenho geral dos alunos. conhecimento de estruturas de dados básicas em diversas instituições, instrutores, cursos e pedagogias.

O BDSI está disponível para o corpo docente através da adesão ao grupo BDSI online.1

O formato do instrumento é um PDF em duas partes: o material introdutório (incluindo guia de pseudocódigo) e o teste Ele mesmo. Deve ser impresso para que os alunos o completem em papel. Há Existem alguns diagramas no BDSI, e uma versão acessível, embora não validada, com descrições textuais no lugar dos diagramas também está disponível.

Disponível para alunos com deficiência visual preencherem em um dispositivo. com software leitor de tela. Os professores devem planejar fornecer aos alunos

Leva cerca de 1 hora para concluir o CI. Como os CIs não são destinados a serem implementados. para ser utilizado na avaliação somativa de alunos individuais, o

O BDSI não deve ser usado em, ou em substituição de, uma avaliação final abrangente.

exame. No entanto, os alunos podem achá-lo útil como um "vestimenta" supervisionada. "ensaio" de prática para a prova final, que o corpo docente pode usar como uma forma de avaliação mútua.

oportunidade vantajosa para a obtenção de resultados estudantis. Para preservar a utilidade e a validade do BDSI, o corpo docente deve Nunca divulgue publicamente a prova ou suas soluções, e os alunos devem não terão permissão para levar sua cópia da sala durante ou após o término da aula. administração.

7 CONCLUSÃO

Neste trabalho, apresentamos o BDSI — um Inventário de Conceitos para Dados Básicos. Estruturas — desenvolvidas por meio de consultas com o corpo docente e entrevistas com os alunos. As perguntas sobre o IC foram desenvolvidas por meio de um processo iterativo de revisão e feedback até que o corpo docente em uma variedade das instituições relataram valorizar o conteúdo e os alunos interpretaram as questões de forma consistente e correta. Um projeto piloto em larga escala.

uma execução do instrumento seguida por uma execução menor baseada no resultado final. As revisões possibilitaram a avaliação estatística do instrumento. Utilizando Na Teoria Clássica dos Testes e na Teoria da Resposta ao Item, o IC foi demonstrado.

Para garantir consistência interna, utilizando uma variedade de medidas estatísticas. O valor de um IC não está nas próprias perguntas, mas em sua abordagem. capacidade de impulsionar mudanças pedagógicas. Como tal, juntamente com a elaboração de relatórios. Em relação à validade do instrumento, disponibilizamos o IC para a comunidade. Pesquisadores da área da educação agora podem usar essa validação. avaliação do conhecimento dos alunos em suas pesquisas e dos instrutores podem usá-lo para avaliar os pontos fortes e fracos de seus próprios currículos . Em última análise, esperamos que este indicador de competência seja adotado e implementado.

pela comunidade de pesquisa em educação em ciência da computação para aprimorar ainda mais o aprendizado dos alunos. aprendizado.

AGRADECIMENTOS

Os autores agradecem as contribuições dos seguintes colaboradores: Meghan Allen, Owen Astrachan, John Bell, Darci Burdge, Stephanie Chasteen, Rajendra Chattergoon, John Donaldson , Maureen Doyle, John Glick, Paul Hilfinger, Josh Hug, Marina Langlois, Kevin Lin, Lisa Meeden, Zach Palmer, Mahika Phutane, Joe Politz, Kate Rydberg, Samar Sabie, Kate Sanders, Jacqueline Smith, Marty Stepp, Paramsothy Thananjeyan, Steve Wolfman, Anna Zait- sev e Christine Zhou. Este trabalho foi parcialmente financiado pela NSF. Prêmio 1505001.

1https://groups.google.com/forum/##forum/cs2-bdsi-concept-inventory

REFERÊNCIAS

- [1] W. Adams e C. Wieman. Desenvolvimento e validação de instrumentos para medir a aprendizagem do pensamento especializado. *International Journal of Science Education*, 33(9):1289–1312, 2011.
- [2] L. Arthurs, JF Hsia e W. Schweinle. O inventário de conceitos de oceanografia : uma avaliação semicustomizável para medir a compreensão de oceanografia pelos alunos. *Journal of Geoscience Education*, 63(4):310–322, 2015.
- [3] SV Chasteen, RE Pepper, MD Caballero, SJ Pollock e KK Perkins. Diagnóstico de eletrostática de nível superior no Colorado: uma avaliação conceitual para o nível júnior. *Physical Review Special Topics - Physics Education Research*, 8(2), 2012.
- [4] CH Crouch e E. Mazur. Instrução por pares: Dez anos de experiência e resultados. *Revista americana de física*, 69(9):970–977, 2001.
- [5] H. Danielsiek, W. Paul e J. Vahrenhold. Detecção e compreensão de concepções errôneas de alunos relacionadas a algoritmos e estruturas de dados. Em *Anais do 43º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*, páginas 21–26, 2012.
- [6] C. D'Avanzo. Inventários de conceitos de biologia: visão geral, estado atual e próximos passos. *BioScience*, 58(11):1079–1085, 2008.
- [7] L. Ding, R. Chabay, B. Sherwood e R. Beichner. Avaliando uma ferramenta de avaliação de eletricidade e magnetismo: Avaliação breve de eletricidade e magnetismo. *Physical review special Topics-Physics education research*, 2(1):010105, 2006.
- [8] J. Epstein. Desenvolvimento e validação do inventário de conceitos de cálculo. In *Anais da nona conferência internacional sobre educação matemática em uma comunidade global*, volume 9, páginas 165–170, 2007.
- [9] MF Farghally, KH Koh, JV Ernst e CA Shaffer. Rumo a um inventário de conceitos para tópicos de análise de algoritmos. Em *Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*, páginas 207–212, 2017.
- [10] K. Goldman, P. Gross, C. Heeren, G. Herman, L. Kaczmarczyk, MC Loui e C. Zilles. Identificando conceitos importantes e difíceis em cursos introdutórios de computação usando um processo Delphi. *SIGCSE Bulletin*, 40(1):256–260, 2008.
- [11] RR Hake. Envolvimento interativo versus métodos tradicionais: Uma pesquisa com seis mil estudantes sobre dados de testes de mecânica para cursos introdutórios de física. *American Journal of Physics*, 66(1):64–74, 1998.
- [12] S. Hamouda, SH Edwards, HG Elmongui, JV Ernst e CA Shaffer. Um inventário de conceitos básicos de recursão. *Computer Science Education*, 27(2):121–148, 2017.
- [13] GL Herman, C. Zilles e MC Loui. Uma avaliação psicométrica do inventário de conceitos de lógica digital. *Educação em Ciência da Computação*, 24(4):277–303, 2014.
- [14] D. Hestenes, M. Wells e G. Swackhamer. Inventário do conceito de força. *A Física Professor*, 30(1):141–158, 1992.
- [15] N. Jorion, BD Gane, K. James, L. Schroeder, LV DiBello e JW Pellegrino. Uma estrutura analítica para avaliar a validade das afirmações do inventário de conceitos. *Revista de Educação em Engenharia*, 104(4):454–496, 2015.
- [16] K. Karpietz e SA Wolfman. Conceitos errôneos e questões de inventário de conceitos para árvores de busca binária e tabelas hash. Em *Anais do 45º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*, páginas 109–114, 2014.
- [17] S. Krause, J. Birk, R. Bauer, B. Jenkins e MJ Pavelich. Desenvolvimento, teste e aplicação de um inventário de conceitos de química. Em *34ª Conferência Anual Frontiers in Education*, 2004.
- [18] J. Libarkin, E. Ward, S. Anderson, G. Kortemeyer e S. Raeburn. Revisitando o inventário de conceitos de geociências: um apelo à comunidade. *GSA Today*, 21(8):26–28, 2011.
- [19] DP Maloney, TL O'Kuma, CJ Hieggelke e A. Van Heuvelen. Levantamento do conhecimento conceitual dos alunos sobre eletricidade e magnetismo. *American Journal of Physics*, 69(S1):S12–S23, 2001.
- [20] MC Parker, M. Guzdial e S. Engleman. Replicação, validação e uso de uma avaliação de conhecimento CS1 independente de idioma. Em *Anais da 12ª Conferência ACM sobre Pesquisa Internacional em Educação em Computação*, 2016.
- [21] L. Porter, S. Garcia, H.-W. Tseng e D. Zingaro. Avaliando a compreensão dos alunos sobre conceitos básicos em arquitetura de computadores. Em *Anais da 18ª conferência da ACM sobre Inovação e tecnologia no ensino de ciência da computação*, páginas 279–284, 2013.
- [22] L. Porter, D. Zingaro, C. Lee, C. Taylor, KC Webb e M. Clancy. Desenvolvimento de objetivos de aprendizagem em nível de curso para estruturas de dados básicas em CS2. Em *Anais do 49º simpósio técnico da ACM sobre Educação em Ciência da Computação*, páginas 858–863, 2018.
- [23] CY Read e LD Ward. Desempenho do corpo docente no inventário de conceitos de enfermagem genômica. *Journal of Nursing Scholarship*, 48(1):5–13, 2016.
- [24] PM Sadler, H. Coyle, JL Miller, N. Cook-Smith, M. Dussault e RR Gould. Inventário de conceitos de astronomia e ciências espaciais: desenvolvimento e validação de instrumentos de avaliação alinhados com os padrões nacionais de ciências do ensino fundamental e médio (K-12). *Revista de Educação em Astronomia*, 8(1):010111, 2010.
- [25] MK Smith, WB Wood e JK Knight. A avaliação do conceito de genética: um novo inventário de conceitos para avaliar a compreensão dos alunos sobre genética. *CBE—Life Sciences Education*, 7(4):422–430, 2008.
- [26] A. Stone, K. Allen, TR Rhoads, TJ Murphy, RL Shehab e C. Saha. O inventário de conceitos estatísticos: um estudo piloto. Em *33ª Conferência Anual Frontiers in Education*, 2003.
- [27] C. Taylor, D. Zingaro, L. Porter, KC Webb, CB Lee e M. Clancy. Inventários de conceitos de ciência da computação: passado e futuro. *Educação em Ciência da Computação*, 24(4):253–276, 2014.
- [28] AE Tew e M. Guzdial. Desenvolvimento de uma avaliação validada de conceitos fundamentais de CS1. Em *Anais do 41º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*, páginas 97–101, 2010.
- [29] CS Wallace e JM Bailey. Os inventários de conceitos medem realmente alguma coisa. *Revista de Educação em Astronomia*, 9(1):010116, 2010.
- [30] KC Webb e C. Taylor. Desenvolvimento de um inventário de conceitos pré e pós-curso para avaliar a aprendizagem de sistemas operacionais. Em *Anais do 45º simpósio técnico da ACM sobre educação em ciência da computação*, páginas 103–108, 2014.
- [31] B. Xie, MJ Davidson, M. Li e AJ Ko. Uma avaliação da teoria de resposta ao item de uma avaliação de conhecimento CS1 independente de idioma. Em *Anais do 50º Simpósio Técnico da ACM sobre Educação em Ciência da Computação*, páginas 699–705, 2019.
- [32] M. Zeilik. Nascimento do teste diagnóstico de astronomia: evolução do prototeste. *Astronomy Education Review*, 1(2):46–52, 2002.
- [33] Zingaro D, Taylor C, Porter L, Clancy M, Lee C, Nam Liao S e Webb KC. Identificação das dificuldades dos alunos com estruturas de dados básicas. In *Anais da 14ª Conferência Internacional da ACM sobre Pesquisa em Educação Computacional*, páginas 169–177, 2018.